2026 年 10 月 25 日核验修订版 前文历史成绩保留 新实验及最新状态见末节补充验证

基于 AI 的 5G 网络关键性能指标预测与异常检测系统

数据集统计分析报告

gotsf-ds 四类 KPI 的原始数据审计、预处理与时间序列构建

数据集：gotsf-ds / netop/gotsf-ds

处理工具：Python / Pandas / NumPy / scikit-learn

1. 实验目的与数据来源

本实验以公开的 gotsf-ds 数据集为输入，完成数据结构识别、数据质量审计、时间序列划分、标准化与归一化处理，为后续传统机器学习 KPI 预测提供统一的数据基础。

数据对象	规模或范围	说明
数据来源	gotsf-ds	四份 *_train_0w-5w.csv 文件
KPI 种类	4	DLPRB / DLThpVol / DLThpTime / MR_number
时间索引	0–839	840 个等间隔索引；原记录按小时描述
空间对象	30 基站 / 90 cell / 2880 beam	列名含 base_station_cell_beam 标识
输出文件	kpi_timeseries.csv	2,419,200 行 × 17 列

2. 数据格式与对象标识

原始 CSV 每个 KPI 单独存储为宽表，首列由 Pandas 读为 Unnamed: 0，其余 2880 列按“基站_cell_beam”编码。预处理脚本将首列恢复为 Time，并将多份宽表按相同时间和 beam 结构合并为统一长表。

原始列示例	转换后字段	对应含义
Unnamed: 0	Time	时间索引
12_2_31	base_station=12; cell=2; beam=31	三层网络对象标识
各 KPI 对应数值	DLPRB / DLThpVol / DLThpTime / MR_number	同一时间和 beam 的四种观测值

3. 原始数据质量审计

使用审计脚本对时间连续性、重复时间、完全重复行、缺失值、无限值、负值及非法 beam 标识进行核验，并确认四份 KPI 文件具有一致的时间轴和 beam 结构。原始审计结果如下表所示。

检查项	DLPRB	DLThpVol	DLThpTime	MR_number
时间点数量	840	840	840	840
Beam 数量	2880	2880	2880	2880
缺失值	0	0	0	0
无穷值	0	0	0	0
负值	0	0	0	0
重复时间	0	0	0	0
完全重复行	0	0	0	0

检查项	DLPRB	DLThpVol	DLThpTime	MR_number
时间缺口	0	0	0	0
非法 Beam 标识	0	0	0	0

4. KPI 统计特征

KPI	均值	中位数	P99	最大值	零值占比
DLPRB	0.5409	0.1750	5.0773	41.0263	23.77%
DLThpVol	0.3212	0.0952	3.5190	245.3746	31.76%
DLThpTime	0.4252	0.1293	4.4634	84.2068	27.76%
MR_number	0.6024	0.2273	5.0658	33.6660	20.15%

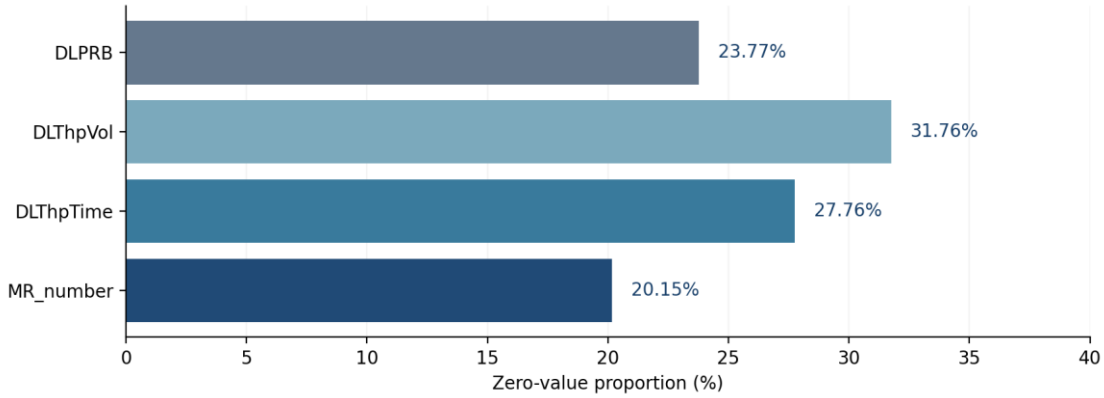


图 1 四类 KPI 的零值占比

四类 KPI 的零值占比在 20.15%至 31.76%之间。DLThpVol 的中位数为 0.0952，而其 99%分位数为 3.5190、最大值为 245.3746，反映出分布的明显右偏与长尾。零值可能对应 beam 在部分时段不活跃，因此本阶段保留合法零值；高幅值观测也未仅依据统计阈值直接判定为错误。

5. 数据清洗与结构重构

原始数据通过审计后，执行以下顺序的确定性处理：恢复 Time 字段，解析 beam 标识，对四类 KPI 按时间与 beam 对齐，构造 Time × beam 的长表，然后按时间顺序标记 train/test，并分别在训练期拟合两个数值变换器。

最终基础长表总行数为 840 × 2880 = 2,419,200。每行表示一个时间索引与一个 beam 的四类 KPI 观测。

6. 训练集和测试集划分

数据子集	Time 范围	时间索引数	样本行数
Train	0–671	672	1,935,360
Test	672–839	168	483,840

以时间索引作分割而不随机打乱，保证训练样本位于留出测试期之前。两个 scaler 均在 Train 上拟合，再用于 Train 与 Test 的数值变换，避免测试期统计信息进入训练预处理。

7. 标准化与归一化

7.1 StandardScaler

StandardScaler 以训练期均值与标准差计算 z = (x − μ_train) / σ_train；产出 _z 结尾的四列。训练期变换后的均值约为 0，标准差约为 1。

KPI	训练集均值 μ	训练集标准差 σ
DLPRB	0.536839	1.036266
DLThpVol	0.322617	1.096362
DLThpTime	0.422703	1.029392
MR_number	0.597422	1.039071

7.2 MinMaxScaler

MinMaxScaler 根据训练集最小值与最大值构建 x_mm = (x − min_train)/(max_train − min_train)。其训练样本映射到 0–1 区间；测试样本不重新拟合，也不强制裁剪超出训练范围的情况。

KPI	训练集最小值	训练集最大值	测试集归一化最大值
DLPRB	0	41.0263	0.8503
DLThpVol	0	245.3746	0.1214
DLThpTime	0	84.2068	0.4814
MR_number	0	33.6660	0.9601

8. 数据集与 20 维预测特征的衔接

本报告生成的 kpi_timeseries.csv 是包含 17 列的基础长表，本身不是 20 维机器学习特征矩阵。后续由 w2_traditional_ml_kpi_prediction_features.py 读取四类 KPI 的标准化列，在同一 beam 内构造滞后特征；下表明确了 20 维输入的组成，以便追溯模型训练数据的来源。

8.1 输入字段定义

KPI	五个输入字段（均为 StandardScaler 结果）
DLPRB	DLPRB_z_t / DLPRB_z_lag1 / DLPRB_z_lag2 / DLPRB_z_lag24 / DLPRB_z_lag168
DLThpVol	DLThpVol_z_t / DLThpVol_z_lag1 / DLThpVol_z_lag2 / DLThpVol_z_lag24 / DLThpVol_z_lag168
DLThpTime	DLThpTime_z_t / DLThpTime_z_lag1 / DLThpTime_z_lag2 / DLThpTime_z_lag24 / DLThpTime_z_lag168
MR_number	MR_number_z_t / MR_number_z_lag1 / MR_number_z_lag2 / MR_number_z_lag24 / MR_number_z_lag168

其中“_z_t”表示当前时间 t 的标准化观测；“_z_lagk”表示同一 beam 在 t−k 时刻的标准化观测。四个 KPI × 每类五个时间点，共 20 维；模型以相应 KPI 在 t+1 的原始尺度数值为预测标签。

8.2 有效样本与时间约束

项目	范围或数量	说明
有效特征时间	168–838	最长历史滞后 168 步，预测前向 1 步
有效目标时间	169–839	按目标时间判断训练集 / 测试集
有效训练样本	1,448,640	target_time < 672
留出测试样本	483,840	target_time ≥ 672

标准化器在原始训练时段 Time 0–671 上拟合，测试集不参与其参数估计；在后来补充的三折时间序列验证中，标准化器对每一折仅利用该折训练时间窗重新拟合。上述补充属于后续预测模块的数据构造与验证口径，并不改变本报告的原始数据审计结论。

9. 结论

本阶段完成了数据获取、质量审计、结构重构与两种缩放特征的生成。四份原始 KPI 的主要结构及数值检查均通过，得到包含 2,419,200 行、17 列的基础时间序列数据集。在此基础上，后续特征工程针对每个 beam 按四种 KPI × 五个历史时间点构造 20 维输入，并建立以 t+1 为目标的 1,932,480 条有效样本。基础数据预处理与预测特征构造属于两个连续步骤，分别由相应脚本输出与验证。

2026 年 10 月 25 日算法验证与导师反馈补充

本节为本次实际执行的补充验证。前文原留出成绩保留为历史实验，本节新成绩使用独立目录归档，不替换旧权重或旧图表。Web 入口、页面、交互与后台集成源码保持不变。

20 维输入与超参数来源

KPI	五个输入字段
DLPRB	DLPRB_z_t / DLPRB_z_lag1 / DLPRB_z_lag2 / DLPRB_z_lag24 / DLPRB_z_lag168
DLThpVol	DLThpVol_z_t / DLThpVol_z_lag1 / DLThpVol_z_lag2 / DLThpVol_z_lag24 / DLThpVol_z_lag168
DLThpTime	DLThpTime_z_t / DLThpTime_z_lag1 / DLThpTime_z_lag2 / DLThpTime_z_lag24 / DLThpTime_z_lag168
MR_number	MR_number_z_t / MR_number_z_lag1 / MR_number_z_lag2 / MR_number_z_lag24 / MR_number_z_lag168

每组按当前 t、滞后 1、2、24、168 小时排序。z 为训练期 StandardScaler 无量纲值，监督目标为 t+1 原始 KPI 尺度。Time 和 base_station/cell/beam 用于时间与身份对齐，不是额外输入维度。原数据未提供可据以换算的物理量纲，本报告保留数据集数值尺度，不擅写 Mbps、百分比等单位。最长滞后要求 169 个连续整小时；训练与推理列顺序的合成测试已通过。

主表传统 ML 及三种 DL 均使用固定人工设置；DL 的 Adam 与早停属于权重优化及轮次选择，不等于自动超参数搜索。只有 DLPRB 的 RF 已有 Optuna TPE 12 次、256 beam、三折平均 RMSE 搜索；范围为树数 40–160、深度 8–24、最小叶样本 5–50、max_features∈{sqrt,0.7,1.0}、max_samples 0.5–0.9。最佳 137/13/9/sqrt/0.698071 及 CV RMSE=0.473700 没有替换本次固定 30 树 RF；未补造调优后的全量测试成绩。逐模型参数及定义/引用见参数登记簿。

W4 异常统计证据与联合规则

复用既有 W4 统计，本次只重新核对全量标记逻辑和相关矩阵。483,840 条唯一 beam-hour 记录中，3σ 为 22,059，IQR 为 51,318，IF 为 9,900，联合候选 3,165。SVM 仍为历史 12,000 条抽样测试，不参加共识投票。逐 beam 偏度/峰度支持偏态厚尾普遍存在，但阈值宽度、beam 异质性和时间分布变化也影响标记率，不能把偏态指定为唯一因果机制。

KPI	|偏度|>1	超额峰度>3	3σ / IQR 标记率
DLPRB	86.25%	59.79%	1.77% / 4.13%
DLThpVol	98.33%	75.45%	1.60% / 4.59%
DLThpTime	96.56%	76.15%	1.85% / 4.87%
MR_number	59.76%	21.77%	1.39% / 2.76%

零 IQR 回退分布数为 0。逐 KPI 比例的分母各为 483,840，整条 beam-hour 的总体标记则是任意 KPI 触发，不能把四个逐 KPI 比例相加当总体比例。

逻辑组合	候选数
IF AND (3σ OR IQR)	3,165
IF AND IQR	3,159
IF AND 3σ	2,080
IF AND 3σ AND IQR	2,074

逻辑组合	候选数
IF OR 3σ OR IQR	58,108

OR 允许任一统计阈值支持，AND 要求 IF 与统计信号共同触发。本数据最终规则比 IF AND IQR 仅多 6 条，不能夸大 OR 分支的实际增益。候选规模的收紧/放宽不等于故障准确率或召回率改善；没有真实故障标签，不报告这些分类指标。

相关矩阵样本量与统计推断

KPI 组合	r	站级 bootstrap 95% CI	Holm p
DLPRB / DLThpVol	0.423	[0.169, 0.601]	7.61e-05
DLPRB / DLThpTime	0.697	[0.485, 0.795]	3.53e-10
DLPRB / MR_number	0.889	[0.841, 0.918]	1.1e-28
DLThpVol / DLThpTime	0.680	[0.535, 0.770]	2.68e-08
DLThpVol / MR_number	0.327	[0.065, 0.488]	0.0101
DLThpTime / MR_number	0.630	[0.449, 0.758]	8.36e-08

每对 n=3,165 是候选记录数；30 是基站聚类数，不代表 3,165 条独立样本。p 值来自站级聚类稳健零回归斜率检验，六对一起 Holm 校正；区间另用站级 bootstrap 估计。六对校正后 p 均<0.05，仅说明已筛选候选中的关联。候选选择可能改变相关结构，单向站级聚类未完全处理跨站同小时共同冲击；30 聚类仍为近似推断，不构成故障根因或因果证明。

代码修复与最新验收

修复仅涉及底层小时数据契约、DL 输出预检和 scaler 测试提取。训练加载器与推理拒绝共同缺小时、重复或非整数小时；保留 ML 20 维、DL 窗口、逆标准化和 IF AND (3σ OR IQR)定义。DL 当前代码已仅在内部训练前缀拟合 scaler；本次锁定该行为，没有把历史成绩改写为新成绩。

本次既有自动化基线 48 项通过；新增算法及统计回归后最新完整测试 57 项通过（final_tests.txt）。六个 Streamlit 页面 AppTest 加载及切换均无异常，实际新模型回载及 CSV 导出通过，原异常模型 5,760 条检测通过。另用 1 轮、512 条样本执行现有 DL CLI 仅作功能验收，不把其分数纳入模型比较。Web 页面及服务源码哈希保持不变。本次未以真人浏览器重走每个上传/下载控件或实时 WebSocket 训练全流程，不能将自动验收冒充完整手工验收。

证据根目录：reports/final_audit_20261025。新实验配置 protocol.json、逐次 runs.json、60 组 metrics.csv、hourly_losses.csv、48 组 holdout_significance.csv；实际权重及逐 beam-hour 配对预测位于 resources/final_audit_20261025（Git 忽略，需本机备份）。历史 reports/和 figures/数值保持原样。没有独立外部数据、全模型调参或生产实时网管接入，本次不扩大该范围。