2026 年 10 月 25 日核验修订版 前文历史成绩保留 新实验及最新状态见末节补充验证

基于 AI 的 5G 网络关键性能指标预测与异常检测系统

模型性能评估报告

传统机器学习的 5G KPI 一步超前预测与比较

数据集：gotsf-ds / 四种 beam-level KPI

模型：Persistence / Linear Regression / Decision Tree / Random Forest / XGBoost / LightGBM

1 实验目的与数据来源

本实验依据生成的 beam-level KPI 时间序列，构建传统机器学习基线，对 DLPRB、DLThpVol、DLThpTime、MR_number 四个目标进行下一时间索引预测，并比较不同方法的 MAE、RMSE 与 R^2。

项目	设置	说明
数据集	gotsf-ds	基于四份 *_train_0w-5w.csv
预测目标	各 KPI 在 t+1 的原始尺度数值	一次预测一个时间步
模型数量	6 种比较方法	含 Persistence 基线
记录总数	4 KPI × 6 = 24	全量模式：quick_mode=false
评估样本	483,840 行	beam-level 逐观测评分

2 时序特征构造与样本划分

环节	时间或样本范围	说明
原始观测索引	0–839	每个 beam 840 个记录
特征时刻	168–838	需具备 168 步历史与 1 步未来标签
目标时刻	169–839	按目标时间划分训练/测试
训练样本	1,448,640 行	target_time < 672
测试样本	483,840 行	target_time ≥ 672
有效总样本	1,932,480 行	2,880 个 beam ×671 个目标时刻

针对每一个 beam，分别提取 DLPRB、DLThpVol、DLThpTime 和 MR_number 在当前时刻及滞后 1、2、24、168 个时间步的标准化数值，每类 KPI 形成 5 个特征，共构成 20 维输入。预测标签为下一时间步的对应 KPI 原始数值。滞后特征在同一 beam 内构建，避免不同 beam 之间的数据混合。

2.1 20 维输入特征的字段清单

对 beam b，在目标时刻 t+1 预测单项 KPI 时，输入向量按 KPI 分组排列：每组取 t、t−1、t−2、t−24、t−168 五个位置。字段对应如下；所有输入为训练期 StandardScaler 处理后的数值。

输入分组	第 1 至第 5 个字段（按实际列顺序）
DLPRB	DLPRB_z_t / DLPRB_z_lag1 / DLPRB_z_lag2 / DLPRB_z_lag24 / DLPRB_z_lag168
DLThpVol	DLThpVol_z_t / DLThpVol_z_lag1 / DLThpVol_z_lag2 / DLThpVol_z_lag24 / DLThpVol_z_lag168
DLThpTime	DLThpTime_z_t / DLThpTime_z_lag1 / DLThpTime_z_lag2 / DLThpTime_z_lag24 / DLThpTime_z_lag168
MR_number	MR_number_z_t / MR_number_z_lag1 / MR_number_z_lag2 / MR_number_z_lag24 / MR_number_z_lag168

特征总维数为 4×5＝20。每一行只使用目标时刻以前、同一 beam 的历史值；标签 target_DLPRB、target_DLThpVol、target_DLThpTime、target_MR_number 分别保存 t+1 对应 KPI 的原始值。最长滞后 168 步，使有效特征时间从 168 开始；按 target_time 划分，保证留出测试期的目标时间为 672–839。

3 比较模型与实现

模型	主要实现	本实验角色
Persistence	ŷ(t+1)=y(t)	无参数时序基线
Linear Regression	sklearn.linear_model.LinearRegression	线性模型
Decision Tree	sklearn.tree.DecisionTreeRegressor	单树非线性基线
Random Forest	sklearn.ensemble.RandomForestRegressor	随机森林集成回归
XGBoost	xgboost.XGBRegressor	梯度提升树
LightGBM	lightgbm.LGBMRegressor	叶子优先提升树

本实验采用完整训练配置，随机森林使用 30 棵决策树，XGBoost 与 LightGBM 均设置 250 轮估计，随机种子为 42。各模型采用相同的 20 维输入特征及相同的时间留出测试集，以保证评价条件一致。

4 评估指标和口径

MAE = mean(|y−ŷ|)；RMSE = sqrt(mean((y−ŷ)²))；$R^2 = 1-\Sigma(y-\hat{y})^2/\Sigma(y-\bar{y})^2$。其中 MAE、RMSE 越小越好，$R^2$ 越大越好。报告中的评分基于 483,840 个 beam×目标时刻逐样本值计算；后文可视化的“各时刻 beam 均值”不是用于上述指标评分的样本粒度。

跨 KPI 不直接比较误差绝对值的大小，因为不同 KPI 的物理含义与量纲可能不同。改善率按同一 KPI 的 Persistence 误差作为参照计算。

5 模型性能结果

KPI	Persistence MAE	最小 MAE（模型）	降低比例	最小 RMSE（模型）	最高 R^2
DLPRB	0.298215	0.261817 XGBoost	12.21%	0.493705 RF	0.787133
DLThpVol	0.237776	0.207615 RF	12.68%	0.460162 RF	0.615323
DLThpTime	0.279268	0.243576 XGBoost	12.78%	0.524467 RF	0.702391
MR_number	0.245860	0.224767 XGBoost	8.58%	0.395647 RF	0.867182

随机森林（RF）在四个目标上均取得最小 RMSE 与最高 R^2。XGBoost 在 DLPRB、DLThpTime、MR_number 的 MAE 上略优；DLThpVol 的 MAE 最优模型则为随机森林。说明模型优劣依赖评估指标，不存在一套模型在所有考察维度上都绝对最优的结论。

5.1 完整测试集模型指标

KPI	模型	MAE↓	RMSE↓	R^2↑
DLPRB	Persistence	0.298215	0.567152	0.719086
DLPRB	LinearRegression	0.274974	0.522147	0.761901
DLPRB	DecisionTree	0.282239	0.534094	0.750880
DLPRB	RandomForest	0.262541	0.493705	0.787133
DLPRB	XGBoost	0.261817	0.496777	0.784475
DLPRB	LightGBM	0.262246	0.498070	0.783352
DLThpVol	Persistence	0.237776	0.546478	0.457474
DLThpVol	LinearRegression	0.222735	0.487435	0.568374
DLThpVol	DecisionTree	0.223274	0.514746	0.518651
DLThpVol	RandomForest	0.207615	0.460162	0.615323
DLThpVol	XGBoost	0.208802	0.481722	0.578433
DLThpVol	LightGBM	0.209779	0.488796	0.565961
DLThpTime	Persistence	0.279268	0.606604	0.601875
DLThpTime	LinearRegression	0.253178	0.545464	0.678085
DLThpTime	DecisionTree	0.262772	0.573985	0.643540
DLThpTime	RandomForest	0.244028	0.524467	0.702391
DLThpTime	XGBoost	0.243576	0.530915	0.695028
DLThpTime	LightGBM	0.244187	0.532348	0.693380
MR_number	Persistence	0.245860	0.431494	0.842024
MR_number	LinearRegression	0.258042	0.462582	0.818441
MR_number	DecisionTree	0.242171	0.424696	0.846963
MR_number	RandomForest	0.225858	0.395647	0.867182
MR_number	XGBoost	0.224767	0.396050	0.866912
MR_number	LightGBM	0.225362	0.397979	0.865612

6 模型评价结果可视化

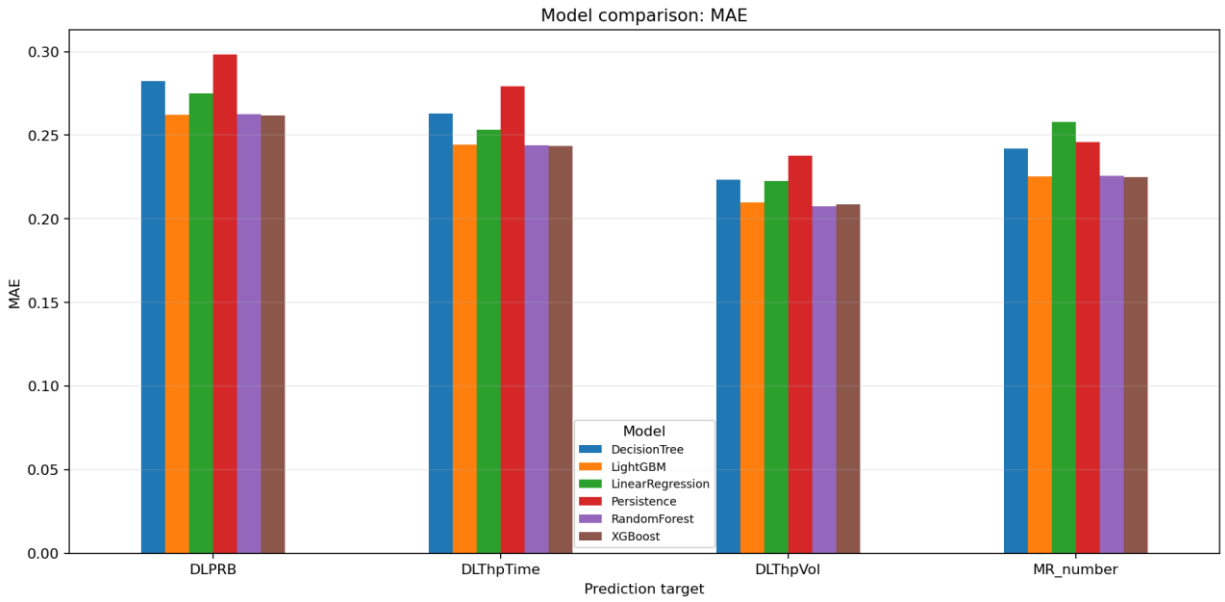


图 1 六种方法在四个 KPI 上的 MAE 比较

图注补充：历史 gotsf-ds 留出目标 Time 672–839，n=483,840 beam-hour；误差使用原 KPI 尺度，均值曲线不替代逐样本评分。 图示结论：历史留出集 XGB 在 DLPRB、DLThpTime、MR_number 的 MAE 较低，DLThpVol 以 RF 最低。

图 1 显示，XGBoost 在 DLPRB、DLThpTime 与 MR_number 上具有略低的 MAE，随机森林在 DLThpVol 上最低。值得注意的是 MR_number 的 Linear Regression MAE（0.258042）反而高于 Persistence（0.245860），不能笼统宣称所有模型都优于基线。

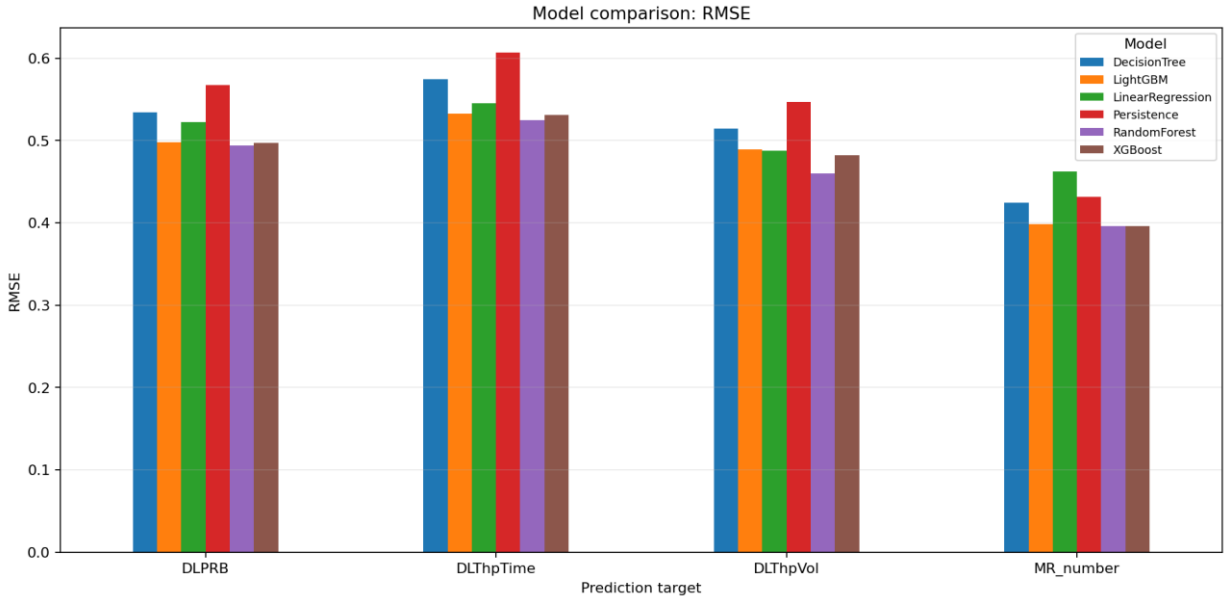


图 2 六种方法在四个 KPI 上的 RMSE 比较

图注补充：历史 gotsf-ds 留出目标 Time 672–839，n=483,840 beam-hour；误差使用原 KPI 尺度，均值曲线不替代逐样本评分。 图示结论：历史留出集 RF 在四项 KPI 的 RMSE 均最低；新协议成绩另见附表。

图 2 显示，随机森林在四种 KPI 的 RMSE 上均为最低。相比 Persistence，各目标的 RMSE 相对降低约 12.95%、15.79%、13.54%与 8.31%。

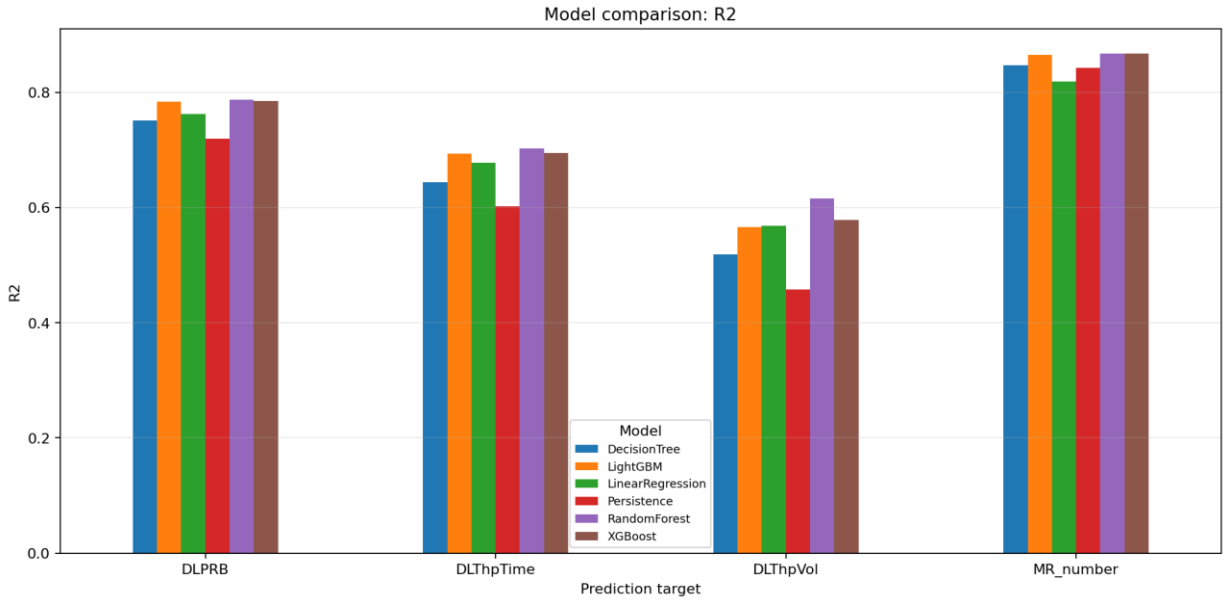


图 3 六种方法在四类 KPI 上的 R^2 比较

图注补充：历史留出 Time 672–839，n=483,840 逐 beam-hour；R^2为无量纲方差解释指标，越高越好，不是原 KPI 单位的误差。

图 3 显示，四个目标的最高 R^2均来自随机森林，分别为 0.787133、0.615323、0.702391、0.867182。MR_number 的基线 R^2已达到 0.842024，提示该目标具有较强的短期持续性。

7 预测时序结果与展示粒度

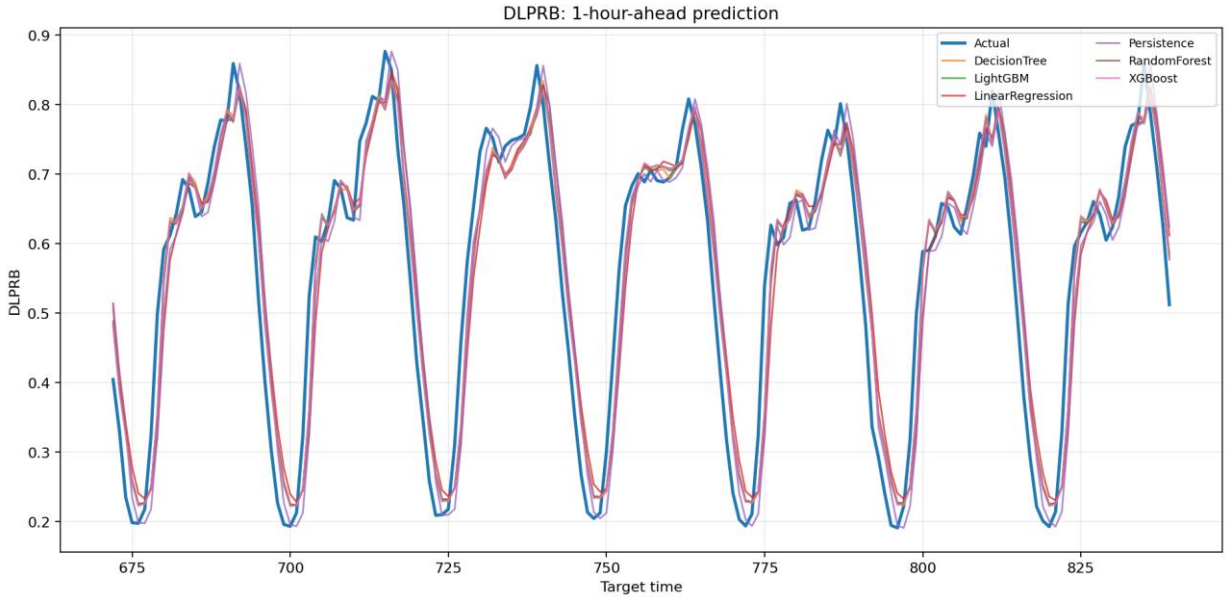


图 4 DLPRB 预测趋势

图注补充：历史 gotsf-ds 留出目标 Time 672–839，n=483,840 beam-hour；误差使用原 KPI 尺度，均值曲线不替代逐样本评分。

由图 4 可见，测试期内可观察到反复出现的低谷与峰值，随机森林与 XGBoost 的均值预测总体跟随了变化方向，但个别时刻仍存在偏差。

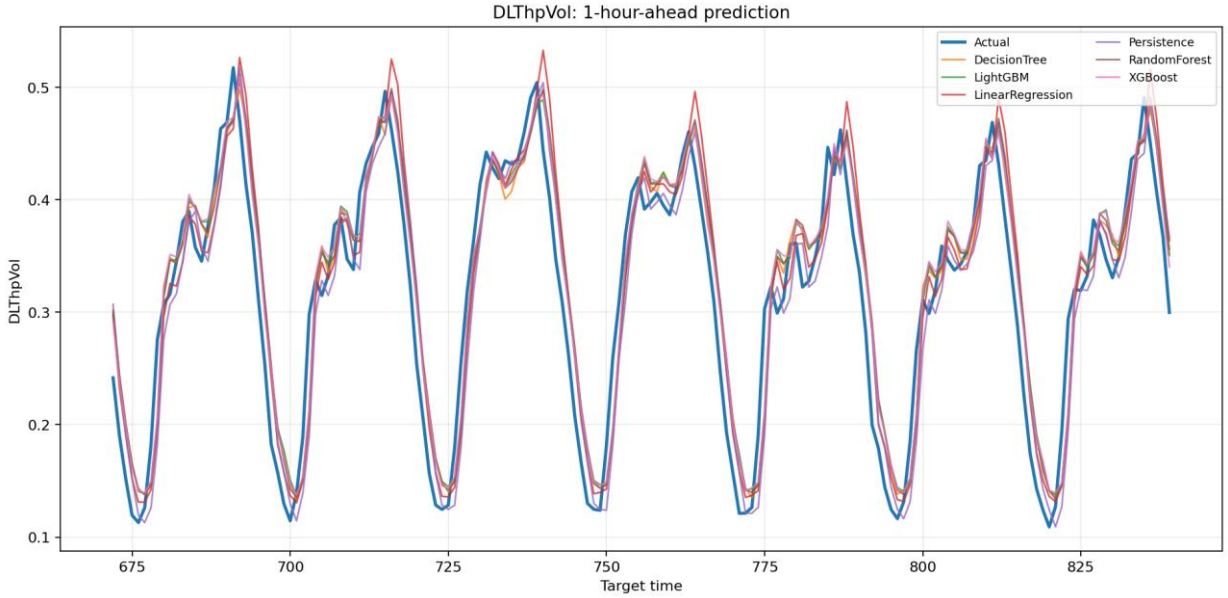


图 5 DLThpVol 预测趋势

图注补充：历史 gotsf-ds 留出目标 Time 672–839，n=483,840 beam-hour；误差使用原 KPI 尺度，均值曲线不替代逐样本评分。

DLThpVol 的各时刻 beam 均值呈明显起伏。不同模型在峰谷处的偏差仍存在，逐样本评估中随机森林的 MAE 与 RMSE 同时优于其他方法。

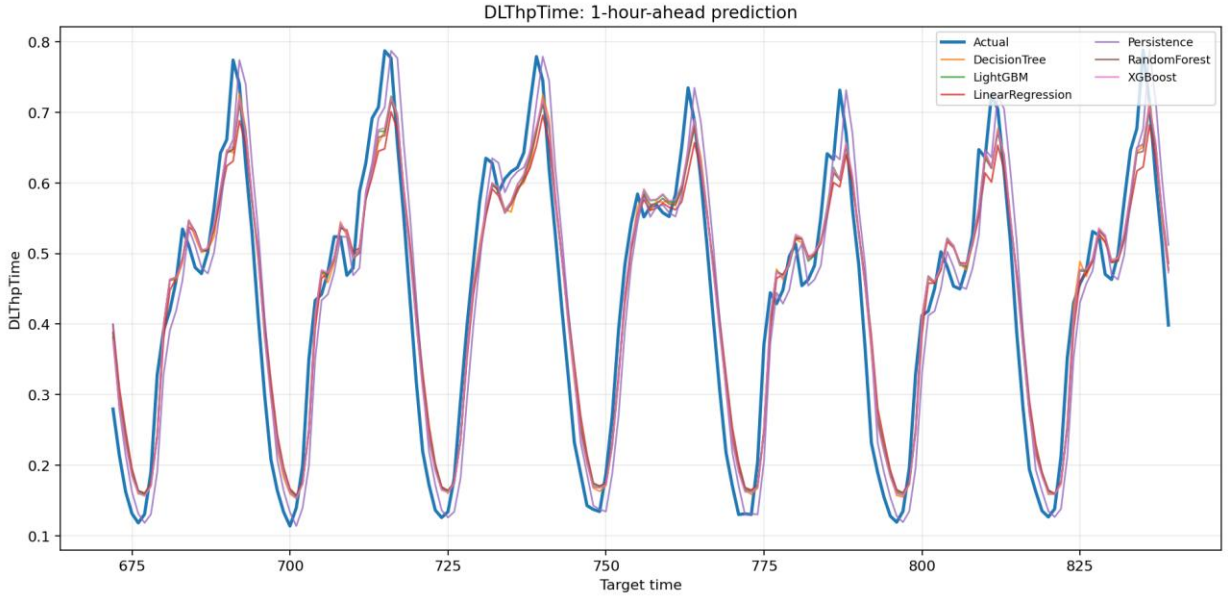


图 6 DLThpTime 预测趋势

图注补充：历史 gotsf-ds 留出目标 Time 672–839，n=483,840 beam-hour；误差使用原 KPI 尺度，均值曲线不替代逐样本评分。

DLThpTime 在低值时刻和高值时刻间交替变化。随机森林在逐样本 RMSE 上领先，XGBoost 在 MAE 上略低，不能仅根据跨 beam 聚合后的均值曲线判定哪一种模型对每个时刻更准确。

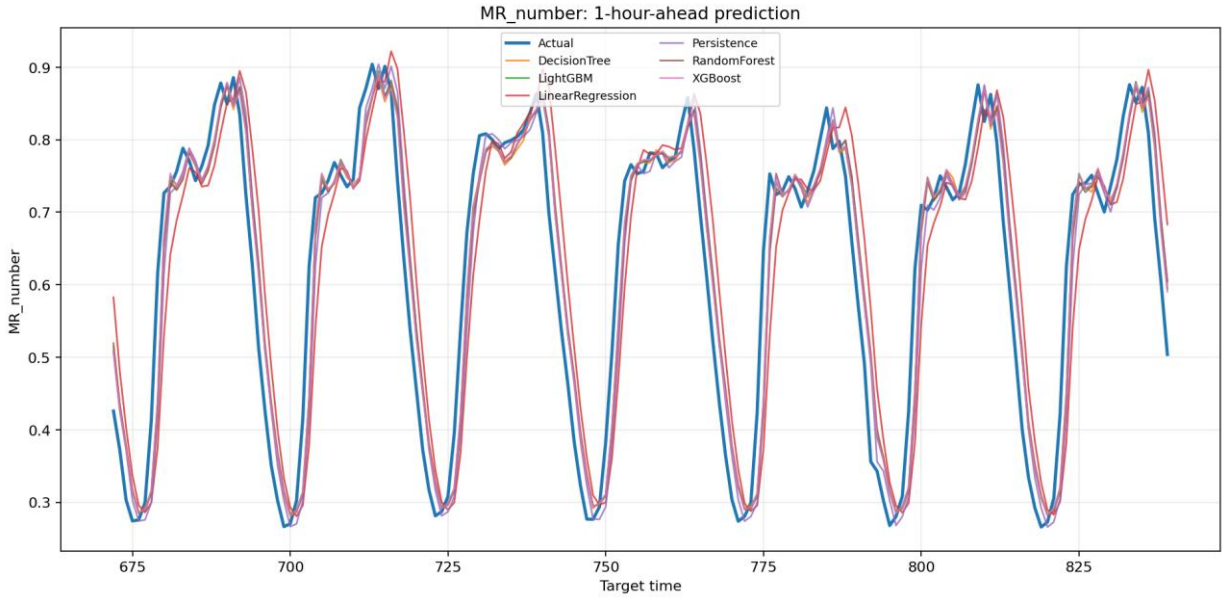


图 7 MR_number 测试期 beam 均值趋势

图注补充：历史 gotsf-ds 留出目标 Time 672–839，n=483,840 beam-hour；误差使用原 KPI 尺度，均值曲线不替代逐样本评分。

MR_number 的 Persistence 基线已具有较高 R^2，表明直接沿用当前值可获得一定预测能力。随机森林与 XGBoost 进一步降低误差，但相对增益小于其他三个 KPI。

8 拟合开销与工程考虑

模型	四 KPI 的拟合耗时范围（s）	说明
Linear Regression	0.43–0.44	线性基线，低拟合开销
Decision Tree	40.06–44.09	单树在本次设置中开销较大
Random Forest	21.15–25.99	RMSE 与 R^2表现最稳
XGBoost	13.07–16.65	在多个 KPI 的 MAE 上领先
LightGBM	3.97–4.78	本次运行记录中训练较快

上述为一次既有运行记录，不代表各算法在所有机器和版本上的速度排名。若后续需要部署，应补充真实硬件环境、内存峰值、端到端延迟以及多次重复计时。

9 综合模型排名与选型依据

为回应“哪一个模型综合发挥最好”的问题，使用 reports/validation/model_comparison_summary.csv 对五种可训练的传统 ML 模型作统一描述性排序。对每个 KPI 分别按 MAE（升序）、RMSE（升序）和 R^2（降序）赋名次；再对四个 KPI 的三项名次等权平均，综合名次越小表示整体排名越靠前。Persistence 仅作为参考基线，不参与这张排名表。

综合名次	模型	MAE 平均名次	RMSE 平均名次	R^2平均名次	综合值
1	Random Forest	2.25	1.00	1.00	1.417
2	XGBoost	1.25	2.00	2.00	1.750

综合名次	模型	MAE 平均名次	RMSE 平均名次	R^2平均名次	综合值
3	LightGBM	2.50	3.25	3.25	3.000
4	Linear Regression	4.25	4.00	4.00	4.083
5	Decision Tree	4.75	4.75	4.75	4.750

在当前固定留出测试段上，随机森林以综合值 1.417 排名第一；其四种 KPI 的 RMSE 与 R^2 均领先，而 XGBoost 在三个 KPI 的 MAE 上占优。综合结论依赖“各 KPI、各指标等权”的排序规则，属于描述性模型选择，不构成部署场景下的唯一最优性证明。

10 时间序列交叉验证与滚动回测

采用三折扩展训练窗口（expanding-window）验证。每折向后推进 96 个目标时间步，训练集只包含验证段以前的观测，且在每折仅利用训练数据重新拟合 StandardScaler，以降低时间泄漏风险。最终独立留出时段 672–839 不参与交叉验证或调参。

折次	训练目标时间	验证目标时间	验证样本数
Fold 1	169–383	384–479	276,480
Fold 2	169–479	480–575	276,480
Fold 3	169–575	576–671	276,480

下表给出 Random Forest 与 XGBoost 在三折验证中的平均 MAE / RMSE（各折标准差）。指标仍按 beam×目标时间逐样本、在原始 KPI 尺度上计算；各折在时间上相邻，不能视为完全独立的总体抽样。

KPI	RF MAE（均值 ±SD）	XGB MAE（均值 ±SD）	RF RMSE（均值 ±SD）	XGB RMSE（均值 ±SD）
DLPRB	0.2662 ± 0.0031	0.2652 ± 0.0029	0.5006 ± 0.0094	0.5020 ± 0.0078
DLThpVol	0.2331 ± 0.0146	0.2345 ± 0.0152	1.0037 ± 0.3413	1.0404 ± 0.3423
DLThpTime	0.2580 ± 0.0119	0.2577 ± 0.0120	0.6642 ± 0.1254	0.6741 ± 0.1216
MR_number	0.2248 ± 0.0016	0.2238 ± 0.0016	0.3883 ± 0.0032	0.3885 ± 0.0045

随机森林在四个目标的平均 RMSE 上均略优于 XGBoost，而 XGBoost 在 DLPRB、DLThpTime、MR_number 的平均 MAE 上较低。DLThpVol 的跨折 RMSE 波动较大（RF 标准差约 0.3413），提示不同时间窗口可能存在分布或高误差样本差异；仅凭一次留出集排名不足以概括全部时间段的表现。

11 预测误差的统计显著性检验

使用测试期 168 个目标时间步的“逐小时 beam 平均绝对误差或平方误差”构造配对损失序列，比较 Random Forest（基准）与 XGBoost、LightGBM 的损失差：d=候选模型损失−Random Forest 损失。采用带宽 24 的 Newey–West HAC 方差估计（Bartlett 权重），计算双侧近似 p 值；在每种候选模型和每种损失类型内部，针对四种 KPI 的比较进行 Holm 校正。正差表示 Random Forest 误差较低，负差表示候选模型误差较低。

KPI	候选模型 / 损失	平均差 d	Holm 校正 p	比较结论（α=0.05）
DLPRB	XGBoost / MAE	−0.000723	5.23×10^{-6}	XGBoost 较低
DLPRB	XGBoost / MSE	+0.003043	0.0235	RF 较低

KPI	候选模型 / 损失	平均差 d	Holm 校正 p	比较结论（α=0.05）
DLThpVol	XGBoost / MAE	+0.001187	1.08×10^{-10}	RF 较低
DLThpTime	XGBoost / MAE	−0.000452	0.0480	XGBoost 较低
MR_number	XGBoost / MAE	−0.001092	1.05×10^{-22}	XGBoost 较低
MR_number	XGBoost / MSE	+0.000319	0.5978	差异未显著
DLPRB	LightGBM / MAE	−0.000295	0.0515	差异未显著

表中列出具有代表性的七组结果，完整 16 组对比见 reports/validation/significance_hac.csv。对于 DLPRB，XGBoost 的 MAE 可显著低于随机森林，但其 MSE 又显著高于随机森林，说明结论对损失函数敏感。HAC 旨在缓解逐小时损失的序列相关问题；相关假设、样本段与多重校正范围均有限，不能据此声称所有数据和模型之间都存在稳定、普遍的显著差异。

12 超参数设置与优化实验

12.1 主实验所用参数

第二阶段主实验并非全模型自动超参数搜索后的结果。代码使用固定的人工指定参数进行统一基准评估（random_state=42，quick_mode=false）；重要参数如下。

模型	主实验关键超参数
Decision Tree	max_depth=18；min_samples_leaf=20
Random Forest	n_estimators=30；max_depth=16；min_samples_leaf=20；max_features=sqrt；max_samples=0.6
XGBoost	n_estimators=250；max_depth=8；learning_rate=0.05；subsample=0.8；colsample_bytree=0.8
LightGBM	n_estimators=250；num_leaves=63；learning_rate=0.05；subsample=0.8；colsample_bytree=0.8；min_child_samples=20

Linear Regression 使用 scikit-learn 的常规线性回归配置；Persistence 无需训练参数。上述设置是原有主实验使用的固定配置，不能表述为所有模型已系统调优。

12.2 已完成的 Optuna TPE 搜索

后续补充实验针对 DLPRB 的 Random Forest 使用 Optuna 的 TPE 采样器，以三折扩展窗口平均 RMSE 为最小化目标，随机抽取 256 个 beam 的完整历史，执行 12 次搜索；调参过程未使用最终留出测试段。

项目	实验记录
已搜索参数	n_estimators / max_depth / min_samples_leaf / max_features / max_samples
最佳参数	137 / 13 / 9 / sqrt / 0.698071
最佳三折平均 RMSE	0.473700（256 个 beam 的调参样本）
记录文件	reports/validation/tune_DLPRB_RandomForest_best.json 和 _trials.csv

该 0.473700 来自抽样 beam 的交叉验证，不是调优模型在最终留出集的测试 RMSE，不能直接与主实验全量测试 RMSE=0.493705 作公平优劣比较。仓库当前没有显示把上述最佳参数替换原随机森林并

重新执行完整留出测试的结果；XGBoost 和 LightGBM 虽在补充脚本中预留调参能力，也没有相应已完成的 Optuna 搜索记录。

13 实验边界与修订结论

原报告所述“缺少滚动回测和显著性检验”现已通过补充实验部分弥补：完成了训练期内三折扩展窗口验证，并在最终留出段对 RF 与 XGBoost、LightGBM 的逐小时配对损失进行了 HAC 检验与 Holm 校正。仍未完成独立外部数据集测试、多随机种子稳定性实验，以及将调优最优参数在全量留出段上的统一复评；样本内 beam 和时间相关性也限制了结果推广。

综上，本阶段构建了明确的 20 维历史 KPI 输入、四类 t+1 预测标签，完成五种拟合模型及 Persistence 基线的 24 组评估、综合描述性排序和补充稳健性分析。按等权综合名次，Random Forest 为当前传统 ML 的首选基线（综合值 1.417），在四种 KPI 的 RMSE 和 R^2 上领先；如以 MAE 优先，XGBoost 在三个 KPI 上略优。单独的 Optuna 搜索应视作补充实验，不得混同为主实验自动调参结果。结论适用于 3 现有公开数据及时序划分，不直接代表生产网络部署表现。

2026 年 10 月 25 日算法验证与导师反馈补充

本节为本次实际执行的补充验证。前文原留出成绩保留为历史实验，本节新成绩使用独立目录归档，不替换旧权重或旧图表。Web 入口、页面、交互与后台集成源码保持不变。

统一比较协议与时序回测

RF、XGBoost 和 GRU 使用完全相同的 60,000 条训练标签及目标时段；ML 输入 20 维，GRU 输入 24×4 连续历史与 4 维季节向量。统一训练样本量并不等于统一计算预算，GRU 有内部验证早停，树模型沿用固定参数。三个外层评估窗为 384–479、480–575、576–671；内部早停窗分别为 336–383、432–479、528–575，训练目标从 169 开始至内部验证前一小时。全部 2,880 beam 参与每个外层评估，各 276,480 条。

留出评估为 672–839，共 483,840 条；训练目标 169–587，内部验证 588–671。每个模型的缩放器只用内部验证起点之前的 raw 观测拟合；已通过改变所有未来值而训练缩放参数不变的回归测试。固定 seed42 执行三折与留出，seed43 仅重复留出；两种模型种子使用相同训练抽样（抽样 seed42）。这是有限的初始化稳定性证据。

表 A1 新实验留出集结果 seed42 原始 KPI 尺度

KPI	模型	MAE	RMSE	R^2
DLPRB	RandomForest	0.266552	0.513284	0.769915
DLThpVol	RandomForest	0.212908	0.478479	0.584089
DLThpTime	RandomForest	0.247807	0.540264	0.684194
MR_number	RandomForest	0.231022	0.413987	0.854584
DLPRB	XGBoost	0.268472	0.518092	0.765584
DLThpVol	XGBoost	0.220221	0.559090	0.432144
DLThpTime	XGBoost	0.251333	0.581392	0.634282
MR_number	XGBoost	0.231131	0.416529	0.852792
DLPRB	GRU	0.247765	0.476520	0.801694
DLThpVol	GRU	0.211055	0.498167	0.549158
DLThpTime	GRU	0.236438	0.519272	0.708258
MR_number	GRU	0.207566	0.366875	0.885797

GRU 在 seed42 的四项 MAE 均最低；DLThpVol 仍由 RF 取得较低 RMSE 和较高 R^2。GRU 适合作为 MAE 优先推荐，DLThpVol 在关注大误差时保留 RF。本结论针对本数据、配置和损失权重。历史传统综合排名 1.417 来自 MAE/RMSE/R^2名次等权，其中 RMSE 与 R^2同序，不能视为三个独立证据。

表 A2 新三折扩展窗口结果 seed42 均值及折间标准差

KPI	模型	MAE 均值±SD	RMSE 均值±SD
DLPRB	GRU	0.2553 ± 0.0061	0.4756 ± 0.0077
DLThpTime	GRU	0.2515 ± 0.0084	0.6752 ± 0.1417
DLThpVol	GRU	0.2287 ± 0.0127	1.0353 ± 0.3805
MR_number	GRU	0.2121 ± 0.0028	0.3562 ± 0.0065
DLPRB	RandomForest	0.2695 ± 0.0029	0.5161 ± 0.0107
DLThpTime	RandomForest	0.2628 ± 0.0125	0.7271 ± 0.1729
DLThpVol	RandomForest	0.2381 ± 0.0152	1.0875 ± 0.3967
MR_number	RandomForest	0.2294 ± 0.0016	0.4069 ± 0.0029

KPI	模型	MAE 均值±SD	RMSE 均值±SD
DLPRB	XGBoost	0.2715 ± 0.0034	0.5237 ± 0.0112
DLThpTime	XGBoost	0.2659 ± 0.0125	0.7259 ± 0.1452
DLThpVol	XGBoost	0.2440 ± 0.0137	1.1110 ± 0.3230
MR_number	XGBoost	0.2291 ± 0.0021	0.4097 ± 0.0054

三折均值中 GRU 的四项 MAE/RMSE 均低于本轮 RF/XGB，但 DLThpVol 跨折 RMSE 波动较大，不能用一次留出结果概括所有时段。旧全量传统回测中 DLThpVol 的线性回归 RMSE=0.967665 低于 RF=1.003675；该旧实验的训练预算不同，应独立解释。LSTM 与 Transformer 本次没有新增三折或种子实验。

跨类别配对显著性与随机种子

在相同 beam 和目标小时上，先计算逐记录绝对/平方误差，再按小时平均，形成 168 个配对损失。d 为候选损失减参考损失，负值有利于候选。使用 Newey–West HAC 带宽 24、双侧近似检验；每个场景和 seed 的 3 对模型×4KPI×2 损失共 24 项一起 Holm 校正。95%区间为逐项 HAC 区间，未作同时区间校正。未为获得显著结果修改参数。

表 A3 GRU 对 RF 的留出配对损失检验 seed42

KPI 及损失	平均差 d	95% CI	Holm p
DLPRB mae	-0.018787	[-0.020485, -0.017089]	7.46e-103
DLPRB mse	-0.036389	[-0.040054, -0.032723]	5.21e-83
DLThpVol mae	-0.001853	[-0.004178, 0.000471]	0.354
DLThpVol mse	0.019228	[-0.006343, 0.044798]	0.354
DLThpTime mae	-0.011369	[-0.013218, -0.009520]	2.68e-32
DLThpTime mse	-0.022241	[-0.027565, -0.016918]	2.64e-15
MR_number mae	-0.023456	[-0.025629, -0.021282]	5.82e-98
MR_number mse	-0.036788	[-0.041060, -0.032516]	1.23e-62

DLThpVol 在 seed42 上的 GRU 对 RF，MAE 差−0.001853、MSE 差+0.019228，两者 Holm p 均约 0.354，不能判定差异显著。DLPRB、DLThpTime、MR_number 的 GRU 对 RF 两类损失在该协议下均有显著改善。其余模型配对与 seed43 的完整效应、区间和 p 值见 holdout_significance.csv，不将未显著解释为模型完全等效。

表 A4 两组模型种子的留出误差 seed42 及 43

KPI	模型	MAE 42 / 43	RMSE 42 / 43
DLPRB	GRU	0.2478 / 0.2473	0.4765 / 0.4773
DLThpVol	GRU	0.2111 / 0.2097	0.4982 / 0.5001
DLThpTime	GRU	0.2364 / 0.2277	0.5193 / 0.5122
MR_number	GRU	0.2076 / 0.2080	0.3669 / 0.3697
DLPRB	RandomForest	0.2666 / 0.2663	0.5133 / 0.5115
DLThpVol	RandomForest	0.2129 / 0.2130	0.4785 / 0.4779
DLThpTime	RandomForest	0.2478 / 0.2478	0.5403 / 0.5408
MR_number	RandomForest	0.2310 / 0.2312	0.4140 / 0.4148
DLPRB	XGBoost	0.2685 / 0.2684	0.5181 / 0.5185
DLThpVol	XGBoost	0.2202 / 0.2201	0.5591 / 0.5561

KPI	模型	MAE 42 / 43	RMSE 42 / 43
DLThpTime	XGBoost	0.2513 / 0.2515	0.5814 / 0.5877
MR_number	XGBoost	0.2311 / 0.2310	0.4165 / 0.4158

seed43 保留了 GRU 四项 MAE 较低、RF 的 DLThpVol RMSE 较低的观察；两组种子不构成独立时间样本，不能把它们当作大样本稳定性证明。测试期已在历史选型中反复使用，本次属于固定协议复核，并非独立外部验证。

20 维输入与超参数来源

KPI	五个输入字段
DLPRB	DLPRB_z_t / DLPRB_z_lag1 / DLPRB_z_lag2 / DLPRB_z_lag24 / DLPRB_z_lag168
DLThpVol	DLThpVol_z_t / DLThpVol_z_lag1 / DLThpVol_z_lag2 / DLThpVol_z_lag24 / DLThpVol_z_lag168
DLThpTime	DLThpTime_z_t / DLThpTime_z_lag1 / DLThpTime_z_lag2 / DLThpTime_z_lag24 / DLThpTime_z_lag168
MR_number	MR_number_z_t / MR_number_z_lag1 / MR_number_z_lag2 / MR_number_z_lag24 / MR_number_z_lag168

每组按当前 t、滞后 1、2、24、168 小时排序。z 为训练期 StandardScaler 无量纲值，监督目标为 t+1 原始 KPI 尺度。Time 和 base_station/cell/beam 用于时间与身份对齐，不是额外输入维度。原数据未提供可据以换算的物理量纲，本报告保留数据集数值尺度，不擅写 Mbps、百分比等单位。最长滞后要求 169 个连续整小时；训练与推理列顺序的合成测试已通过。

主表传统 ML 及三种 DL 均使用固定人工设置；DL 的 Adam 与早停属于权重优化及轮次选择，不等于自动超参数搜索。只有 DLPRB 的 RF 已有 Optuna TPE 12 次、256 beam、三折平均 RMSE 搜索；范围为树数 40–160、深度 8–24、最小叶样本 5–50、max_features∈{sqrt,0.7,1.0}、max_samples 0.5–0.9。最佳 137/13/9/sqrt/0.698071 及 CV RMSE=0.473700 没有替换本次固定 30 树 RF；未补造调优后的全量测试成绩。逐模型参数及定义/引用见参数登记簿。

代码修复与最新验收

修复仅涉及底层小时数据契约、DL 输出预检和 scaler 测试提取。训练加载器与推理拒绝共同缺小时、重复或非整数小时；保留 ML 20 维、DL 窗口、逆标准化和 IF AND (3σ OR IQR)定义。DL 当前代码已仅在内部训练前缀拟合 scaler；本次锁定该行为，没有把历史成绩改写为新成绩。

本次既有自动化基线 48 项通过；新增算法及统计回归后最新完整测试 57 项通过（final_tests.txt）。六个 Streamlit 页面 AppTest 加载及切换均无异常，实际新模型回载及 CSV 导出通过，原异常模型 5,760 条检测通过。另用 1 轮、512 条样本执行现有 DL CLI 仅作功能验收，不把其分数纳入模型比较。Web 页面及服务源码哈希保持不变。本次未以真人浏览器重走每个上传/下载控件或实时 WebSocket 训练全流程，不能将自动验收冒充完整手工验收。

证据根目录：reports/final_audit_20261025。新实验配置 protocol.json、逐次 runs.json、60 组 metrics.csv、hourly_losses.csv、48 组 holdout_significance.csv；实际权重及逐 beam-hour 配对预测位于 resources/final_audit_20261025（Git 忽略，需本机备份）。历史 reports/和 figures/数值保持原样。没有独立外部数据、全模型调参或生产实时网管接入，本次不扩大该范围。