2026 年 10 月 25 日核验修订版 前文历史成绩保留 新实验及最新状态见末节补充验证

基于 AI 的 5G 网络关键性能指标预测与异常检测系统

传统 ML 与 DL 模型对比分析

传统机器学习基线与 LSTM、GRU、Transformer 的统一测试对比

数据集：gotsf-ds / 4 类 beam-level KPI
对比模型：Persistence、LR、DT、RF、XGBoost、LightGBM / LSTM、GRU、Transformer
评价指标：MAE / RMSE / R^2

1. 分析目的与评价方法

本分析将第二阶段的传统机器学习结果作为基线，与第三阶段 LSTM、GRU、Transformer 的下一小时 KPI 预测结果作并列对比。比较在同一留出测试时段 Time 672–839、同样的 2880 beam 和原始 KPI 数值尺度下开展，关注误差、解释能力与不同模型之间的性能取舍。

比较维度	传统 ML	深度学习
模型	Persistence、LR、DT、RF、XGBoost、LightGBM	LSTM、GRU、Transformer
输入特征	四种 KPI × （t,t−1,t−2,t−24,t−168）	24 小时连续序列 + t−168 特征
训练样本	1,448,640 行	抽样 60,000 窗口；另有验证 12,000
测试时段与规模	672–839；483,840 条	672–839；483,840 条
指标	MAE、RMSE、R^2	MAE、RMSE、R^2

报告中的“ML 最优”和“DL 最优”分别在各自模型组内、按每种 KPI 的对应指标选取。不同 KPI 的绝对误差不直接求和排序，误差改善率按（ML 最优误差−DL 最优误差）/ ML 最优误差计算；R^2 比较采用差值。

2. 最优模型对比结果

KPI	指标	ML 最优	DL 最优	DL 相对变化
DLPRB	MAE	XGBoost 0.2618	GRU 0.2456	+6.19%
DLPRB	RMSE	RandomForest 0.4937	GRU 0.4689	+5.03%
DLPRB	R^2	RandomForest 0.7871	GRU 0.8080	+0.0209
DLThpVol	MAE	RandomForest 0.2076	GRU 0.2046	+1.46%
DLThpVol	RMSE	RandomForest 0.4602	LSTM 0.4844	-5.26%
DLThpVol	R^2	RandomForest 0.6153	LSTM 0.5738	-0.0416
DLThpTime	MAE	XGBoost 0.2436	GRU 0.2298	+5.66%
DLThpTime	RMSE	RandomForest 0.5245	GRU 0.5134	+2.12%
DLThpTime	R^2	RandomForest 0.7024	GRU 0.7149	+0.0125
MR_number	MAE	XGBoost 0.2248	GRU 0.2097	+6.71%

KPI	指标	ML 最优	DL 最优	DL 相对变化
MR_number	RMSE	RandomForest 0.3956	GRU 0.3669	+7.27%
MR_number	R^2	RandomForest 0.8672	GRU 0.8858	+0.0186

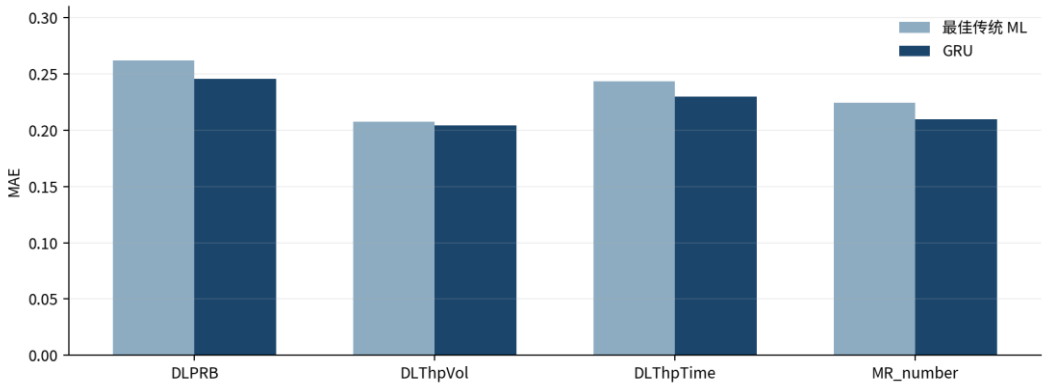


图 1 四类 KPI 的最佳传统 ML 与 GRU 测试 MAE 比较

图注补充：历史 gotsf-ds 留出目标 Time 672–839，n=483,840 beam-hour；误差使用原 KPI 尺度，均值曲线不替代逐样本评分。

3. 性能差异与结果解释

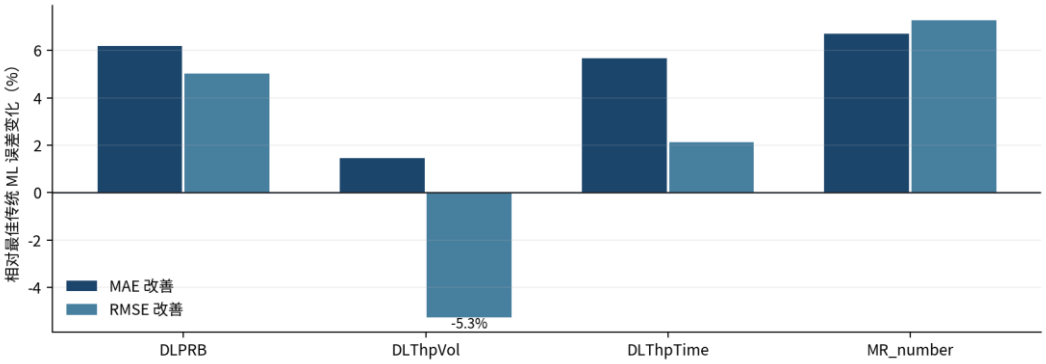


图 2 深度学习最佳误差相对传统 ML 最佳误差的变化（负值表示退步）

图注补充：同一 483,840 条历史留出记录，纵轴为相对误差降低百分比；正值改善，负值退步，分母为相应 KPI 及指标的传统 ML 最佳误差。

在四类 KPI 的 MAE 指标上，GRU 均优于传统机器学习组内最佳模型：DLPRB 改善 6.19%，DLThpVol 改善 1.46%，DLThpTime 改善 5.66%，MR_number 改善 6.71%。对于 DLPRB、DLThpTime 与 MR_number，GRU 的 RMSE 亦较传统 ML 最优结果有所降低，R^2 同时增加。

DLThpVol 则展示了相反证据：深度学习组内 RMSE 最好的 LSTM 为 0.4844，仍高于 RandomForest 的 0.4602，意味着其最优深度学习 RMSE 相比传统 ML 增加约 5.26%；对应 R^2 由 0.6153 降至 0.5738。不能仅根据四项 MAE 改善便称深度学习全面优于传统方法。

4. 模型选择的工程考虑

评价角度	当前证据	实际含义
优先降低典型绝对误差	GRU 的四种 KPI MAE 均为最低	可作为后续预测模块的优先候选
关注大误差及流量尖峰	DLThpVol 的 RF RMSE 优于所有 DL 模型	需保留传统 ML 作为强基线
训练复杂度	DL 本轮在 CPU 上训练；未做等算力计时比较	不能推定部署性能或训练成本优劣
模型稳定性	传统 ML 有历史滚动验证；DL 尚未同协议回测	当前只支持单次留出期结论

5. 可比性限制与进一步验证

虽然预测目标、测试时间与评价尺度相同，但传统 ML 使用约 144.86 万条训练样本及手工滞后特征，深度学习仅抽样训练 6 万个序列窗口、使用额外 24 小时连续历史输入，并通过内部验证早停。二者并非“相同训练数据与计算预算”的受控对比。当前结果仅说明现有实现及配置在该留出集上的实际表现。

建议在进一步实验中统一训练数据覆盖范围、固定多组随机种子，按目标时间滚动回测，并增加每时段误差分析、极端误差分位数和模型推理开销。对于 DLThpVol 尤其应区分一般时段和高变化时段的误差贡献。

6. 传统机器学习基线的综合排序与稳健性证据

第二阶段已经在同一留出测试集上按每个 KPI 分别计算 MAE、RMSE 与 R^2；先对传统学习模型在各 KPI、各指标内排名，再对 12 个名次等权平均，得到下表。此排名为描述性综合名次，并非统计检验，也不直接对不同 KPI 的误差绝对值求平均。

综合排名	传统 ML 模型	MAE 均名次	RMSE 均名次	R^2均名次	等权综合
1	Random Forest	2.25	1.00	1.00	1.417
2	XGBoost	1.25	2.00	2.00	1.750
3	LightGBM	2.50	3.25	3.25	3.000
4	Linear Regression	4.25	4.00	4.00	4.083
5	Decision Tree	4.75	4.75	4.75	4.750

因此，在既定等权评价标准下，Random Forest 是传统 ML 的综合最优基线；XGBoost 在 MAE 维度有相对优势。该结论仅适用于已记录的模型配置和测试期。

6.1 三折扩展窗口交叉验证（滚动起点回测）

折次	模型训练目标时刻	验证目标时刻	验证窗口
Fold 1	169–383	384–479	96 小时
Fold 2	169–479	480–575	96 小时
Fold 3	169–575	576–671	96 小时

历史阶段状态：每折只使用验证窗口之前的数据拟合模型，并在该折训练样本上重新拟合 StandardScaler。最终测试段 672–839 未参与三折验证；交叉验证和滚动回测在此指同一套扩展窗口时序实验。仓库已有 24 组模型×KPI 的三折均值和标准差（validation/walkforward_summary.csv），未对深度学习模型执行同样的三折回测。 2026 年 10 月 25 日已增加 GRU 三折及 RF/XGB/GRU 跨类配对检验，详见本报告末尾补充验证；独立外部测试仍未完成。

6.2 显著性检验的适用范围

传统模型内部已对 Random Forest、XGBoost 和 LightGBM 的每小时平均绝对/平方损失进行配对 Newey–West HAC 检验（带宽 24），再以 Holm 方法校正多重比较。例如在 DLPRB 上，XGBoost 的 MAE 相对 RF 更低（Holm $p \approx 5.23\times10^{-6}$），而 RF 的平方损失更小（Holm $p \approx 0.0235$）。这些结论反映误差目标不同会改变优劣关系。

历史阶段状态：上述显著性检验仅覆盖传统模型之间的比较；目前并无“GRU 相对 Random Forest / XGBoost 的显著性”分析。因此，深度学习取得的测试集 MAE 改善应表述为描述性效果，不应写成已通过显著性检验。 2026 年 10 月 25 日已增加 GRU 三折及 RF/XGB/GRU 跨类配对检验，详见本报告末尾补充验证；独立外部测试仍未完成。

6.3 超参数优化记录及比较限制

当前传统 ML 主表使用固定候选参数；后续单独对 DLPRB 的 Random Forest 运行过 Optuna TPE 12 次试验、抽样 256 个 beam，在三折验证上筛选出 n_estimators=137、max_depth=13、min_samples_leaf=9、max_features=sqrt、max_samples≈0.6981，最佳交叉验证 RMSE≈0.473700。该最佳参数尚未替换原主实验模型，也不能将此搜索记录扩展表述为全部传统模型均已自动调参。

考虑到深度学习仅使用 60,000 个随机训练窗口，而传统模型使用 1,448,640 条训练行，且二者特征表示与模型容量不同，建议第四阶段保留两套可切换后端，并在统一训练预算、多种种子和更严格预处理折内拟合的条件下再次比较。

7. 结论与可复现材料

基于留出测试集，GRU 是目前四种 KPI 的 MAE 最优模型，但随机森林在 DLThpVol 的 RMSE、R^2 上更好。因而当前更合理的系统设计是保留可切换的预测后端，以 GRU 作为首选候选，同时维护 RF / XGBoost 基线用于稳健性验证。

2026 年 10 月 25 日算法验证与导师反馈补充

本节为本次实际执行的补充验证。前文原留出成绩保留为历史实验，本节新成绩使用独立目录归档，不替换旧权重或旧图表。Web 入口、页面、交互与后台集成源码保持不变。

统一比较协议与时序回测

RF、XGBoost 和 GRU 使用完全相同的 60,000 条训练标签及目标时段；ML 输入 20 维，GRU 输入 24×4 连续历史与 4 维季节向量。统一训练样本量并不等于统一计算预算，GRU 有内部验证早停，树模型沿用固定参数。三个外层评估窗为 384–479、480–575、576–671；内部早停窗分别为 336–383、432–479、528–575，训练目标从 169 开始至内部验证前一小时。全部 2,880 beam 参与每个外层评估，各 276,480 条。

留出评估为 672–839，共 483,840 条；训练目标 169–587，内部验证 588–671。每个模型的缩放器只用内部验证起点之前的 raw 观测拟合；已通过改变所有未来值而训练缩放参数不变的回归测试。固定 seed42 执行三折与留出，seed43 仅重复留出；两种模型种子使用相同训练抽样（抽样 seed42）。这是有限的初始化稳定性证据。

表 A1 新实验留出集结果 seed42 原始 KPI 尺度

KPI	模型	MAE	RMSE	R^2
DLPRB	RandomForest	0.266552	0.513284	0.769915
DLThpVol	RandomForest	0.212908	0.478479	0.584089
DLThpTime	RandomForest	0.247807	0.540264	0.684194
MR_number	RandomForest	0.231022	0.413987	0.854584
DLPRB	XGBoost	0.268472	0.518092	0.765584
DLThpVol	XGBoost	0.220221	0.559090	0.432144
DLThpTime	XGBoost	0.251333	0.581392	0.634282
MR_number	XGBoost	0.231131	0.416529	0.852792
DLPRB	GRU	0.247765	0.476520	0.801694
DLThpVol	GRU	0.211055	0.498167	0.549158
DLThpTime	GRU	0.236438	0.519272	0.708258
MR_number	GRU	0.207566	0.366875	0.885797

GRU 在 seed42 的四项 MAE 均最低；DLThpVol 仍由 RF 取得较低 RMSE 和较高 R^2。GRU 适合作为 MAE 优先推荐，DLThpVol 在关注大误差时保留 RF。本结论针对本数据、配置和损失权重。历史传统综合排名 1.417 来自 MAE/RMSE/R^2名次等权，其中 RMSE 与 R^2同序，不能视为三个独立证据。

表 A2 新三折扩展窗口结果 seed42 均值及折间标准差

KPI	模型	MAE 均值±SD	RMSE 均值±SD
DLPRB	GRU	0.2553 ± 0.0061	0.4756 ± 0.0077
DLThpTime	GRU	0.2515 ± 0.0084	0.6752 ± 0.1417
DLThpVol	GRU	0.2287 ± 0.0127	1.0353 ± 0.3805
MR_number	GRU	0.2121 ± 0.0028	0.3562 ± 0.0065
DLPRB	RandomForest	0.2695 ± 0.0029	0.5161 ± 0.0107
DLThpTime	RandomForest	0.2628 ± 0.0125	0.7271 ± 0.1729
DLThpVol	RandomForest	0.2381 ± 0.0152	1.0875 ± 0.3967
MR_number	RandomForest	0.2294 ± 0.0016	0.4069 ± 0.0029

KPI	模型	MAE 均值±SD	RMSE 均值±SD
DLPRB	XGBoost	0.2715 ± 0.0034	0.5237 ± 0.0112
DLThpTime	XGBoost	0.2659 ± 0.0125	0.7259 ± 0.1452
DLThpVol	XGBoost	0.2440 ± 0.0137	1.1110 ± 0.3230
MR_number	XGBoost	0.2291 ± 0.0021	0.4097 ± 0.0054

三折均值中 GRU 的四项 MAE/RMSE 均低于本轮 RF/XGB，但 DLThpVol 跨折 RMSE 波动较大，不能用一次留出结果概括所有时段。旧全量传统回测中 DLThpVol 的线性回归 RMSE=0.967665 低于 RF=1.003675；该旧实验的训练预算不同，应独立解释。LSTM 与 Transformer 本次没有新增三折或种子实验。

跨类别配对显著性与随机种子

在相同 beam 和目标小时上，先计算逐记录绝对/平方误差，再按小时平均，形成 168 个配对损失。d 为候选损失减参考损失，负值有利于候选。使用 Newey–West HAC 带宽 24、双侧近似检验；每个场景和 seed 的 3 对模型×4KPI×2 损失共 24 项一起 Holm 校正。95%区间为逐项 HAC 区间，未作同时区间校正。未为获得显著结果修改参数。

表 A3 GRU 对 RF 的留出配对损失检验 seed42

KPI 及损失	平均差 d	95% CI	Holm p
DLPRB mae	-0.018787	[-0.020485, -0.017089]	7.46e-103
DLPRB mse	-0.036389	[-0.040054, -0.032723]	5.21e-83
DLThpVol mae	-0.001853	[-0.004178, 0.000471]	0.354
DLThpVol mse	0.019228	[-0.006343, 0.044798]	0.354
DLThpTime mae	-0.011369	[-0.013218, -0.009520]	2.68e-32
DLThpTime mse	-0.022241	[-0.027565, -0.016918]	2.64e-15
MR_number mae	-0.023456	[-0.025629, -0.021282]	5.82e-98
MR_number mse	-0.036788	[-0.041060, -0.032516]	1.23e-62

DLThpVol 在 seed42 上的 GRU 对 RF，MAE 差−0.001853、MSE 差+0.019228，两者 Holm p 均约 0.354，不能判定差异显著。DLPRB、DLThpTime、MR_number 的 GRU 对 RF 两类损失在该协议下均有显著改善。其余模型配对与 seed43 的完整效应、区间和 p 值见 holdout_significance.csv，不将未显著解释为模型完全等效。

表 A4 两组模型种子的留出误差 seed42 及 43

KPI	模型	MAE 42 / 43	RMSE 42 / 43
DLPRB	GRU	0.2478 / 0.2473	0.4765 / 0.4773
DLThpVol	GRU	0.2111 / 0.2097	0.4982 / 0.5001
DLThpTime	GRU	0.2364 / 0.2277	0.5193 / 0.5122
MR_number	GRU	0.2076 / 0.2080	0.3669 / 0.3697
DLPRB	RandomForest	0.2666 / 0.2663	0.5133 / 0.5115
DLThpVol	RandomForest	0.2129 / 0.2130	0.4785 / 0.4779
DLThpTime	RandomForest	0.2478 / 0.2478	0.5403 / 0.5408
MR_number	RandomForest	0.2310 / 0.2312	0.4140 / 0.4148
DLPRB	XGBoost	0.2685 / 0.2684	0.5181 / 0.5185
DLThpVol	XGBoost	0.2202 / 0.2201	0.5591 / 0.5561

KPI	模型	MAE 42 / 43	RMSE 42 / 43
DLThpTime	XGBoost	0.2513 / 0.2515	0.5814 / 0.5877
MR_number	XGBoost	0.2311 / 0.2310	0.4165 / 0.4158

seed43 保留了 GRU 四项 MAE 较低、RF 的 DLThpVol RMSE 较低的观察；两组种子不构成独立时间样本，不能把它们当作大样本稳定性证明。测试期已在历史选型中反复使用，本次属于固定协议复核，并非独立外部验证。

代码修复与最新验收

修复仅涉及底层小时数据契约、DL 输出预检和 scaler 测试提取。训练加载器与推理拒绝共同缺小时、重复或非整数小时；保留 ML 20 维、DL 窗口、逆标准化和 IF AND (3σ OR IQR)定义。DL 当前代码已仅在内部训练前缀拟合 scaler；本次锁定该行为，没有把历史成绩改写为新成绩。

本次既有自动化基线 48 项通过；新增算法及统计回归后最新完整测试 57 项通过（final_tests.txt）。六个 Streamlit 页面 AppTest 加载及切换均无异常，实际新模型回载及 CSV 导出通过，原异常模型 5,760 条检测通过。另用 1 轮、512 条样本执行现有 DL CLI 仅作功能验收，不把其分数纳入模型比较。Web 页面及服务源码哈希保持不变。本次未以真人浏览器重走每个上传/下载控件或实时 WebSocket 训练全流程，不能将自动验收冒充完整手工验收。

证据根目录：reports/final_audit_20261025。新实验配置 protocol.json、逐次 runs.json、60 组 metrics.csv、hourly_losses.csv、48 组 holdout_significance.csv；实际权重及逐 beam-hour 配对预测位于 resources/final_audit_20261025（Git 忽略，需本机备份）。历史 reports/和 figures/数值保持原样。没有独立外部数据、全模型调参或生产实时网管接入，本次不扩大该范围。