2026 年 10 月 25 日核验修订版 前文历史成绩保留 新实验及最新状态见末节补充验证

基于 AI 的 5G 网络关键性能指标预测与异常检测系统

第三周实验报告

深度学习 KPI 预测与 5G 网络异常检测

深度学习 / 模型比较 / 异常检测与 KPI 联动
实验依据：代码、实验配置与真实运行记录

1. 本周任务和进展

本周按照压缩后的四周项目计划，完成原计划第 5 周的深度学习 KPI 预测，以及原第 6 周的网络异常检测任务。在第二阶段已构建的 beam-level 时间序列上，训练 LSTM、GRU 和 Transformer，完成传统 ML 与 DL 的统一测试比较，并实现统计阈值、Isolation Forest、One-Class SVM 与基于 KPI 相关性的初步异常分析。

2. 深度学习 KPI 预测

使用 gotsf-ds 的四类 KPI（DLPRB、DLThpVol、DLThpTime、MR_number），每条样本由同一 beam 的过去 24 小时四维序列与 t−168 的四维季节性特征构成，预测下一小时四种 KPI。训练目标时刻为 169–587，验证为 588–671，留出测试为 672–839；训练抽样 60,000 个窗口、验证 12,000 个，测试 483,840 条逐 beam 记录。

KPI	GRU MAE↓	GRU RMSE↓	GRU R^2↑
DLPRB	0.245618	0.468861	0.808018
DLThpVol	0.204574	0.496740	0.551737
DLThpTime	0.229781	0.513352	0.714872
MR_number	0.209693	0.366888	0.885789

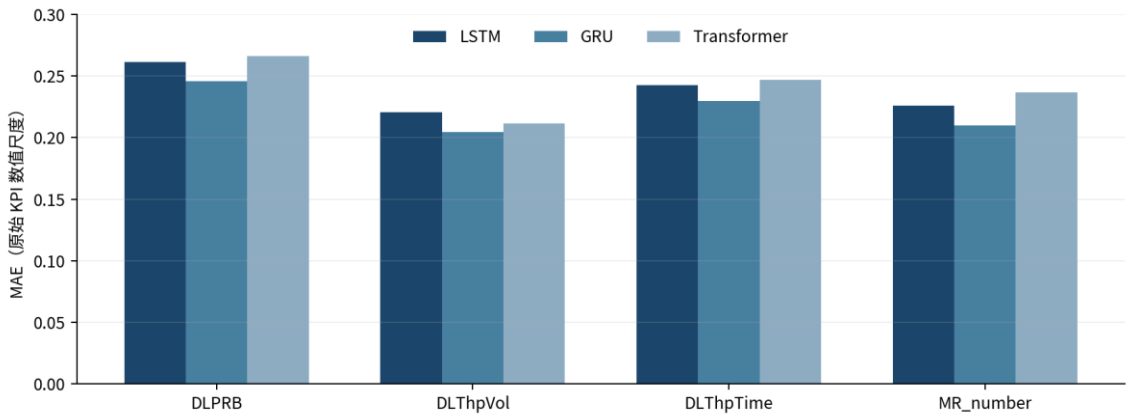


图 1 LSTM、GRU 与 Transformer 在四类 KPI 上的 MAE 比较

图注补充：历史 gotsf-ds 留出目标 Time 672–839，n=483,840 beam-hour；误差使用原 KPI 尺度，均值曲线不替代逐样本评分。

GRU 在四种 KPI 上均取得三种深度学习模型中最低的 MAE；DLThpVol 的最小 RMSE 则来自 LSTM（0.484384），表明不同损失指标的结论并不完全一致。

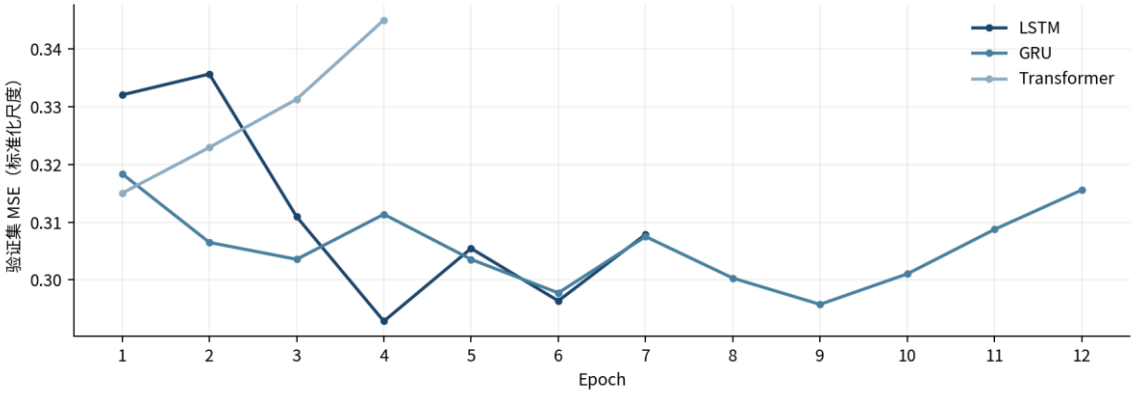


图 2 三种深度学习模型的验证集 MSE 变化

图注补充：历史内部验证抽样 12,000 条，纵轴为标准化 MSE、横轴为 epoch；早停反映该次验证表现，新协议单独列示。

3. 传统 ML 与深度学习对比

对比沿用相同的下一小时预测目标、测试时段和原始 KPI 尺度。以各 KPI 的传统 ML 最佳 MAE 为参照，GRU 的相对误差改善如下。

KPI	传统 ML 最佳 MAE	GRU MAE	相对改善	传统最优 RMSE	DL 最优 RMSE 及模型
DLPRB	0.261817（XGBoost）	0.245618	6.19%	0.4937 Random Forest	0.4689 GRU
DLThpVol	0.207615（RF）	0.204574	1.46%	0.4602 Random Forest	0.4844 LSTM
DLThpTime	0.243576（XGBoost）	0.229781	5.66%	0.5245 Random Forest	0.5134 GRU
MR_number	0.224767（XGBoost）	0.209693	6.71%	0.3956 Random Forest	0.3669 GRU

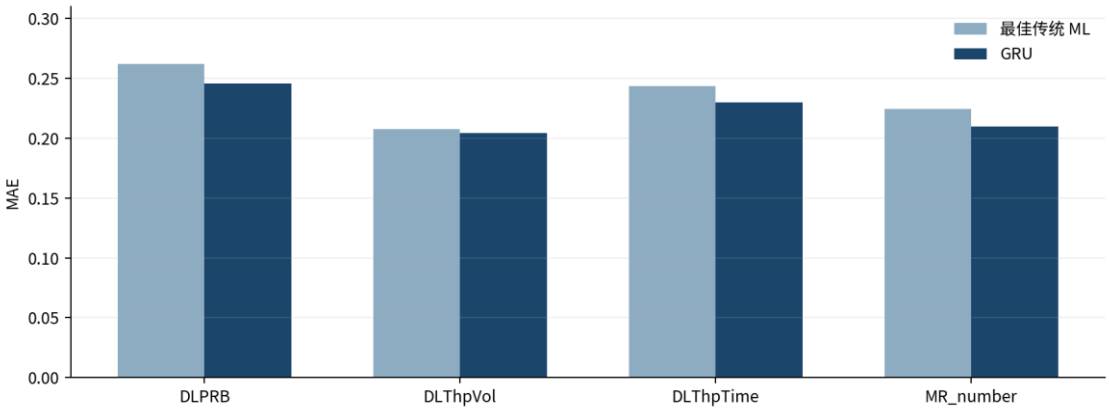


图 3 传统机器学习最佳模型与 GRU 的 MAE 对比

图注补充：历史 gotsf-ds 留出目标 Time 672–839，n=483,840 beam-hour；误差使用原 KPI 尺度，均值曲线不替代逐样本评分。

在同一留出测试段上，GRU 四项 MAE 均优于传统 ML 的最佳值；但 DLThpVol 的最优 DL RMSE（LSTM：0.484384）仍高于随机森林（0.460162）。传统 ML 的三折滚动验证和显著性检验不等于已完成 GRU 与传统 ML 之间的统计显著性比较。

4. 5G 网络异常检测与初步关联分析

在 2,880 个 beam、168 个测试小时构成的 483,840 条记录上，实现 3σ、IQR、Isolation Forest 与 One-Class SVM。统计阈值按 beam 的训练期分布计算；Isolation Forest 训练抽样 80,000 条、测试全量；One-Class SVM 训练 2,500 条、测试抽样 12,000 条。

检测方法	测试记录数	异常标记数	标记比例
3σ	483,840	22,059	4.56%
IQR	483,840	51,318	10.61%
Isolation Forest	483,840	9,900	2.05%
One-Class SVM*	12,000	552	4.60%

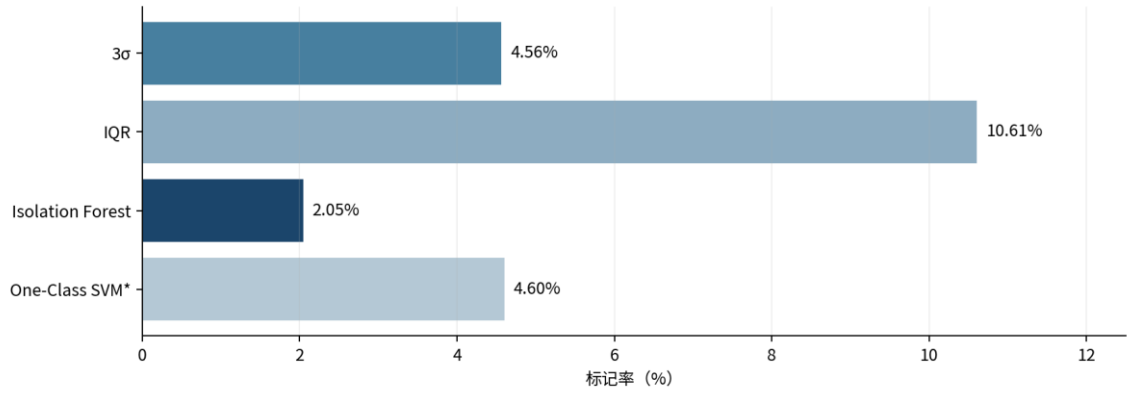


图 4 四种异常检测方法的异常标记率（*SVM 为抽样测试）

图注补充：历史全量分母 483,840 beam-hour；SVM 另为 12,000 抽样；候选率不代表真实故障率。

采用 Isolation Forest AND（3σ OR IQR）筛选出 3,165 条联合候选，占测试集约 0.65%。这些记录属于待核查的异常候选，并非经网络告警或故障工单确认的真实故障。

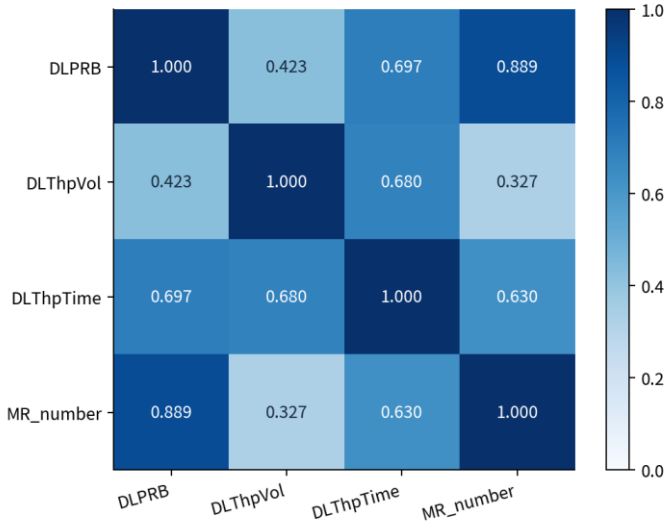


图 5 联合异常候选样本的 KPI 相关性矩阵

图注补充：Pearson r，正式联合候选 n=3,165、30 基站聚类；六对 Holm 检验与区间见本次统计补充，相关不代表因果。

在联合候选中，DLPRB 与 MR_number 的 Pearson 相关系数约为 0.889，DLPRB 与 DLThpTime 约为 0.697。相关性用于提出负载、调度和测量活动等排查假设，不能直接证明因果关系。

5. 技术问题与阶段局限

（1）训练样本与比较口径：深度学习随机抽样 60,000 个训练窗口，传统 ML 使用 1,448,640 条训练样本，输入表示、参数量与计算预算不同，因此当前比较属于同一测试期的描述性性能比较。

（2）验证独立性：神经网络继承的 StandardScaler 在时间 0–671 拟合，包含内部验证段 588–671，但未包含测试段；如需严格评估调参稳定性，应仅在内部训练期拟合缩放器并重新验证。

（3）异常解释边界：数据无真实故障标签，无法计算故障识别的 Precision、Recall 或 F1；One-Class SVM 为抽样测试，其比例不可按全量结果解释。事件 CSV 只导出联合候选中优先级最高的 2,000 条。

6. 交付物核对

任务书交付物	可核对的文件
1. 深度学习 KPI 预测模型代码	w3_dl_prediction.py
2. 深度学习模型性能评估报告	深度学习模型性能评估报告.docx
3. 传统 ML 与 DL 模型对比分析	传统 ML 与 DL 模型对比分析.docx；w3_dl_comparison.py
4. 异常检测模型代码	w3_anomaly_detection.py
5. 异常检测结果报告	异常检测结果报告.docx
6. 异常根因分析初步方案	异常根因分析初步方案.docx

7. 历史阶段的后续安排

第四阶段对应原计划第 7—8 周，重点完成系统集成、Web 展示与项目总结汇报。原第 7 周：先集成 KPI 预测和异常检测模块，统一数据输入与结果输出；再使用 Streamlit 开发交互式 Web 界面；最后完成系统测试与性能优化。本部分交付完整的系统代码、可运行的 Web 应用和系统使用手册。
原第 8 周：汇总前期的数据预处理、传统机器学习、深度学习和异常检测工作，撰写完整项目技术报告；制作项目演示 PPT；整理代码、依赖说明及技术文档并归档至 GitHub。本部分交付完整的项目技术报告、项目演示 PPT，以及包含所有代码和文档的 GitHub 仓库。

2026 年 10 月 25 日算法验证与导师反馈补充

本节为本次实际执行的补充验证。前文原留出成绩保留为历史实验，本节新成绩使用独立目录归档，不替换旧权重或旧图表。Web 入口、页面、交互与后台集成源码保持不变。

统一比较协议与时序回测

RF、XGBoost 和 GRU 使用完全相同的 60,000 条训练标签及目标时段；ML 输入 20 维，GRU 输入 24×4 连续历史与 4 维季节向量。统一训练样本量并不等于统一计算预算，GRU 有内部验证早停，树模型沿用固定参数。三个外层评估窗为 384–479、480–575、576–671；内部早停窗分别为 336–383、432–479、528–575，训练目标从 169 开始至内部验证前一小时。全部 2,880 beam 参与每个外层评估，各 276,480 条。

留出评估为 672–839，共 483,840 条；训练目标 169–587，内部验证 588–671。每个模型的缩放器只用内部验证起点之前的 raw 观测拟合；已通过改变所有未来值而训练缩放参数不变的回归测试。固定 seed42 执行三折与留出，seed43 仅重复留出；两种模型种子使用相同训练抽样（抽样 seed42）。这是有限的初始化稳定性证据。

表 A1 新实验留出集结果 seed42 原始 KPI 尺度

KPI	模型	MAE	RMSE	R^2
DLPRB	RandomForest	0.266552	0.513284	0.769915
DLThpVol	RandomForest	0.212908	0.478479	0.584089
DLThpTime	RandomForest	0.247807	0.540264	0.684194
MR_number	RandomForest	0.231022	0.413987	0.854584
DLPRB	XGBoost	0.268472	0.518092	0.765584
DLThpVol	XGBoost	0.220221	0.559090	0.432144
DLThpTime	XGBoost	0.251333	0.581392	0.634282
MR_number	XGBoost	0.231131	0.416529	0.852792
DLPRB	GRU	0.247765	0.476520	0.801694
DLThpVol	GRU	0.211055	0.498167	0.549158
DLThpTime	GRU	0.236438	0.519272	0.708258
MR_number	GRU	0.207566	0.366875	0.885797

GRU 在 seed42 的四项 MAE 均最低；DLThpVol 仍由 RF 取得较低 RMSE 和较高 R^2。GRU 适合作为 MAE 优先推荐，DLThpVol 在关注大误差时保留 RF。本结论针对本数据、配置和损失权重。历史传统综合排名 1.417 来自 MAE/RMSE/R^2名次等权，其中 RMSE 与 R^2同序，不能视为三个独立证据。

表 A2 新三折扩展窗口结果 seed42 均值及折间标准差

KPI	模型	MAE 均值±SD	RMSE 均值±SD
DLPRB	GRU	0.2553 ± 0.0061	0.4756 ± 0.0077
DLThpTime	GRU	0.2515 ± 0.0084	0.6752 ± 0.1417
DLThpVol	GRU	0.2287 ± 0.0127	1.0353 ± 0.3805
MR_number	GRU	0.2121 ± 0.0028	0.3562 ± 0.0065
DLPRB	RandomForest	0.2695 ± 0.0029	0.5161 ± 0.0107
DLThpTime	RandomForest	0.2628 ± 0.0125	0.7271 ± 0.1729
DLThpVol	RandomForest	0.2381 ± 0.0152	1.0875 ± 0.3967
MR_number	RandomForest	0.2294 ± 0.0016	0.4069 ± 0.0029
DLPRB	XGBoost	0.2715 ± 0.0034	0.5237 ± 0.0112
DLThpTime	XGBoost	0.2659 ± 0.0125	0.7259 ± 0.1452
DLThpVol	XGBoost	0.2440 ± 0.0137	1.1110 ± 0.3230
MR_number	XGBoost	0.2291 ± 0.0021	0.4097 ± 0.0054

三折均值中 GRU 的四项 MAE/RMSE 均低于本轮 RF/XGB，但 DLThpVol 跨折 RMSE 波动较大，不能用一次留出结果概括所有时段。旧全量传统回测中 DLThpVol 的线性回归 RMSE=0.967665 低于 RF=1.003675；该旧实验的训练预算不同，应独立解释。LSTM 与 Transformer 本次没有新增三折或种子实验。

跨类别配对显著性与随机种子

在相同 beam 和目标小时上，先计算逐记录绝对/平方误差，再按小时平均，形成 168 个配对损失。d 为候选损失减参考损失，负值有利于候选。使用 Newey–West HAC 带宽 24、双侧近似检验；每个场景和 seed 的 3 对模型×4KPI×2 损失共 24 项一起 Holm 校正。95%区间为逐项 HAC 区间，未作同时区间校正。未为获得显著结果修改参数。

表 A3 GRU 对 RF 的留出配对损失检验 seed42

KPI 及损失	平均差 d	95% CI	Holm p
DLPRB mae	-0.018787	[-0.020485, -0.017089]	7.46e-103
DLPRB mse	-0.036389	[-0.040054, -0.032723]	5.21e-83
DLThpVol mae	-0.001853	[-0.004178, 0.000471]	0.354
DLThpVol mse	0.019228	[-0.006343, 0.044798]	0.354
DLThpTime mae	-0.011369	[-0.013218, -0.009520]	2.68e-32
DLThpTime mse	-0.022241	[-0.027565, -0.016918]	2.64e-15
MR_number mae	-0.023456	[-0.025629, -0.021282]	5.82e-98
MR_number mse	-0.036788	[-0.041060, -0.032516]	1.23e-62

DLThpVol 在 seed42 上的 GRU 对 RF，MAE 差−0.001853、MSE 差+0.019228，两者 Holm p 均约 0.354，不能判定差异显著。DLPRB、DLThpTime、MR_number 的 GRU 对 RF 两类损失在该协议下均有显著改善。其余模型配对与 seed43 的完整效应、区间和 p 值见 holdout_significance.csv，不将未显著解释为模型完全等效。

表 A4 两组模型种子的留出误差 seed42 及 43

KPI	模型	MAE 42 / 43	RMSE 42 / 43
DLPRB	GRU	0.2478 / 0.2473	0.4765 / 0.4773
DLThpVol	GRU	0.2111 / 0.2097	0.4982 / 0.5001
DLThpTime	GRU	0.2364 / 0.2277	0.5193 / 0.5122
MR_number	GRU	0.2076 / 0.2080	0.3669 / 0.3697
DLPRB	RandomForest	0.2666 / 0.2663	0.5133 / 0.5115
DLThpVol	RandomForest	0.2129 / 0.2130	0.4785 / 0.4779
DLThpTime	RandomForest	0.2478 / 0.2478	0.5403 / 0.5408
MR_number	RandomForest	0.2310 / 0.2312	0.4140 / 0.4148
DLPRB	XGBoost	0.2685 / 0.2684	0.5181 / 0.5185
DLThpVol	XGBoost	0.2202 / 0.2201	0.5591 / 0.5561
DLThpTime	XGBoost	0.2513 / 0.2515	0.5814 / 0.5877
MR_number	XGBoost	0.2311 / 0.2310	0.4165 / 0.4158

seed43 保留了 GRU 四项 MAE 较低、RF 的 DLThpVol RMSE 较低的观察；两组种子不构成独立时间样本，不能把它们当作大样本稳定性证明。测试期已在历史选型中反复使用，本次属于固定协议复核，并非独立外部验证。

W4 异常统计证据与联合规则

复用既有 W4 统计，本次只重新核对全量标记逻辑和相关矩阵。483,840 条唯一 beam-hour 记录中，3σ 为 22,059，IQR 为 51,318，IF 为 9,900，联合候选 3,165。SVM 仍为历史 12,000 条抽样测试，不参加共识投票。逐 beam 偏度/峰度支持偏态厚尾普遍存在，但阈值宽度、beam 异质性和时间分布变化也影响标记率，不能把偏态指定为唯一因果机制。

KPI	|偏度|>1	超额峰度>3	3σ / IQR 标记率
DLPRB	86.25%	59.79%	1.77% / 4.13%
DLThpVol	98.33%	75.45%	1.60% / 4.59%
DLThpTime	96.56%	76.15%	1.85% / 4.87%
MR_number	59.76%	21.77%	1.39% / 2.76%

零 IQR 回退分布数为 0。逐 KPI 比例的分母各为 483,840，整条 beam-hour 的总体标记则是任意 KPI 触发，不能把四个逐 KPI 比例相加当总体比例。

逻辑组合	候选数
IF AND (3σ OR IQR)	3,165
IF AND IQR	3,159
IF AND 3σ	2,080
IF AND 3σ AND IQR	2,074
IF OR 3σ OR IQR	58,108

OR 允许任一统计阈值支持，AND 要求 IF 与统计信号共同触发。本数据最终规则比 IF AND IQR 仅多 6 条，不能夸大 OR 分支的实际增益。候选规模的收紧/放宽不等于故障准确率或召回率改善；没有真实故障标签，不报告这些分类指标。

相关矩阵样本量与统计推断

KPI 组合	r	站级 bootstrap 95% CI	Holm p
DLPRB / DLThpVol	0.423	[0.169, 0.601]	7.61e-05
DLPRB / DLThpTime	0.697	[0.485, 0.795]	3.53e-10
DLPRB / MR_number	0.889	[0.841, 0.918]	1.1e-28
DLThpVol / DLThpTime	0.680	[0.535, 0.770]	2.68e-08
DLThpVol / MR_number	0.327	[0.065, 0.488]	0.0101
DLThpTime / MR_number	0.630	[0.449, 0.758]	8.36e-08

每对 n=3,165 是候选记录数；30 是基站聚类数，不代表 3,165 条独立样本。p 值来自站级聚类稳健零回归斜率检验，六对一起 Holm 校正；区间另用站级 bootstrap 估计。六对校正后 p 均<0.05，仅说明已筛选候选中的关联。候选选择可能改变相关结构，单向站级聚类未完全处理跨站同小时共同冲击；30 聚类仍为近似推断，不构成故障根因或因果证明。

代码修复与最新验收

修复仅涉及底层小时数据契约、DL 输出预检和 scaler 测试提取。训练加载器与推理拒绝共同缺小时、重复或非整数小时；保留 ML 20 维、DL 窗口、逆标准化和 IF AND (3σ OR IQR)定义。DL 当前代码已仅在内部训练前缀拟合 scaler；本次锁定该行为，没有把历史成绩改写为新成绩。

本次既有自动化基线 48 项通过；新增算法及统计回归后最新完整测试 57 项通过（final_tests.txt）。六个 Streamlit 页面 AppTest 加载及切换均无异常，实际新模型回载及 CSV 导出通过，原异常模型 5,760 条检测通过。另用 1 轮、512 条样本执行现有 DL CLI 仅作功能验收，不把其分数纳入模型比较。Web 页面及服务源码哈希保持不变。本次未以真人浏览器重走每个上传/下载控件或实时 WebSocket 训练全流程，不能将自动验收冒充完整手工验收。

证据根目录：reports/final_audit_20261025。新实验配置 protocol.json、逐次 runs.json、60 组 metrics.csv、hourly_losses.csv、48 组 holdout_significance.csv；实际权重及逐 beam-hour 配对预测位于 resources/final_audit_20261025（Git 忽略，需本机备份）。历史 reports/和 figures/数值保持原样。没有独立外部数据、全模型调参或生产实时网管接入，本次不扩大该范围。