2026 年 10 月 25 日核验修订版 前文历史成绩保留 新实验及最新状态见末节补充验证

基于 AI 的 5G 网络关键性能指标预测与异常检测系统

深度学习模型性能评估报告

LSTM、GRU 与 Transformer 的下一小时多变量 KPI 预测

数据集：gotsf-ds / netop/gotsf-ds
评估对象：4 类 KPI × 3 种深度学习模型
实验环境：Python / PyTorch / scikit-learn / CPU

1. 实验目的与数据基础

本实验以第二阶段构建的 gotsf-ds 时序数据为输入，实现 LSTM、GRU 与轻量 Transformer 的多变量下一小时 KPI 预测，统一评估其预测误差及模型行为，为传统机器学习与深度学习模型的后续比较提供证据。

项目	规模或设置	说明
时间索引	0–839	每个时间索引按 1 小时处理
空间对象	2880 beam	30 个基站、90 个 cell
预测对象	DLPRB / DLThpVol / DLThpTime / MR_number	四个 KPI 联合输出
数据基础	2,419,200 行 × 17 列	预处理后长表 kpi_timeseries.csv
测试范围	Time 672–839	168 小时 × 2880 beam = 483,840 条

2. 深度学习模型结构与训练设置

三个模型均使用当前目标时刻之前连续 24 小时的四维标准化 KPI 序列，并补充 t−168 小时对应的四维历史输入，经共享预测头输出下一小时的四类 KPI。LSTM、GRU 通过循环结构提取序列状态；Transformer 使用线性嵌入、位置参数和单层编码器提取时序特征。

项目	配置	说明
输入窗口	24 小时 + t−168 特征	不使用目标小时自身信息
训练 / 验证 / 测试目标时段	169–587 / 588–671 / 672–839	按目标时间顺序切分
抽样规模	训练 60,000 / 验证 12,000	测试全量 483,840
优化配置	Adam，lr=0.001	batch size=256；最大 12 epoch
网络规模	LSTM 6,180 / GRU 4,964 / Transformer 10,788 参数	hidden=32；固定随机种子 42
硬件	CPU	源自实际运行配置文件

3. 评价指标与统一口径

采用 MAE、RMSE 和 R^2 评价每个 beam × 目标小时的预测。MAE 表示平均绝对误差；RMSE 对较大误差更加敏感；R^2 衡量模型相对均值预测的拟合程度。神经网络在标准化尺度训练，最终将预测反变换回原始 KPI 数值尺度计算指标。

4. 模型预测性能

KPI	模型	MAE	RMSE	R^2
DLPRB	LSTM	0.2612	0.4919	0.7887
DLPRB	GRU	0.2456	0.4689	0.8080
DLPRB	Transformer	0.2662	0.5201	0.7638
DLThpVol	LSTM	0.2205	0.4844	0.5738
DLThpVol	GRU	0.2046	0.4967	0.5517
DLThpVol	Transformer	0.2117	0.4874	0.5685
DLThpTime	LSTM	0.2428	0.5251	0.7016
DLThpTime	GRU	0.2298	0.5134	0.7149
DLThpTime	Transformer	0.2467	0.5590	0.6619
MR_number	LSTM	0.2260	0.3893	0.8714
MR_number	GRU	0.2097	0.3669	0.8858
MR_number	Transformer	0.2368	0.4269	0.8454

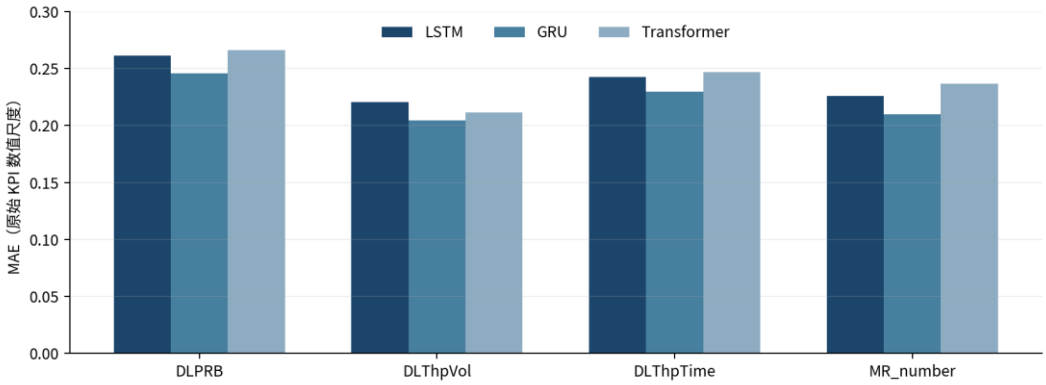


图 1 三种深度学习模型在四类 KPI 上的 MAE 对比

图注补充：历史 gotsf-ds 留出目标 Time 672–839，n=483,840 beam-hour；误差使用原 KPI 尺度，均值曲线不替代逐样本评分。

从 MAE 看，GRU 在四种 KPI 上均取得最低值：DLPRB 为 0.2456，DLThpVol 为 0.2046，DLThpTime 为 0.2298，MR_number 为 0.2097。对于 DLPRB、DLThpTime 和 MR_number，GRU 亦取得最小 RMSE 与最高 R^2。

5. 训练收敛与差异分析

模型	最佳验证 Epoch	最佳验证 MSE	实际训练 Epoch	参数量
LSTM	4	0.29283	7	6,180
GRU	9	0.29574	12	4,964
Transformer	1	0.31503	4	10,788

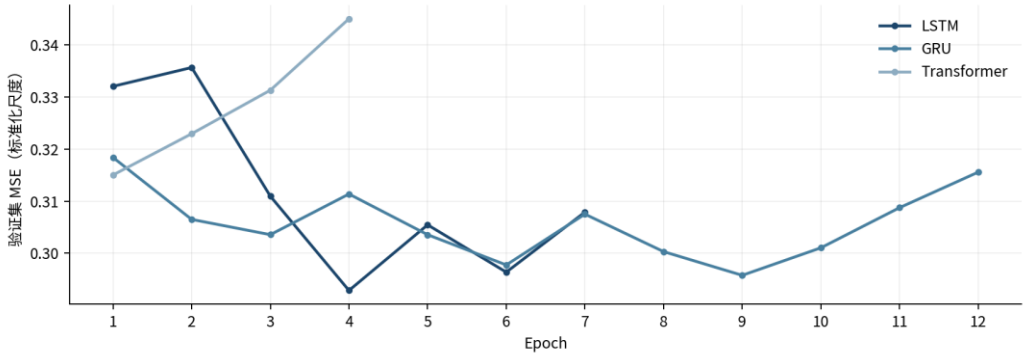


图 2 三种模型的验证集 MSE 变化（标准化数值尺度）

图注补充：历史内部验证抽样 12,000 条，纵轴为标准化 MSE、横轴为 epoch；早停反映该次验证表现，新协议单独列示。

LSTM 在第 4 轮得到最低验证损失，之后因验证指标未继续改善而早停；GRU 在第 9 轮取得其最优验证值，第 12 轮结束；轻量 Transformer 在第 1 轮达到最优验证值，其后损失上升，第 4 轮结束。

DLThpVol 的结果具有差异性：GRU 的 MAE 最低（0.2046），但其 RMSE 为 0.4967，高于 LSTM 的 0.4844，且 R^2 低于 LSTM。这提示 GRU 的典型绝对误差较小，但平方误差受到相对较大偏差的影响；该解释仍需逐样本误差分布验证。

6. 实验限制与后续改进

本轮实验只使用单次随机种子和一组轻量模型参数；训练与验证样本为随机抽样，测试集为完整留出期。数据来源于原始文件名称含 train 的时间区间内部切分，而非独立官方测试文件。此外，上一阶段保存的 StandardScaler 在 Time 0–671 上拟合，其中包含内部验证时段 588–671，因而验证环节存在预处理统计信息覆盖的问题；尽管留出测试期未参与缩放器拟合，后续仍应使用仅基于训练子段拟合的 scaler 复核。

7. 训练配置、模型容量与可复现性补充

为明确模型输入、调参与模型选型依据，以下配置依据实际运行记录 w3_deep_learning_run_config.json 及 w3_dl_prediction.py 整理。

项目	运行设置	说明
模型输入	连续 24 个时间点 × 4 KPI	形状 [24,4]；均为历史观测
季节性补充	额外 4 维 t−168 对应观测	与序列编码后特征拼接
模型输出	同时预测 4 种 KPI 的下一小时值	多输出回归；损失为标准化 MSE
数据划分	训练 169–587；验证 588–671；测试 672–839	按目标时刻，顺序切分
训练样本	训练随机抽样 60,000；验证 12,000	测试全量 483,840 beam-hour
优化设置	Adam，学习率 0.001，batch 256	最多 12 Epoch；patience=3

项目	运行设置	说明
实验环境与复现	CPU，seed=42	指标转换回原始 KPI 数值尺度

LSTM 与 GRU 均使用单层循环编码器、隐藏宽度 32；Transformer 为线性投影 + 可学习位置参数 + 单层编码器（4 个注意力头，前馈宽度 64）。三者使用相同的预测头思路，但参数量不同，故本实验不能视为控制模型容量的架构消融。

模型	参数量	最优轮次	最优验证 MSE	实际训练轮次
LSTM	6,180	4	0.292830	7
GRU	4,964	9	0.295743	12
Transformer	10,788	1	0.315027	4

7.1 结果解释与后续验证边界

历史阶段状态：GRU 的四项 MAE 最优是当前单一留出测试期上的观察结果，并非经统计显著性检验的结论。仅使用单个随机种子、有限训练窗口和一组候选参数，尚未进行深度学习模型的滚动重训或重复种子实验。 2026 年 10 月 25 日已增加 GRU 三折及 RF/XGB/GRU 跨类配对检验，详见本报告末尾补充验证；独立外部测试仍未完成。

预处理 StandardScaler 曾在 Time 0–671 拟合，其中包含内部验证期 588–671；虽然未接触留出测试期，仍应在后续严格验证中改为按训练子段或验证折单独拟合缩放器。建议继续记录每组随机种子、每折 MAE/RMSE/R^2、训练时长，并开展基于小时级配对误差的统计检验。

8. 结论与证据文件

本阶段实现并运行 LSTM、GRU、Transformer 三类多变量 KPI 预测模型，获得 12 组完整测试指标。GRU 在当前设置下取得四类 KPI 的最低 MAE，轻量 Transformer 整体表现落后。模型结果可作为下一步模型选型与异常检测模块的预测基础，但不应将当前结果解释为深度学习模型的一般性优势。

2026 年 10 月 25 日算法验证与导师反馈补充

本节为本次实际执行的补充验证。前文原留出成绩保留为历史实验，本节新成绩使用独立目录归档，不替换旧权重或旧图表。Web 入口、页面、交互与后台集成源码保持不变。

统一比较协议与时序回测

RF、XGBoost 和 GRU 使用完全相同的 60,000 条训练标签及目标时段；ML 输入 20 维，GRU 输入 24×4 连续历史与 4 维季节向量。统一训练样本量并不等于统一计算预算，GRU 有内部验证早停，树模型沿用固定参数。三个外层评估窗为 384–479、480–575、576–671；内部早停窗分别为 336–383、432–479、528–575，训练目标从 169 开始至内部验证前一小时。全部 2,880 beam 参与每个外层评估，各 276,480 条。

留出评估为 672–839，共 483,840 条；训练目标 169–587，内部验证 588–671。每个模型的缩放器只用内部验证起点之前的 raw 观测拟合；已通过改变所有未来值而训练缩放参数不变的回归测试。固定 seed42 执行三折与留出，seed43 仅重复留出；两种模型种子使用相同训练抽样（抽样 seed42）。这是有限的初始化稳定性证据。

表 A1 新实验留出集结果 seed42 原始 KPI 尺度

KPI	模型	MAE	RMSE	R^2
DLPRB	RandomForest	0.266552	0.513284	0.769915
DLThpVol	RandomForest	0.212908	0.478479	0.584089
DLThpTime	RandomForest	0.247807	0.540264	0.684194
MR_number	RandomForest	0.231022	0.413987	0.854584
DLPRB	XGBoost	0.268472	0.518092	0.765584
DLThpVol	XGBoost	0.220221	0.559090	0.432144
DLThpTime	XGBoost	0.251333	0.581392	0.634282
MR_number	XGBoost	0.231131	0.416529	0.852792
DLPRB	GRU	0.247765	0.476520	0.801694
DLThpVol	GRU	0.211055	0.498167	0.549158
DLThpTime	GRU	0.236438	0.519272	0.708258
MR_number	GRU	0.207566	0.366875	0.885797

GRU 在 seed42 的四项 MAE 均最低；DLThpVol 仍由 RF 取得较低 RMSE 和较高 R^2。GRU 适合作为 MAE 优先推荐，DLThpVol 在关注大误差时保留 RF。本结论针对本数据、配置和损失权重。历史传统综合排名 1.417 来自 MAE/RMSE/R^2名次等权，其中 RMSE 与 R^2同序，不能视为三个独立证据。

表 A2 新三折扩展窗口结果 seed42 均值及折间标准差

KPI	模型	MAE 均值±SD	RMSE 均值±SD
DLPRB	GRU	0.2553 ± 0.0061	0.4756 ± 0.0077
DLThpTime	GRU	0.2515 ± 0.0084	0.6752 ± 0.1417
DLThpVol	GRU	0.2287 ± 0.0127	1.0353 ± 0.3805
MR_number	GRU	0.2121 ± 0.0028	0.3562 ± 0.0065
DLPRB	RandomForest	0.2695 ± 0.0029	0.5161 ± 0.0107
DLThpTime	RandomForest	0.2628 ± 0.0125	0.7271 ± 0.1729
DLThpVol	RandomForest	0.2381 ± 0.0152	1.0875 ± 0.3967
MR_number	RandomForest	0.2294 ± 0.0016	0.4069 ± 0.0029

KPI	模型	MAE 均值±SD	RMSE 均值±SD
DLPRB	XGBoost	0.2715 ± 0.0034	0.5237 ± 0.0112
DLThpTime	XGBoost	0.2659 ± 0.0125	0.7259 ± 0.1452
DLThpVol	XGBoost	0.2440 ± 0.0137	1.1110 ± 0.3230
MR_number	XGBoost	0.2291 ± 0.0021	0.4097 ± 0.0054

三折均值中 GRU 的四项 MAE/RMSE 均低于本轮 RF/XGB，但 DLThpVol 跨折 RMSE 波动较大，不能用一次留出结果概括所有时段。旧全量传统回测中 DLThpVol 的线性回归 RMSE=0.967665 低于 RF=1.003675；该旧实验的训练预算不同，应独立解释。LSTM 与 Transformer 本次没有新增三折或种子实验。

跨类别配对显著性与随机种子

在相同 beam 和目标小时上，先计算逐记录绝对/平方误差，再按小时平均，形成 168 个配对损失。d 为候选损失减参考损失，负值有利于候选。使用 Newey–West HAC 带宽 24、双侧近似检验；每个场景和 seed 的 3 对模型×4KPI×2 损失共 24 项一起 Holm 校正。95%区间为逐项 HAC 区间，未作同时区间校正。未为获得显著结果修改参数。

表 A3 GRU 对 RF 的留出配对损失检验 seed42

KPI 及损失	平均差 d	95% CI	Holm p
DLPRB mae	-0.018787	[-0.020485, -0.017089]	7.46e-103
DLPRB mse	-0.036389	[-0.040054, -0.032723]	5.21e-83
DLThpVol mae	-0.001853	[-0.004178, 0.000471]	0.354
DLThpVol mse	0.019228	[-0.006343, 0.044798]	0.354
DLThpTime mae	-0.011369	[-0.013218, -0.009520]	2.68e-32
DLThpTime mse	-0.022241	[-0.027565, -0.016918]	2.64e-15
MR_number mae	-0.023456	[-0.025629, -0.021282]	5.82e-98
MR_number mse	-0.036788	[-0.041060, -0.032516]	1.23e-62

DLThpVol 在 seed42 上的 GRU 对 RF，MAE 差−0.001853、MSE 差+0.019228，两者 Holm p 均约 0.354，不能判定差异显著。DLPRB、DLThpTime、MR_number 的 GRU 对 RF 两类损失在该协议下均有显著改善。其余模型配对与 seed43 的完整效应、区间和 p 值见 holdout_significance.csv，不将未显著解释为模型完全等效。

表 A4 两组模型种子的留出误差 seed42 及 43

KPI	模型	MAE 42 / 43	RMSE 42 / 43
DLPRB	GRU	0.2478 / 0.2473	0.4765 / 0.4773
DLThpVol	GRU	0.2111 / 0.2097	0.4982 / 0.5001
DLThpTime	GRU	0.2364 / 0.2277	0.5193 / 0.5122
MR_number	GRU	0.2076 / 0.2080	0.3669 / 0.3697
DLPRB	RandomForest	0.2666 / 0.2663	0.5133 / 0.5115
DLThpVol	RandomForest	0.2129 / 0.2130	0.4785 / 0.4779
DLThpTime	RandomForest	0.2478 / 0.2478	0.5403 / 0.5408
MR_number	RandomForest	0.2310 / 0.2312	0.4140 / 0.4148
DLPRB	XGBoost	0.2685 / 0.2684	0.5181 / 0.5185
DLThpVol	XGBoost	0.2202 / 0.2201	0.5591 / 0.5561

KPI	模型	MAE 42 / 43	RMSE 42 / 43
DLThpTime	XGBoost	0.2513 / 0.2515	0.5814 / 0.5877
MR_number	XGBoost	0.2311 / 0.2310	0.4165 / 0.4158

seed43 保留了 GRU 四项 MAE 较低、RF 的 DLThpVol RMSE 较低的观察；两组种子不构成独立时间样本，不能把它们当作大样本稳定性证明。测试期已在历史选型中反复使用，本次属于固定协议复核，并非独立外部验证。

代码修复与最新验收

修复仅涉及底层小时数据契约、DL 输出预检和 scaler 测试提取。训练加载器与推理拒绝共同缺小时、重复或非整数小时；保留 ML 20 维、DL 窗口、逆标准化和 IF AND (3σ OR IQR)定义。DL 当前代码已仅在内部训练前缀拟合 scaler；本次锁定该行为，没有把历史成绩改写为新成绩。

本次既有自动化基线 48 项通过；新增算法及统计回归后最新完整测试 57 项通过（final_tests.txt）。六个 Streamlit 页面 AppTest 加载及切换均无异常，实际新模型回载及 CSV 导出通过，原异常模型 5,760 条检测通过。另用 1 轮、512 条样本执行现有 DL CLI 仅作功能验收，不把其分数纳入模型比较。Web 页面及服务源码哈希保持不变。本次未以真人浏览器重走每个上传/下载控件或实时 WebSocket 训练全流程，不能将自动验收冒充完整手工验收。

证据根目录：reports/final_audit_20261025。新实验配置 protocol.json、逐次 runs.json、60 组 metrics.csv、hourly_losses.csv、48 组 holdout_significance.csv；实际权重及逐 beam-hour 配对预测位于 resources/final_audit_20261025（Git 忽略，需本机备份）。历史 reports/和 figures/数值保持原样。没有独立外部数据、全模型调参或生产实时网管接入，本次不扩大该范围。