基于 AI 的 5G 网络关键性能指标预测与异常检测系统

数据集统计分析报告

gotsf-ds 四类 KPI 的原始数据审计、预处理与时间序列构建

数据集：gotsf-ds / netop/gotsf-ds

处理工具：Python / Pandas / NumPy / scikit-learn

1. 实验目的与数据来源

本实验以公开的 gotsf-ds 数据集为输入，完成数据结构识别、数据质量审计、时间序列划分、标准化与归一化处理，为后续传统机器学习 KPI 预测提供统一的数据基础。

数据对象	规模或范围	说明
数据来源	gotsf-ds	四份 *_train_0w-5w.csv 文件
KPI 种类	4	DLPRB / DLThpVol / DLThpTime / MR_number
时间索引	0–839	840 个等间隔索引；原记录按小时描述
空间对象	30 基站 / 90 cell / 2880 beam	列名含 base_station_cell_beam 标识
输出文件	kpi_timeseries.csv	2,419,200 行 × 17 列

2. 数据格式与对象标识

原始 CSV 每个 KPI 单独存储为宽表，首列由 Pandas 读为 Unnamed: 0，其余 2880 列按“基站_cell_beam”编码。预处理脚本将首列恢复为 Time，并将多份宽表按相同时间和 beam 结构合并为统一长表。

原始列示例	转换后字段	对应含义
Unnamed: 0	Time	时间索引
12_2_31	base_station=12; cell=2; beam=31	三层网络对象标识
各 KPI 对应数值	DLPRB / DLThpVol / DLThpTime / MR_number	同一时间和 beam 的四种观测值

3. 原始数据质量审计

使用审计脚本对时间连续性、重复时间、完全重复行、缺失值、无限值、负值及非法 beam 标识进行核验，并确认四份 KPI 文件具有一致的时间轴和 beam 结构。原始审计结果如下表所示。

检查项	DLPRB	DLThpVol	DLThpTime	MR_number
时间点数量	840	840	840	840
Beam 数量	2880	2880	2880	2880
缺失值	0	0	0	0
无穷值	0	0	0	0
负值	0	0	0	0
重复时间	0	0	0	0
完全重复行	0	0	0	0

检查项	DLPRB	DLThpVol	DLThpTime	MR_number
时间缺口	0	0	0	0
非法 Beam 标识	0	0	0	0

4. KPI 统计特征

KPI	均值	中位数	P99	最大值	零值占比
DLPRB	0.5409	0.1750	5.0773	41.0263	23.77%
DLThpVol	0.3212	0.0952	3.5190	245.3746	31.76%
DLThpTime	0.4252	0.1293	4.4634	84.2068	27.76%
MR_number	0.6024	0.2273	5.0658	33.6660	20.15%

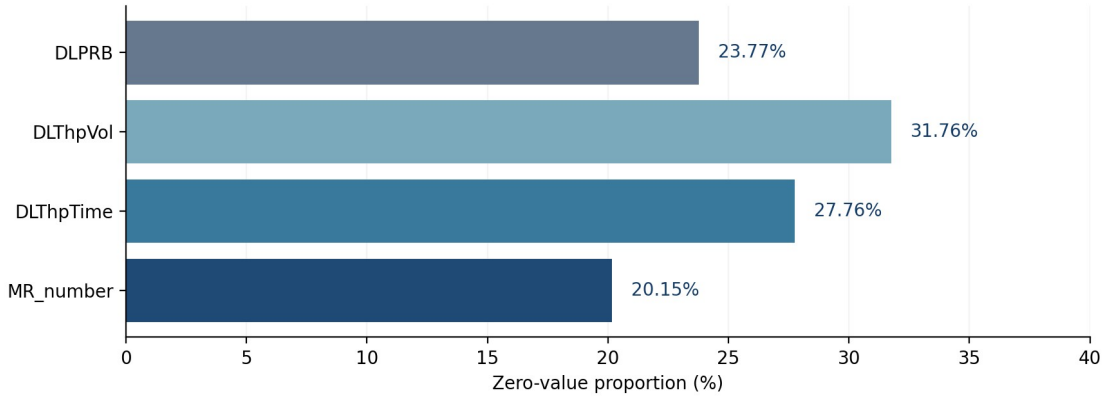


图 1 四类 KPI 的零值占比

四类 KPI 的零值占比在 20.15%至 31.76%之间。DLThpVol 的中位数为 0.0952，而其 99%分位数为 3.5190、最大值为 245.3746，反映出分布的明显右偏与长尾。零值可能对应 beam 在部分时段不活跃，因此本阶段保留合法零值；高幅值观测也未仅依据统计阈值直接判定为错误。

5. 数据清洗与结构重构

原始数据通过审计后，执行以下顺序的确定性处理：恢复 Time 字段，解析 beam 标识，对四类 KPI 按时间与 beam 对齐，构造 Time × beam 的长表，然后按时间顺序标记 train/test，并分别在训练期拟合两个数值变换器。

最终基础长表总行数为 840 × 2880 = 2,419,200。每行表示一个时间索引与一个 beam 的四类 KPI 观测。

6. 训练集和测试集划分

数据子集	Time 范围	时间索引数	样本行数
Train	0–671	672	1,935,360
Test	672–839	168	483,840

以时间索引作分割而不随机打乱，保证训练样本位于留出测试期之前。两个 scaler 均在 Train 上拟合，再用于 Train 与 Test 的数值变换，避免测试期统计信息进入训练预处理。

7. 标准化与归一化

7.1 StandardScaler

StandardScaler 以训练期均值与标准差计算 z = (x − μ_train) / σ_train；产出 _z 结尾的四列。训练期变换后的均值约为 0，标准差约为 1。

KPI	训练集均值 μ	训练集标准差 σ
DLPRB	0.536839	1.036266
DLThpVol	0.322617	1.096362
DLThpTime	0.422703	1.029392
MR_number	0.597422	1.039071

7.2 MinMaxScaler

MinMaxScaler 根据训练集最小值与最大值构建 x_mm = (x − min_train)/(max_train − min_train)。其训练样本映射到 0–1 区间；测试样本不重新拟合，也不强制裁剪超出训练范围的情况。

KPI	训练集最小值	训练集最大值	测试集归一化最大值
DLPRB	0	41.0263	0.8503
DLThpVol	0	245.3746	0.1214
DLThpTime	0	84.2068	0.4814
MR_number	0	33.6660	0.9601

8. 结论

本阶段完成了数据获取、审计、重构与两种缩放特征的生成。四份原始 KPI 的主要结构与数值检查均通过，并构建了包含 2,419,200 行、17 列的时间序列数据集。此结果为后续 lag 特征与传统机器学习模型提供统一的数据基础