基于 AI 的 5G 网络关键性能指标预测与异常检测系统

第二周实验报告

KPI 数据处理及传统机器学习预测

数据处理 / 预测模型 / 模型评估与图表
实验依据：代码及报告记录

1. 本周任务和进展

本周完成了数据获取、预处理与统计分析任务，以及传统机器学习 KPI 预测与评估任务。

2. 数据预处理结果

在 gotsf-ds 四类 KPI（DLPRB、DLThpVol、DLThpTime、MR_number）上执行完整性审计，均未发现缺失、无穷、负值、重复时间或时间缺口。将 4 份原始宽表整合为统一的 beam-level 长表，得到 2,419,200 行、17 列数据。Train 使用时间 0–671，Test 使用 672–839，StandardScaler 与 MinMaxScaler 只在训练期拟合。

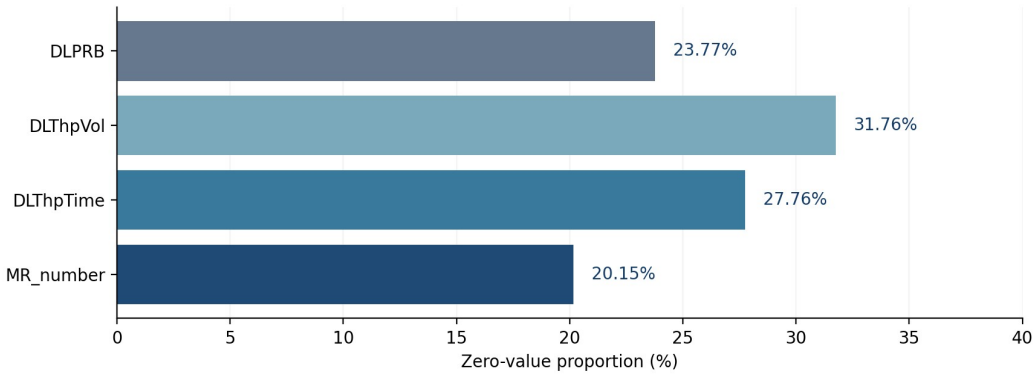


图 1 四类 KPI 原始观测中的零值比例

图 1 说明四类 KPI 均存在较多零值，DLThpVol 的占比最高（31.76%）。保留合法零值与高值以保留其可能包含的网络活动信息。

3. 传统机器学习预测

对每个 beam 的 4 类 KPI 构建 t、t−1、t−2、t−24、t−168 共 20 维输入特征，以 t+1 为预测目标。完成了 Persistence、Linear Regression、Decision Tree、Random Forest、XGBoost 及 LightGBM 六种方法的对比；模型有效训练样本 1,448,640 条，测试样本 483,840 条。

KPI	最小 MAE（模型）	最小 RMSE（模型）	最高 R^2
DLPRB	0.261817（XGBoost）	0.493705（RF）	0.787133
DLThpVol	0.207615（RF）	0.460162（RF）	0.615323
DLThpTime	0.243576（XGBoost）	0.524467（RF）	0.702391
MR_number	0.224767（XGBoost）	0.395647（RF）	0.867182

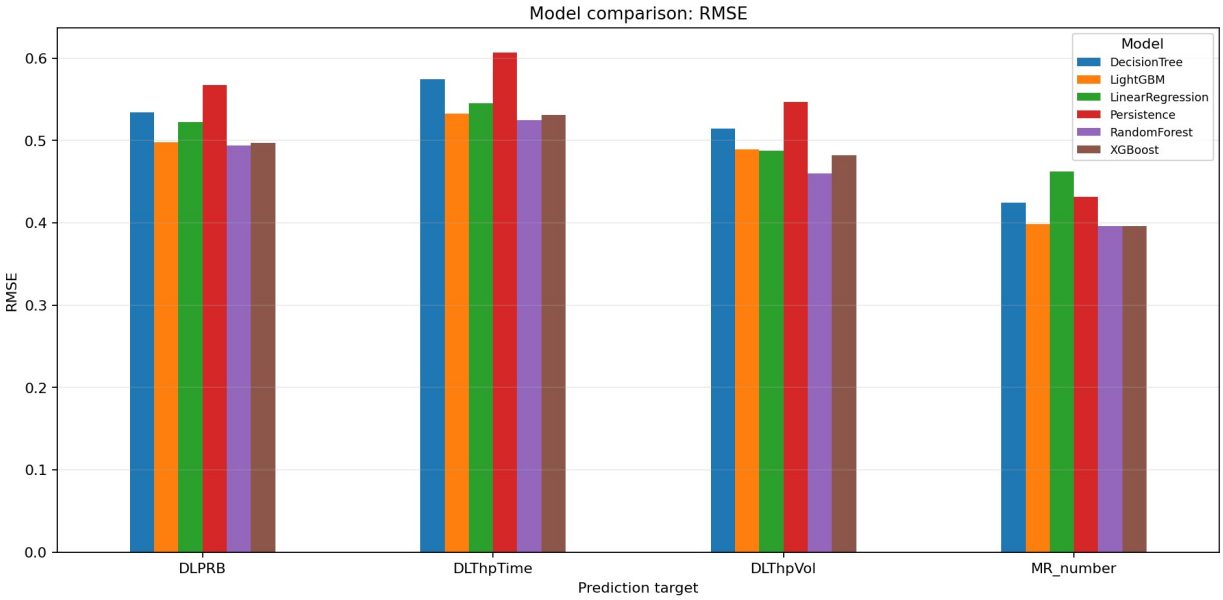


图 2 四类 KPI 的 RMSE 模型比较

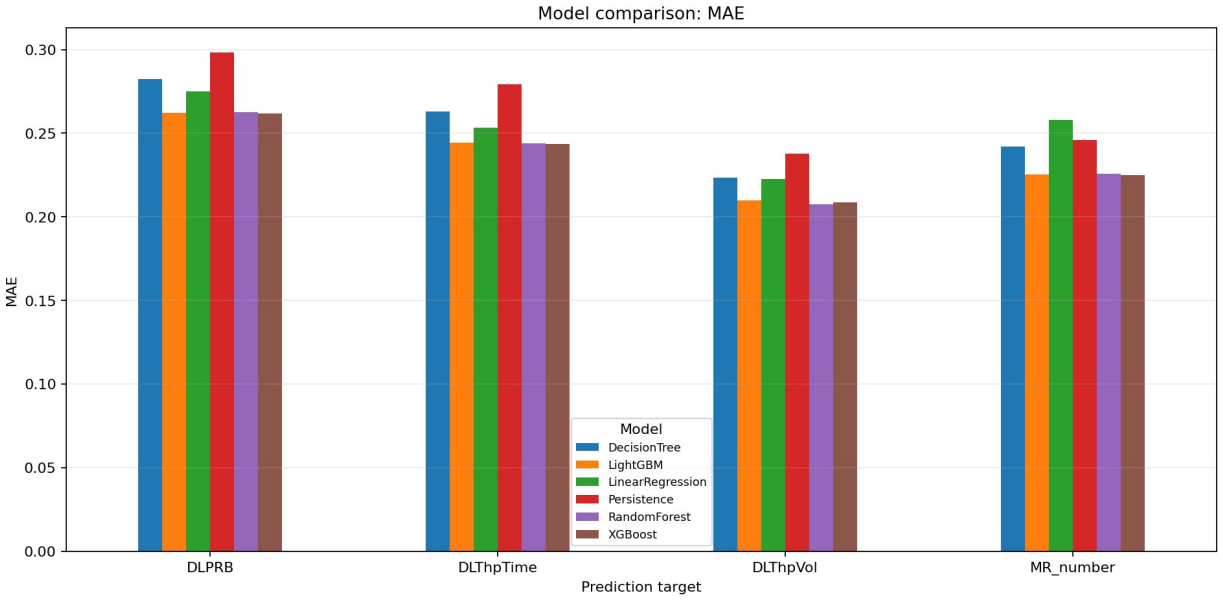


图 3 MAE 模型对比

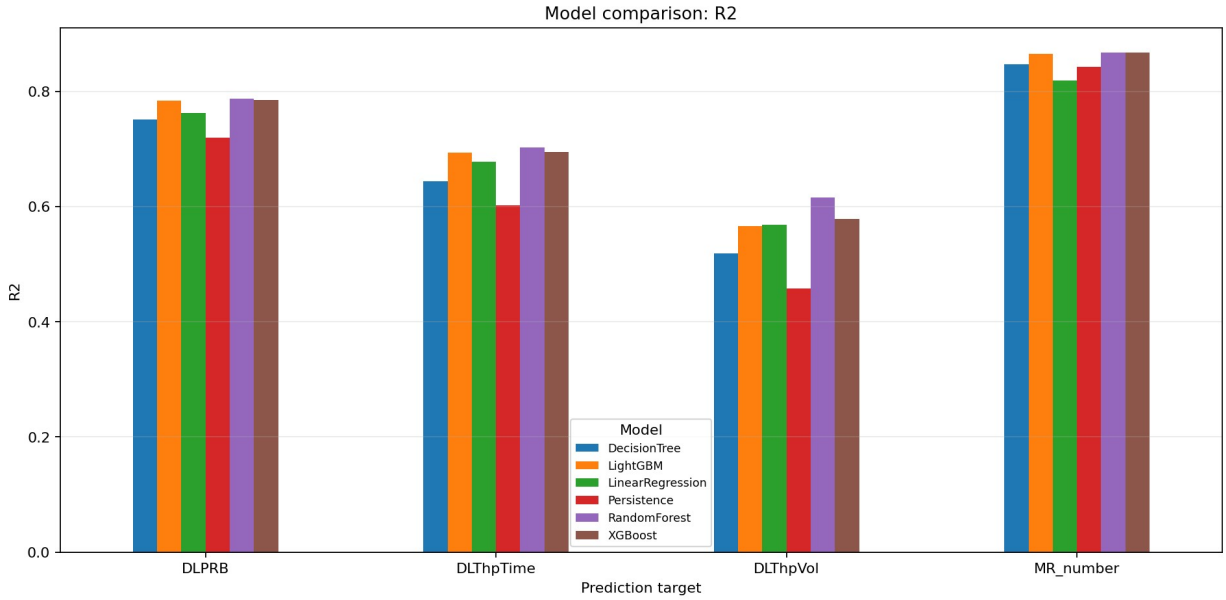


图 4 R^2 模型对比

随机森林在四类 KPI 的 RMSE 和 R^2上均为最优；XGBoost 在三类 KPI 的 MAE 上略优。MR_number 的 LinearRegression 性能比 Persistence 基线差，说明模型复杂度增加不保证效果改进。

4. 技术问题与阶段局限

（1）避免信息泄漏：数据集按时间留出，scaler 仅在基础训练期拟合；特征与标签按同一 beam 分组构造。

（2）评估口径： MAE、RMSE 和 R^2 均基于测试集中的逐 beam 样本计算；模型性能评估报告中的预测时序图则展示同一时间索引下所有 beam 的真实值与预测值均值。两者的统计粒度不同，不能直接根据聚合后的曲线判断逐 beam 预测性能。

（3）泛化边界：仅有一个来源内部的时间留出段，尚未建立滚动回测与独立外部测试，不应夸大模型部署性能。

5. 交付物核对

任务书交付物	可核对的文件
1. 数据预处理 Python 脚本	w2_data_preprocessing_download.py， w2_data_preprocessing_audit.py， w2_data_preprocessing_pipeline.py
2. 预处理 KPI 数据集	kpi_timeseries.csv
3. 数据集统计分析报告	PDF
4. 传统 ML KPI 预测模型代码	w2_traditional_ml_kpi_prediction_features.py， w2_traditional_ml_kpi_prediction_training.py
5. 模型性能评估报告	PDF
6. 预测结果可视化	图片与 prediction_timeseries.csv

脚本名称	功能说明
w2_data_preprocessing_download.py	获取四类原始 KPI 数据
w2_data_preprocessing_audit.py	审计缺失、重复、非法值及时间连续性
w2_data_preprocessing_pipeline.py	构建时间序列长表，完成数据划分、标准化和归一化
w2_traditional_ml_kpi_prediction_features.py	构造 20 维历史时序特征及下一时间步标签
w2_traditional_ml_kpi_prediction_training.py	运行六种预测方法，评估性能并输出可视化结果

6. 下一周工作

下一阶段将构建 LSTM/GRU 时序预测基线并探索 Transformer，同时开展统计阈值、Isolation Forest 和 One-Class SVM 异常检测，初步分析 KPI 之间的异常关联。跨阶段比较需使用一致的测试时段、预测标签与指标计算方式。