基于 AI 的 5G 网络关键性能指标预测与异常检测系统

深度学习模型性能评估报告

模型训练、时间回测与性能评估

项目阶段：第三阶段 | 对应任务书第 5 至 6 周

技术内容：LSTM / GRU / Transformer / 时间回测 / 配对检验

报告日期：2026 年 10 月 25 日

本报告汇总 LSTM、GRU、Transformer 三类深度学习预测器的实现、训练和评价结果，并以 GRU 的时间回测与配对检验支撑模型选型。数据采用公开 gotsf-ds 四项 KPI，共 2,419,200 行、2,880 个波束和 840 个小时索引，预测目标为同一波束的下一小时观测。

1. 模型输入与实验设置

以 t 为最后可见小时，模型读取截至 t 的连续 24×4 历史序列，拼接 t−168 的四维季节向量，联合预测 t+1 的四项 KPI，输入历史长度至少为 169 个连续小时。LSTM 和 GRU 使用单层 hidden=32 编码器；Transformer 使用线性投影、可学习位置参数和单层编码器，包含 4 个注意力头及宽度为 64 的前馈层。

表 1 三类模型的参数量与优化设置

模型	参数量	优化设置
LSTM	6,180	Adam 0.001；batch=256；最多 12 轮；patience=3
GRU	4,964	Adam 0.001；batch=256；最多 12 轮；patience=3
Transformer	10,788	Adam 0.001；batch=256；最多 12 轮；patience=3

2. GRU 正式评价协议

表 2 GRU 正式评价的时间划分

场景	训练目标	内部验证目标	外层评价目标	评价记录数
Fold1	169-335	336-383	384-479	276,480
Fold2	169-431	432-479	480-575	276,480
Fold3	169-527	528-575	576-671	276,480
留出	169-587	588-671	672-839	483,840

RF、XGBoost、GRU 在每个场景使用相同的 60,000 条训练标签，抽样种子为 42。GRU 使用 12,000 条内部验证记录进行早停，树模型采用固定参数。三折模型种子为 42，留出评价采用 42 和 43；每个外层评价窗覆盖全部 2,880 个波束。各模型的输入结构、训练设置和运行结果随实验分别归档。

每个场景的 StandardScaler 在内部验证起点之前的训练观测上拟合并冻结；留出场景使用 Time 0–587 的观测。模型依据内部验证结果选择训练轮次，外层评价按每小时可见的真实历史执行一步预测，目标为 t+1。MAE、RMSE 和 R^2 按逐条 beam-hour 记录在原始 KPI 数值尺度上计算。

3. 三类架构的实验结果

架构实验采用模型种子 42，训练 60,000 条、内部验证 12,000 条、留出测试 483,840 条；其 StandardScaler 拟合范围为 Time 0–671，内部验证时段为 588–671。表 3 汇总这组架构实验的成绩。GRU 正式评价采用第 2 节所列的训练前缀缩放协议，两组结果按各自实验条件分别归档。

表 3 架构实验留出指标 MAE 和 RMSE 为原始尺度

KPI	模型	MAE	RMSE	R^2
DLPRB	LSTM	0.2612	0.4919	0.7887
DLThpVol	LSTM	0.2205	0.4844	0.5738
DLThpTime	LSTM	0.2428	0.5251	0.7016
MR_number	LSTM	0.2260	0.3893	0.8714
DLPRB	GRU	0.2456	0.4689	0.8080
DLThpVol	GRU	0.2046	0.4967	0.5517
DLThpTime	GRU	0.2298	0.5134	0.7149
MR_number	GRU	0.2097	0.3669	0.8858
DLPRB	TRANSFORMER	0.2662	0.5201	0.7638
DLThpVol	TRANSFORMER	0.2117	0.4874	0.5685
DLThpTime	TRANSFORMER	0.2467	0.5590	0.6619
MR_number	TRANSFORMER	0.2368	0.4269	0.8454

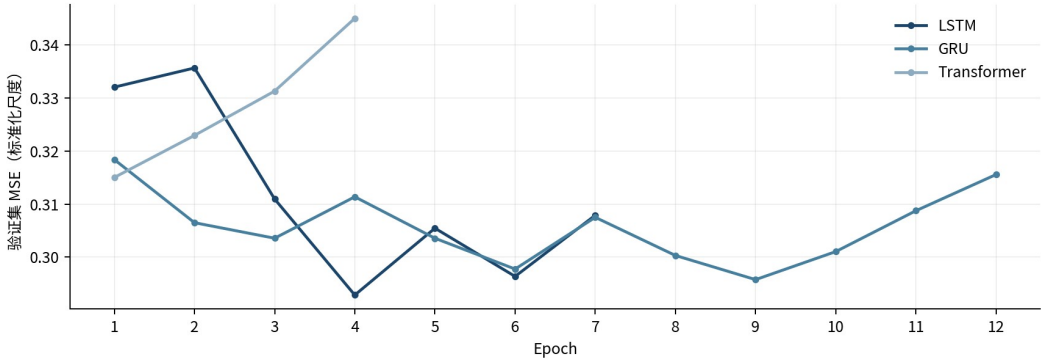


图 1 三类架构的内部验证 MSE 横轴为训练轮次 纵轴为四输出标准化 MSE
内部验证 n=12,000 seed42 数据：reports/w3_deep_learning_run_config.json

LSTM、GRU、Transformer 的最优验证轮次分别为 4、9、1，实际训练轮次分别为 7、12、4。该组架构实验中，GRU 的四项 MAE 最低，DLThpVol 的 RMSE 以 LSTM 更低，体现了不同结构在各项误差指标上的表现。

4. GRU 正式留出与回测结果

表 4 GRU 正式留出指标 Time 672–839 n=483,840 seed42

KPI	模型	MAE	RMSE	R^2
DLPRB	GRU	0.247765	0.476520	0.801694
DLThpVol	GRU	0.211055	0.498167	0.549158
DLThpTime	GRU	0.236438	0.519272	0.708258
MR_number	GRU	0.207566	0.366875	0.885797

表 5 GRU 三折回测结果 每折 n=276,480 seed42

KPI	模型	MAE 均值 ± SD	RMSE 均值 ± SD
DLPRB	GRU	0.2553 ± 0.0061	0.4756 ± 0.0077
DLThpVol	GRU	0.2287 ± 0.0127	1.0353 ± 0.3805
DLThpTime	GRU	0.2515 ± 0.0084	0.6752 ± 0.1417
MR_number	GRU	0.2121 ± 0.0028	0.3562 ± 0.0065

三折结果反映 GRU 在连续时间窗口中的预测表现。DLThpVol 的 RMSE 为 1.0353±0.3805，时段波动较大；表中 SD 表示三个评价窗口之间的标准差。模型选择同时参考平均误差、时窗波动和留出结果。

表 6 GRU 双种子留出结果 固定训练抽样与评价时段

KPI	模型	MAE 42 / 43	RMSE 42 / 43
DLPRB	GRU	0.2478 / 0.2473	0.4765 / 0.4773
DLThpVol	GRU	0.2111 / 0.2097	0.4982 / 0.5001
DLThpTime	GRU	0.2364 / 0.2277	0.5193 / 0.5122
MR_number	GRU	0.2076 / 0.2080	0.3669 / 0.3697

在本轮三模型留出比较中，GRU 的四项 MAE 均最低；DLThpVol 的 RF RMSE 为 0.478479，低于 GRU 的 0.498167。项目据此以 GRU 作为综合推荐模型，关注 DLThpVol 大误差时选用 RF。MAE 衡量平均绝对误差，RMSE 与 R^2 共同反映平方误差及拟合表现。

5. 与传统基线的配对统计检验

先计算同一波束、同一目标小时的绝对误差和平方误差，再按小时平均，形成 168 对损失。定义 d=GRU 损失−RF 损失，负值表示 GRU 损失更低。采用 Newey–West HAC、Bartlett 权重、带宽 24 和双侧正态近似。每种子的 3 对模型×4 项 KPI×2 类损失共 24 项比较统一作 Holm 校正；表中区间为逐项 95% HAC 区间。

表 7 GRU 相对 RF 的留出损失差 seed42

KPI / 损失	平均差 d	95% HAC 区间	Holm p
DLPRB / MAE	-0.018787	[-0.020485, -0.017089]	7.46e-103
DLPRB / MSE	-0.036389	[-0.040054, -0.032723]	5.21e-83
DLThpVol / MAE	-0.001853	[-0.004178, 0.000471]	0.354
DLThpVol / MSE	0.019228	[-0.006343, 0.044798]	0.354
DLThpTime / MAE	-0.011369	[-0.013218, -0.009520]	2.68e-32
DLThpTime / MSE	-0.022241	[-0.027565, -0.016918]	2.64e-15
MR_number / MAE	-0.023456	[-0.025629, -0.021282]	5.82e-98
MR_number / MSE	-0.036788	[-0.041060, -0.032516]	1.23e-62

seed42 下，GRU 相对 RF 在 DLPRB、DLThpTime、MR_number 的两类损失上均显著降低。DLThpVol 的两项 Holm 校正 p 值约为 0.354；seed43 的 MAE、MSE 校正 p 值分别为 0.01035、0.3196。两组种子固定训练抽样与评价时段，用于比较初始化变化对结果的影响。

6. 评估结论与复现材料

三类深度学习架构均已完成实现与训练，形成完整的架构实验记录。GRU 在训练前缀缩放协议下完成三折回测、双种子留出评价及跨类别配对检验，构成项目模型推荐的主要依据。评估以 gotsf-ds 数据集和本报告记录的配置为基础，按 KPI 与误差目标形成 GRU 和 RF 的选型方案。

复现材料位于项目根目录 reports/final_audit_20261025/experiments/，包括 protocol.json、runs.json、metrics.csv、walkforward_summary_flat.csv、seed_summary.csv、hourly_losses.csv、holdout_significance.csv 和 runner_used.py。现行计算模块位于 src/，实验协议与模块说明见 ARCHITECTURE.md，运行操作见 USERGUIDE.md。

架构实验底稿为 reports/w3_deep_learning_metrics.csv 和 reports/w3_deep_learning_run_config.json。模型与验证实现分别位于 src/models/architectures.py、src/models/train_deep_learning_models.py、src/analysis/final_model_validation.py。