基于 AI 的 5G 网络关键性能指标预测与异常检测系统

深度学习模型性能评估报告

LSTM、GRU 与 Transformer 的下一小时多变量 KPI 预测

数据集：gotsf-ds / netop/gotsf-ds
评估对象：4 类 KPI × 3 种深度学习模型
实验环境：Python / PyTorch / scikit-learn / CPU

1. 实验目的与数据基础

本实验以第二阶段构建的 gotsf-ds 时序数据为输入，实现 LSTM、GRU 与轻量 Transformer 的多变量下一小时 KPI 预测，统一评估其预测误差及模型行为，为传统机器学习与深度学习模型的后续比较提供证据。

项目	规模或设置	说明
时间索引	0–839	每个时间索引按 1 小时处理
空间对象	2880 beam	30 个基站、90 个 cell
预测对象	DLPRB / DLThpVol / DLThpTime / MR_number	四个 KPI 联合输出
数据基础	2,419,200 行 × 17 列	预处理后长表 kpi_timeseries.csv
测试范围	Time 672–839	168 小时 × 2880 beam = 483,840 条

2. 深度学习模型结构与训练设置

三个模型均使用当前目标时刻之前连续 24 小时的四维标准化 KPI 序列，并补充 t−168 小时对应的四维历史输入，经共享预测头输出下一小时的四类 KPI。LSTM、GRU 通过循环结构提取序列状态；Transformer 使用线性嵌入、位置参数和单层编码器提取时序特征。

项目	配置	说明
输入窗口	24 小时 + t−168 特征	不使用目标小时自身信息
训练 / 验证 / 测试目标时段	169–587 / 588–671 / 672–839	按目标时间顺序切分
抽样规模	训练 60,000 / 验证 12,000	测试全量 483,840
优化配置	Adam，lr=0.001	batch size=256；最大 12 epoch
网络规模	LSTM 6,180 / GRU 4,964 / Transformer 10,788 参数	hidden=32；固定随机种子 42
硬件	CPU	源自实际运行配置文件

3. 评价指标与统一口径

采用 MAE、RMSE 和 R^2 评价每个 beam × 目标小时的预测。MAE 表示平均绝对误差；RMSE 对较大误差更加敏感；R^2 衡量模型相对均值预测的拟合程度。神经网络在标准化尺度训练，最终将预测反变换回原始 KPI 数值尺度计算指标。

4. 模型预测性能

KPI	模型	MAE	RMSE	R^2
DLPRB	LSTM	0.2612	0.4919	0.7887
DLPRB	GRU	0.2456	0.4689	0.8080
DLPRB	Transformer	0.2662	0.5201	0.7638
DLThpVol	LSTM	0.2205	0.4844	0.5738
DLThpVol	GRU	0.2046	0.4967	0.5517
DLThpVol	Transformer	0.2117	0.4874	0.5685
DLThpTime	LSTM	0.2428	0.5251	0.7016
DLThpTime	GRU	0.2298	0.5134	0.7149
DLThpTime	Transformer	0.2467	0.5590	0.6619
MR_number	LSTM	0.2260	0.3893	0.8714
MR_number	GRU	0.2097	0.3669	0.8858
MR_number	Transformer	0.2368	0.4269	0.8454

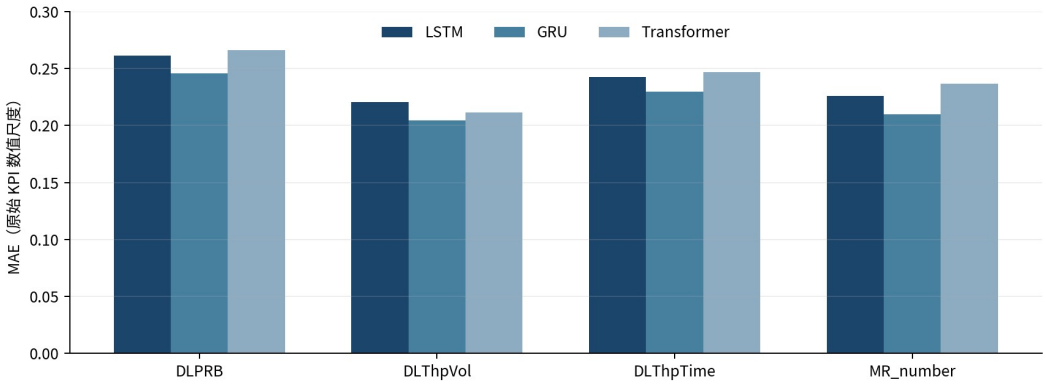


图 1 三种深度学习模型在四类 KPI 上的 MAE 对比

从 MAE 看，GRU 在四种 KPI 上均取得最低值：DLPRB 为 0.2456，DLThpVol 为 0.2046，DLThpTime 为 0.2298，MR_number 为 0.2097。对于 DLPRB、DLThpTime 和 MR_number，GRU 亦取得最小 RMSE 与最高 R^2。

5. 训练收敛与差异分析

模型	最佳验证 Epoch	最佳验证 MSE	实际训练 Epoch	参数量
LSTM	4	0.29283	7	6,180
GRU	9	0.29574	12	4,964
Transformer	1	0.31503	4	10,788

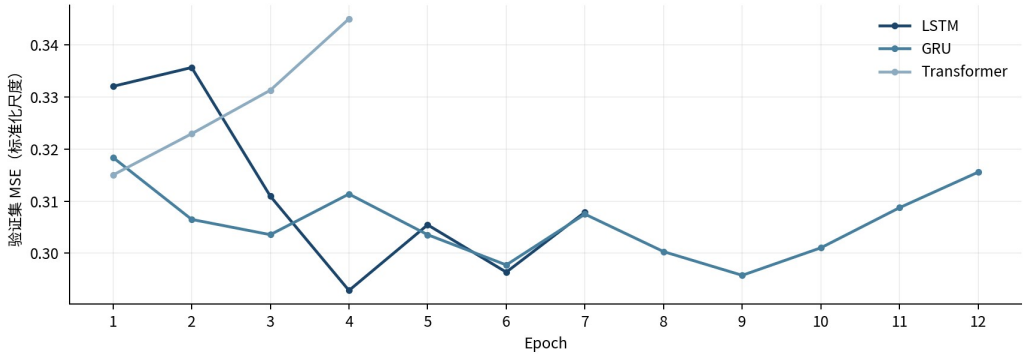


图 2 三种模型的验证集 MSE 变化（标准化数值尺度）

LSTM 在第 4 轮得到最低验证损失，之后因验证指标未继续改善而早停；GRU 在第 9 轮取得其最优验证值，第 12 轮结束；轻量 Transformer 在第 1 轮达到最优验证值，其后损失上升，第 4 轮结束。

DLThpVol 的结果具有差异性：GRU 的 MAE 最低（0.2046），但其 RMSE 为 0.4967，高于 LSTM 的 0.4844，且 R^2 低于 LSTM。这提示 GRU 的典型绝对误差较小，但平方误差受到相对较大偏差的影响；该解释仍需逐样本误差分布验证。

6. 实验限制与后续改进

本轮实验只使用单次随机种子和一组轻量模型参数；训练与验证样本为随机抽样，测试集为完整留出期。数据来源于原始文件名称含 train 的时间区间内部切分，而非独立官方测试文件。此外，上一阶段保存的 StandardScaler 在 Time 0–671 上拟合，其中包含内部验证时段 588–671，因而验证环节存在预处理统计信息覆盖的问题；尽管留出测试期未参与缩放器拟合，后续仍应使用仅基于训练子段拟合的 scaler 复核。

7. 训练配置、模型容量与可复现性补充

为明确模型输入、调参与模型选型依据，以下配置依据实际运行记录 w3_deep_learning_run_config.json 及 w3_dl_prediction.py 整理。

项目	运行设置	说明
模型输入	连续 24 个时间点 × 4 KPI	形状 [24,4]；均为历史观测
季节性补充	额外 4 维 t−168 对应观测	与序列编码后特征拼接
模型输出	同时预测 4 种 KPI 的下一小时值	多输出回归；损失为标准化 MSE
数据划分	训练 169–587；验证 588–671；测试 672–839	按目标时刻，顺序切分
训练样本	训练随机抽样 60,000；验证 12,000	测试全量 483,840 beam-hour
优化设置	Adam，学习率 0.001，batch 256	最多 12 Epoch；patience=3
实验环境与复现	CPU，seed=42	指标转换回原始 KPI 数值尺度

LSTM 与 GRU 均使用单层循环编码器、隐藏宽度 32；Transformer 为线性投影 + 可学习位置参数 + 单层编码器（4 个注意力头，前馈宽度 64）。三者使用相同的预测头思路，但参数量不同，故本实验不能视为控制模型容量的架构消融。

模型	参数量	最优轮次	最优验证 MSE	实际训练轮次
LSTM	6,180	4	0.292830	7
GRU	4,964	9	0.295743	12
Transformer	10,788	1	0.315027	4

7.1 结果解释与后续验证边界

GRU 的四项 MAE 最优是当前单一留出测试期上的观察结果，并非经统计显著性检验的结论。仅使用单个随机种子、有限训练窗口和一组候选参数，尚未进行深度学习模型的滚动重训或重复种子实验。

预处理 StandardScaler 曾在 Time 0–671 拟合，其中包含内部验证期 588–671；虽然未接触留出测试期，仍应在后续严格验证中改为按训练子段或验证折单独拟合缩放器。建议继续记录每组随机种子、每折 MAE/RMSE/R^2、训练时长，并开展基于小时级配对误差的统计检验。

8. 结论与证据文件

本阶段实现并运行 LSTM、GRU、Transformer 三类多变量 KPI 预测模型，获得 12 组完整测试指标。GRU 在当前设置下取得四类 KPI 的最低 MAE，轻量 Transformer 整体表现落后。模型结果可作为下一步模型选型与异常检测模块的预测基础，但不应将当前结果解释为深度学习模型的一般性优势。