基于 AI 的 5G 网络关键性能指标预测与异常检测系统

传统 ML 与 DL 模型对比分析

传统机器学习基线与 LSTM、GRU、Transformer 的统一测试对比

数据集：gotsf-ds / 4 类 beam-level KPI
对比模型：Persistence、LR、DT、RF、XGBoost、LightGBM / LSTM、GRU、Transformer
评价指标：MAE / RMSE / R^2

1. 分析目的与评价方法

本分析将第二阶段的传统机器学习结果作为基线，与第三阶段 LSTM、GRU、Transformer 的下一小时 KPI 预测结果作并列对比。比较在同一留出测试时段 Time 672–839、同样的 2880 beam 和原始 KPI 数值尺度下开展，关注误差、解释能力与不同模型之间的性能取舍。

比较维度	传统 ML	深度学习
模型	Persistence、LR、DT、RF、XGBoost、LightGBM	LSTM、GRU、Transformer
输入特征	四种 KPI × （t,t−1,t−2,t−24,t−168）	24 小时连续序列 + t−168 特征
训练样本	1,448,640 行	抽样 60,000 窗口；另有验证 12,000
测试时段与规模	672–839；483,840 条	672–839；483,840 条
指标	MAE、RMSE、R^2	MAE、RMSE、R^2

报告中的“ML 最优”和“DL 最优”分别在各自模型组内、按每种 KPI 的对应指标选取。不同 KPI 的绝对误差不直接求和排序，误差改善率按（ML 最优误差−DL 最优误差）/ ML 最优误差计算；R^2 比较采用差值。

2. 最优模型对比结果

KPI	指标	ML 最优	DL 最优	DL 相对变化
DLPRB	MAE	XGBoost 0.2618	GRU 0.2456	+6.19%
DLPRB	RMSE	RandomForest 0.4937	GRU 0.4689	+5.03%
DLPRB	R^2	RandomForest 0.7871	GRU 0.8080	+0.0209
DLThpVol	MAE	RandomForest 0.2076	GRU 0.2046	+1.46%
DLThpVol	RMSE	RandomForest 0.4602	LSTM 0.4844	-5.26%
DLThpVol	R^2	RandomForest 0.6153	LSTM 0.5738	-0.0416
DLThpTime	MAE	XGBoost 0.2436	GRU 0.2298	+5.66%
DLThpTime	RMSE	RandomForest 0.5245	GRU 0.5134	+2.12%
DLThpTime	R^2	RandomForest 0.7024	GRU 0.7149	+0.0125
MR_number	MAE	XGBoost 0.2248	GRU 0.2097	+6.71%
MR_number	RMSE	RandomForest	GRU 0.3669	+7.27%

KPI	指标	ML 最优	DL 最优	DL 相对变化
MR_number	R^2	0.3956 RandomForest 0.8672	GRU 0.8858	+0.0186

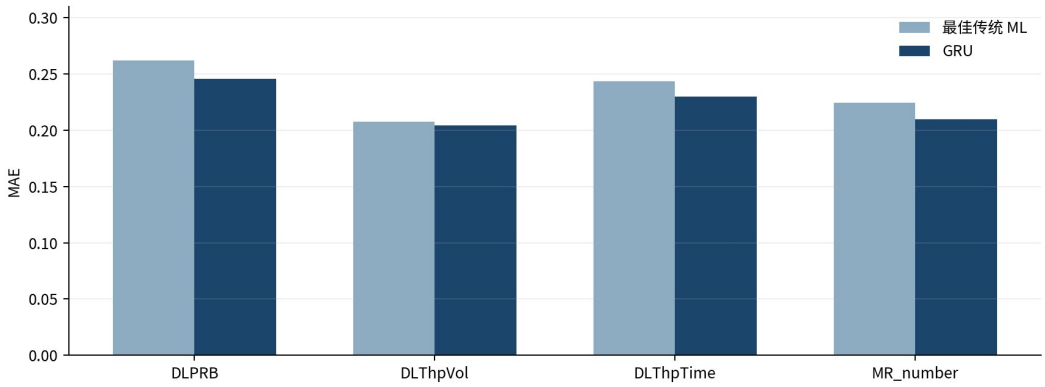


图 1 四类 KPI 的最佳传统 ML 与 GRU 测试 MAE 比较

3. 性能差异与结果解释

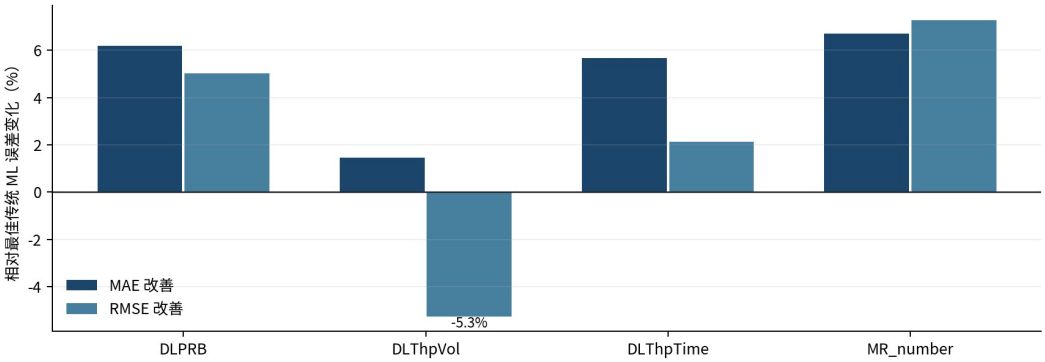


图 2 深度学习最佳误差相对传统 ML 最佳误差的变化（负值表示退步）

在四类 KPI 的 MAE 指标上，GRU 均优于传统机器学习组内最佳模型：DLPRB 改善 6.19%，DLThpVol 改善 1.46%，DLThpTime 改善 5.66%，MR_number 改善 6.71%。对于 DLPRB、DLThpTime 与 MR_number，GRU 的 RMSE 亦较传统 ML 最优结果有所降低，R^2 同时增加。

DLThpVol 则展示了相反证据：深度学习组内 RMSE 最好的 LSTM 为 0.4844，仍高于 RandomForest 的 0.4602，意味着其最优深度学习 RMSE 相比传统 ML 增加约 5.26%；对应 R^2 由 0.6153 降至 0.5738。不能仅根据四项 MAE 改善便称深度学习全面优于传统方法。

4. 模型选择的工程考虑

评价角度	当前证据	实际含义
优先降低典型绝对误差	GRU 的四种 KPI MAE 均为最低	可作为后续预测模块的优先候选

评价角度	当前证据	实际含义
关注大误差及流量尖峰	DLThpVol 的 RF RMSE 优于所有 DL 模型	需保留传统 ML 作为强基线
训练复杂度	DL 本轮在 CPU 上训练；未做等算力计时比较	不能推定部署性能或训练成本优劣
模型稳定性	传统 ML 有历史滚动验证；DL 尚未同协议回测	当前只支持单次留出期结论

5. 可比性限制与进一步验证

虽然预测目标、测试时间与评价尺度相同，但传统 ML 使用约 144.86 万条训练样本及手工滞后特征，深度学习仅抽样训练 6 万个序列窗口、使用额外 24 小时连续历史输入，并通过内部验证早停。二者并非“相同训练数据与计算预算”的受控对比。当前结果仅说明现有实现及配置在该留出集上的实际表现。

建议在进一步实验中统一训练数据覆盖范围、固定多组随机种子，按目标时间滚动回测，并增加每时段误差分析、极端误差分位数和模型推理开销。对于 DLThpVol 尤其应区分一般时段和高变化时段的误差贡献。

6. 传统机器学习基线的综合排序与稳健性证据

第二阶段已经在同一留出测试集上按每个 KPI 分别计算 MAE、RMSE 与 R^2；先对传统学习模型在各 KPI、各指标内排名，再对 12 个名次等权平均，得到下表。此排名为描述性综合名次，并非统计检验，也不直接对不同 KPI 的误差绝对值求平均。

综合排名	传统 ML 模型	MAE 均名次	RMSE 均名次	R^2均名次	等权综合
1	Random Forest	2.25	1.00	1.00	1.417
2	XGBoost	1.25	2.00	2.00	1.750
3	LightGBM	2.50	3.25	3.25	3.000
4	Linear Regression	4.25	4.00	4.00	4.083
5	Decision Tree	4.75	4.75	4.75	4.750

因此，在既定等权评价标准下，Random Forest 是传统 ML 的综合最优基线；XGBoost 在 MAE 维度有相对优势。该结论仅适用于已记录的模型配置和测试期。

6.1 三折扩展窗口交叉验证（滚动起点回测）

折次	模型训练目标时刻	验证目标时刻	验证窗口
Fold 1	169–383	384–479	96 小时
Fold 2	169–479	480–575	96 小时
Fold 3	169–575	576–671	96 小时

每折只使用验证窗口之前的数据拟合模型，并在该折训练样本上重新拟合 StandardScaler。最终测试段 672–839 未参与三折验证；交叉验证和滚动回测在此指同一套扩展窗口时序实验。仓库已有 24 组模型×KPI 的三折均值和标准差（validation/walkforward_summary.csv），未对深度学习模型执行同样的三折回测。

6.2 显著性检验的适用范围

传统模型内部已对 Random Forest、XGBoost 和 LightGBM 的每小时平均绝对/平方损失进行配对 Newey–West HAC 检验（带宽 24），再以 Holm 方法校正多重比较。例如在 DLPRB 上，XGBoost 的 MAE 相对 RF 更低（Holm $p \approx 5.23\times10^{-6}$），而 RF 的平方损失更小（Holm $p \approx 0.0235$）。这些结论反映误差目标不同会改变优劣关系。

上述显著性检验仅覆盖传统模型之间的比较；目前并无“GRU 相对 Random Forest / XGBoost 的显著性”分析。因此，深度学习取得的测试集 MAE 改善应表述为描述性效果，不应写成已通过显著性检验。

6.3 超参数优化记录及比较限制

当前传统 ML 主表使用固定候选参数；后续单独对 DLPRB 的 Random Forest 运行过 Optuna TPE 12 次试验、抽样 256 个 beam，在三折验证上筛选出 n_estimators=137、max_depth=13、min_samples_leaf=9、max_features=sqrt、max_samples≈0.6981，最佳交叉验证 RMSE≈0.473700。该最佳参数尚未替换原主实验模型，也不能将此搜索记录扩展表述为全部传统模型均已自动调参。

考虑到深度学习仅使用 60,000 个随机训练窗口，而传统模型使用 1,448,640 条训练行，且二者特征表示与模型容量不同，建议第四阶段保留两套可切换后端，并在统一训练预算、多种种子和更严格预处理折内拟合的条件下再次比较。

7. 结论与可复现材料

基于留出测试集，GRU 是目前四种 KPI 的 MAE 最优模型，但随机森林在 DLThpVol 的 RMSE、R^2 上更好。因而当前更合理的系统设计是保留可切换的预测后端，以 GRU 作为首选候选，同时维护 RF / XGBoost 基线用于稳健性验证。