基于 AI 的 5G 网络关键性能指标预测与异常检测系统

传统机器学习与深度学习模型对比分析

统一实验协议与 KPI 预测模型选型

项目阶段：第三阶段 | 对应任务书第 5 至 6 周

技术内容：Random Forest / XGBoost / GRU / 时间回测 / 统计检验

报告日期：2026 年 10 月 25 日

本报告基于统一训练标签与时间划分，比较 RF、XGBoost、GRU 的预测性能并形成模型选择方案。MAE 为主要选型指标，RMSE 用于评价大误差表现，R^2 辅助说明拟合程度。LSTM、Transformer 及其他传统算法的架构和探索结果分别保存在对应阶段的指标文件中。

1. 输入与固定模型配置

树模型按四项 KPI 分别取 t、t−1、t−2、t−24、t−168 的观测，形成 4×5=20 维输入，每项 KPI 独立拟合。GRU 使用连续 24×4 历史序列及四维季节向量，联合输出四项 KPI。base_station、cell、beam 用于记录对齐。

表 1 三模型的输入输出与固定参数

模型	输入 / 输出	固定配置
RandomForest	20 维 / 单 KPI	30 棵树，深度 16，叶样本 20，max_features=sqrt，max_samples=0.6
XGBoost	20 维 / 单 KPI	250 轮，深度 8，lr=0.05，subsample=0.8，colsample_bytree=0.8
GRU	24×4 序列+4 维季节向量 / 四 KPI	hidden=32，Adam lr=0.001，batch=256，最多 12 轮，patience=3，CPU 4 线程

2. 时间划分与标准化

表 2 正式比较的时间划分

场景	训练目标	内部验证目标	外层评价目标	评价记录数
Fold1	169-335	336-383	384-479	276,480
Fold2	169-431	432-479	480-575	276,480
Fold3	169-527	528-575	576-671	276,480
留出	169-587	588-671	672-839	483,840

RF、XGBoost、GRU 在每个场景使用相同的 60,000 条训练标签，抽样种子为 42。GRU 使用 12,000 条内部验证记录进行早停，树模型采用固定参数。三折模型种子为 42，留出评价采用 42 和 43；每个外层评价窗覆盖全部 2,880 个波束。各模型的输入结构、训练设置和运行结果随实验分别归档。

每个场景的 StandardScaler 在内部验证起点之前的训练观测上拟合并冻结；留出场景使用 Time 0–587 的观测。模型依据内部验证结果选择训练轮次，外层评价按每小时可见的真实历史执行一步预测，目标为 t+1。MAE、RMSE 和 R^2 按逐条 beam-hour 记录在原始 KPI 数值尺度上计算。

3. 留出性能与模型选择

表 3 三模型留出指标 Time 672–839 n=483,840 seed42

KPI	模型	MAE	RMSE	R^2
DLPRB	RandomForest	0.266552	0.513284	0.769915
DLPRB	XGBoost	0.268472	0.518092	0.765584
DLPRB	GRU	0.247765	0.476520	0.801694
DLThpVol	RandomForest	0.212908	0.478479	0.584089
DLThpVol	XGBoost	0.220221	0.559090	0.432144
DLThpVol	GRU	0.211055	0.498167	0.549158
DLThpTime	RandomForest	0.247807	0.540264	0.684194
DLThpTime	XGBoost	0.251333	0.581392	0.634282
DLThpTime	GRU	0.236438	0.519272	0.708258
MR_number	RandomForest	0.231022	0.413987	0.854584
MR_number	XGBoost	0.231131	0.416529	0.852792
MR_number	GRU	0.207566	0.366875	0.885797

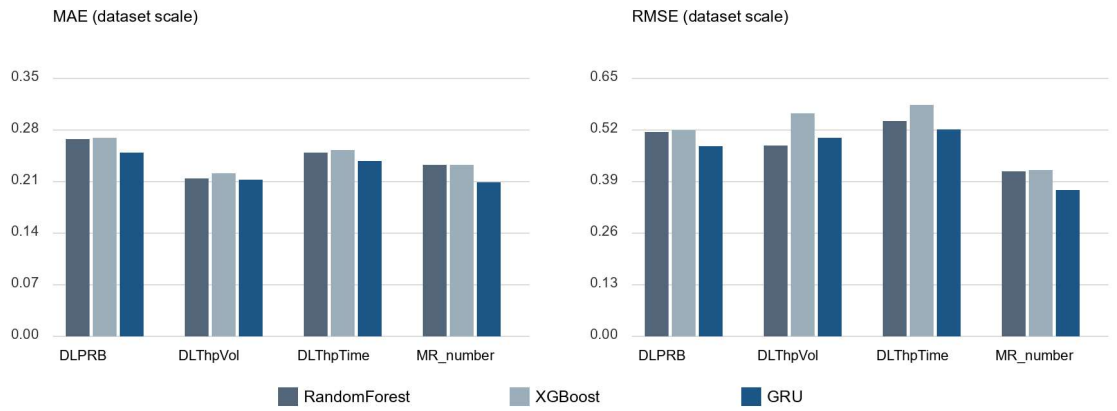


图 1 三模型留出 MAE 与 RMSE 横轴为 KPI 纵轴为原始尺度误差
逐条 beam-hour 评价 Time 672–839 n=483,840 seed42
数据来源：reports/final_audit_20261025/experiments/metrics.csv

在本轮三模型留出比较中，GRU 的四项 MAE 均最低；DLThpVol 的 RF RMSE 为 0.478479，低于 GRU 的 0.498167。项目据此以 GRU 作为综合推荐模型，关注 DLThpVol 大误差时选用 RF。MAE 衡量平均绝对误差，RMSE 与 R^2 共同反映平方误差及拟合表现。

4. 时间回测与随机种子

表 4 三折扩展窗口回测 均值 ± 折间标准差 每折 n=276,480

KPI	模型	MAE 均值 ± SD	RMSE 均值 ± SD
DLPRB	RandomForest	0.2695 ± 0.0029	0.5161 ± 0.0107
DLPRB	XGBoost	0.2715 ± 0.0034	0.5237 ± 0.0112
DLPRB	GRU	0.2553 ± 0.0061	0.4756 ± 0.0077
DLThpVol	RandomForest	0.2381 ± 0.0152	1.0875 ± 0.3967
DLThpVol	XGBoost	0.2440 ± 0.0137	1.1110 ± 0.3230
DLThpVol	GRU	0.2287 ± 0.0127	1.0353 ± 0.3805
DLThpTime	RandomForest	0.2628 ± 0.0125	0.7271 ± 0.1729
DLThpTime	XGBoost	0.2659 ± 0.0125	0.7259 ± 0.1452
DLThpTime	GRU	0.2515 ± 0.0084	0.6752 ± 0.1417
MR_number	RandomForest	0.2294 ± 0.0016	0.4069 ± 0.0029
MR_number	XGBoost	0.2291 ± 0.0021	0.4097 ± 0.0054
MR_number	GRU	0.2121 ± 0.0028	0.3562 ± 0.0065

GRU 的四项 MAE 和 RMSE 三折均值均低于本轮 RF、XGBoost。DLThpVol 的 GRU RMSE 折间标准差为 0.3805，反映不同时间窗口的误差波动。项目将三折均值、时段波动及留出指标共同用于模型选择。

表 5 GRU 双种子留出 MAE 与 RMSE

KPI	模型	MAE 42 / 43	RMSE 42 / 43
DLPRB	GRU	0.2478 / 0.2473	0.4765 / 0.4773
DLThpVol	GRU	0.2111 / 0.2097	0.4982 / 0.5001
DLThpTime	GRU	0.2364 / 0.2277	0.5193 / 0.5122
MR_number	GRU	0.2076 / 0.2080	0.3669 / 0.3697

两组种子下，GRU 的四项 MAE 均最低，RF 的 DLThpVol RMSE 最低，seed42 和 seed43 分别为 0.478479、0.4779。两次实验固定训练抽样与评价时段，对比模型初始化变化。三模型完整双种子结果见 experiments/metrics.csv 和 seed_summary.csv。

5. 配对损失与统计显著性

先计算同一波束、同一目标小时的绝对误差和平方误差，再按小时平均，形成 168 对损失。定义 d=GRU 损失−RF 损失，负值表示 GRU 损失更低。采用 Newey–West HAC、Bartlett 权重、带宽 24 和双侧正态近似。每种子的 3 对模型×4 项 KPI×2 类损失共 24 项比较统一作 Holm 校正；表中区间为逐项 95% HAC 区间。

表 6 GRU 相对 RF 的留出配对检验 seed42

KPI / 损失	平均差 d	95% HAC 区间	Holm p
DLPRB / MAE	-0.018787	[-0.020485, -0.017089]	7.46e-103
DLPRB / MSE	-0.036389	[-0.040054, -0.032723]	5.21e-83
DLThpVol / MAE	-0.001853	[-0.004178, 0.000471]	0.354
DLThpVol / MSE	0.019228	[-0.006343, 0.044798]	0.354
DLThpTime / MAE	-0.011369	[-0.013218, -0.009520]	2.68e-32
DLThpTime / MSE	-0.022241	[-0.027565, -0.016918]	2.64e-15
MR_number / MAE	-0.023456	[-0.025629, -0.021282]	5.82e-98
MR_number / MSE	-0.036788	[-0.041060, -0.032516]	1.23e-62

seed42 下，GRU 相对 RF 在 DLPRB、DLThpTime、MR_number 的两类损失上均显著降低。DLThpVol 的两项 Holm 校正 p 值约为 0.354；seed43 的 MAE、MSE 校正 p 值分别为 0.01035、0.3196。两组种子固定训练抽样与评价时段，用于比较初始化变化对结果的影响。

完整 48 项留出检验覆盖两个种子及三对模型。seed42 下，GRU 相对 XGBoost 的四项 KPI、两类损失均显著降低；RF 与 XGBoost 在 MR_number 上的 MAE、MSE 校正 p 值分别约为 0.8312、0.2778。各项效应差、区间及校正 p 值均随结果归档。

6. 超参数搜索与选型结论

正式比较采用表 1 的固定参数。针对 DLPRB 的 RF，另完成 Optuna TPE 12 次搜索，并在 256 个波束上进行三折验证。搜索范围为树数 40–160、深度 8–24、叶样本 5–50、max_features∈{sqrt,0.7,1.0}、max_samples 0.5–0.9；最优配置依次为 137、13、9、sqrt、0.698071，CV RMSE=0.473700。优化配置和搜索结果作为独立研究记录保存，便于与正式配置对照。

项目依据误差目标选择 GRU 或 RF。正式 RF/XGBoost/GRU 比较采用相同的 60,000 条训练标签及训练前缀标准化。历史传统模型使用约 144.86 万条训练记录，LSTM、Transformer 的架构实验使用各自记录的缩放设置；各组实验的输入表示、训练配置和指标分别归档。

复现材料位于项目根目录 reports/final_audit_20261025/experiments/，包括 protocol.json、runs.json、metrics.csv、walkforward_summary_flat.csv、seed_summary.csv、hourly_losses.csv、holdout_significance.csv 和 runner_used.py。现行计算模块位于 src/，实验协议与模块说明见 ARCHITECTURE.md，运行操作见 USERGUIDE.md。