基于 AI 的 5G 网络关键性能指标预测与异常检测系统

完整项目技术报告

5G SA 仿真 · KPI 时序预测 · 异常检测与初步根因分析

实验平台：free5GC v4.2.3 / UERANSIM v3.3.0 / Ubuntu 22.04

数据基础：gotsf-ds / 2,880 beam / 4 类 KPI

技术方法：传统 ML / LSTM / GRU / Transformer / Isolation Forest

报告日期 2026 年 10 月 25 日

摘要

本项目构建了覆盖 5G SA 通信链路验证、公开 KPI 时序预测、无监督异常筛查及 Web 推理的工程系统。free5GC 与 UERANSIM 完成 UE 注册、PDU Session 配置和 N3 用户面转发验证；KPI 建模采用独立的 gotsf-ds 公开数据，覆盖 30 个基站、2,880 个 beam、840 个小时索引及四类指标。

RF、XGBoost 与 GRU 在相同 60,000 条训练标签、相同目标时段及逐折训练前缀标准化协议下完成三折扩展窗口评估和留出评估。seed42 的 483,840 条留出观测中，GRU 的 DLPRB、DLThpVol、DLThpTime、MR_number MAE 分别为 0.247765、0.211055、0.236438、0.207566，均低于两个树模型；DLThpVol 的 RMSE 则以 RF 的 0.478479 更优。配对小时损失经 HAC 与 Holm 校正后，GRU 相对 RF 在其余三项 KPI 的两类损失上均显著降低。默认按 MAE 选择 GRU，对 DLThpVol 的大误差控制保留 RF。[R19,R20]

异常检测采用 IF AND（3σ OR IQR），在 483,840 条观测中筛得 3,165 条候选，占 0.654%。分布诊断、逻辑组合和站级聚类关联分析为人工排查提供依据；候选率不代表故障率。Streamlit 已集成六个页面， 58 项自动测试通过，六页 AppTest 无异常，正式模型回载及 CSV 导出通过。[R14–R18,R21]

关键词：5G SA；KPI 预测；GRU；随机森林；异常检测；系统验收

1 项目背景与总体要求

1.1 项目背景与技术目标

随着网络规模、并发业务量和无线资源负载变化增加，仅依赖人工检查历史 KPI 及收到告警后定位问题，难以实现高频率、可扩展的趋势监测。项目要求围绕真实公开数据与开源 5G 仿真环境，建立从协议理解到 KPI 建模，再到异常筛查和 Web 展示的完整开发链条。[R1]

本项目采用两条数据与证据链：其一为 free5GC + UERANSIM 的仿真网络链路，用于验证 5G 控制面和用户面流程；其二为公开 beam 级 KPI 时间序列，用于离线模型训练、留出期评估及异常候选筛查。

1.2 关键定义与评价边界

KPI 指关键性能指标；beam-hour 指一个 beam 在一个小时索引下的一条观测。预测目标为下一小时。MAE、RMSE 按数据集原始数值尺度、R^2 按无量纲指标计算；数据未给出可核验的物理单位，不换算为 Mbps 或百分比。异常候选用于筛查，尚无故障工单真值。

2 实验平台与 5G SA 通信链路

2.1 开发与仿真环境分离

初期在 Windows 下部署 WSL2 Ubuntu 22.04，配置 Python、Git、Docker 与常用网络工具。部署过程中发现 WSL2 使用 Microsoft 定制 Linux 内核且缺少当前内核对应的标准构建目录，无法直接满足 free5GC 用户面 gtp5g 内核模块的既定实验条件。项目因此保留 WSL2 作为数据处理和 AI 开发环境，另以 VirtualBox Ubuntu 22.04 运行核心网及 gNB/UE 仿真。[R2,R3]

表 1 实验环境与地址参数

组成	配置与用途
WSL2 开发侧	Ubuntu 22.04；Python / Pandas / scikit-learn / PyTorch 等
free5GC 虚拟机	Ubuntu 22.04；192.168.56.101；AMF、SMF、UPF、MongoDB、gtp5g
UERANSIM 虚拟机	Ubuntu 22.04；192.168.56.102；nr-gnb / nr-ue
VM 网络	网卡 1 NAT 出网；网卡 2 Host-Only 承载实验 N2/N3
UE 用户面	PDU Session 建立后 uesimtun0=10.60.0.1
抓包分析	tcpdump on enp0s8；Wireshark 3.6.2 离线分析

2.2 5G 核心网功能与协议关系

5G SA 场景中，UE 经 gNodeB 接入 5GC。AMF 执行接入与移动性控制，SMF 管理 PDU Session，UPF 转发用户数据；N1 是 UE 与 AMF 的逻辑控制接口，N2 承载 gNB 与 AMF 间 NGAP 控制信令，N3 则采用 GTP-U 承载 gNB 与 UPF 间的实际用户面数据。[R4,R6]

2.3 端到端链路及实际报文证据

在 WebConsole 中完成与 UE 配置一致的 Subscriber 参数，随后依次启动 5GC、gNB 与 UE。UE 生成 uesimtun0 并获得 10.60.0.1，实际以该接口向外部目标发起 ping，可收到 ICMP Echo Reply，时延约 10–12 ms。该结果表明测试场景下 UE→gNB→UPF→NAT→外网 的基本用户面链路成立。[R2,R3]

表 2 关键控制信令与用户面报文 [R4,R5]

Frame	协议或消息	对应结论
560–563	SCTP INIT / INIT_ACK / COOKIE 交互	N2 传输关联建立
564 / 566	NGSetupRequest / Response	NG 接口初始化成功
604	InitialUEMessage / 明文 NAS 注册请求	UE 发起注册
605 / 606	Authentication Request / Response	5G AKA 认证交互可见
607 / 608	Security Mode Command / 受保护 NAS	后续 NAS 完整性保护及加密生效
610 / 611	Initial Context Setup / Response	UE 接入侧上下文建立
617 / 618	PDU Session Resource Setup / Response	N3 隧道端点参数协商
646 / 647	GTP-U T-PDU 承载 ICMP Request / Reply	用户面双向传输

Frame 617 中，UPF 侧 N3 Transport Layer Address=192.168.56.101，UL GTP-TEID=0x00000002；Frame 618 返回 gNB 侧地址 192.168.56.102 和 GTP-TEID=0x00000001。Frame 646 的外层地址为 192.168.56.102→192.168.56.101，UDP/2152，GTP-U TEID=0x00000002，内层 IP 流为 10.60.0.1→8.8.8.8；该 TEID 与控制面配置一致，构成了控制与数据路径的一致性证据。[R4,R5]

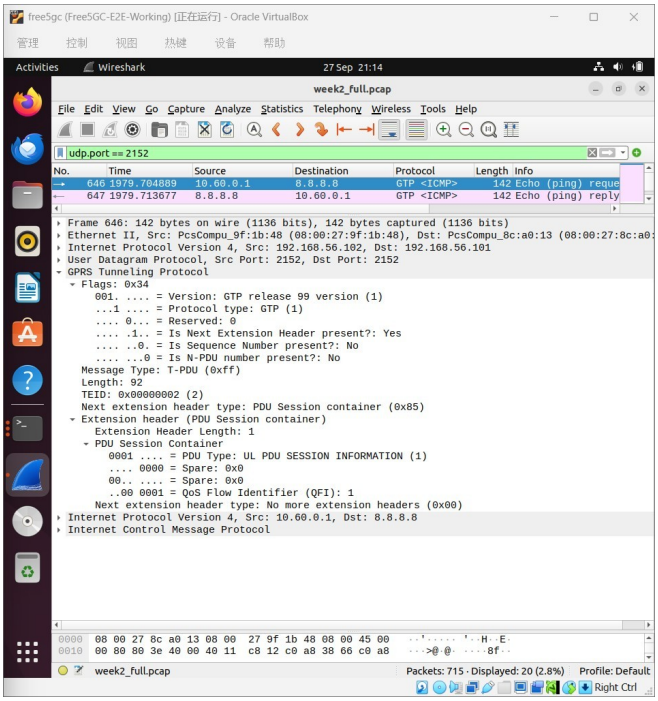


图 1 Frame 646：GTP-U 解封装后的 N3 外层地址、TEID 与内部 ICMP（截图来源：[R4]，第 11 页）

Frame 608 等已保护 NAS 的内部消息类型需解密后确认；本节只据可见字段解释链路。

3 KPI 数据与预处理

3.1 数据结构与质量审计

预测与异常模块采用公开 gotsf-ds 数据集。使用数据集中的 DLPRB、DLThpVol、DLThpTime、MR_number 四类 beam 级数据，整理成长表 kpi_timeseries.csv，规模为 2,419,200 行×17 列。索引 0–839 每个按 1 小时处理，覆盖 30 个基站、90 个 cell、2,880 个 beam，各 beam 均有 840 个索引记录。[R8,R9]

表 3 数据字段与时空规模 [R8,R15]

字段或对象	含义/规模	作用
Time	0–839；每索引 1 小时	时间切分及滞后关系
base_station / cell / beam	30 站、90 cell、2,880 beam	定义独立时序单元
DLPRB	下行 PRB 相关 KPI	资源使用表征
DLThpVol	下行吞吐数据量相关 KPI	流量强度表征
DLThpTime	下行吞吐持续时间相关 KPI	业务时长表征
MR_number	测量报告数量相关 KPI	测量活动表征
长表规模	2,419,200×17	建模的整理后数据

原始四份 KPI 表的时间轴、波束列一致，无缺失观测及重复时间，小时索引步长为 1。2,880×840=2,419,200 条观测构成长表。base_station、cell、beam 与 Time 共同用于记录对齐，不作为额外预测输入。原始值供评分和结果解释，标准化值供模型训练。[R15,R22]

3.2 特征和预测时间定义

以 t 为最后一个可见小时，标签为 t+1。树模型按 KPI 分组，依次取 t、t−1、t−2、t−24、t−168 的标准化值，形成 4×5=20 维输入。GRU 读取截至 t 的连续 24×4 序列，并拼接 t−168 的 4 维季节向量，联合输出四种 KPI。最长滞后要求至少 169 个连续整小时，首个有效目标为 169；2,880×671=1,932,480 条有效监督记录。[R19,R22]

所有评估均按小时获取截至当时的真实历史，再预测下一小时。连续 96 小时或 168 小时的评估窗是逐小时一步预测集合，不是一次性递归多步预测。加载器拒绝重复、缺失和非整数小时；训练与推理遵守同一列顺序和波束主键。[R19,R21]

3.3 训练与外层评估协议

表 4 各场景训练与评价时段 [R19,R20]

场景	训练目标	内部验证目标	外层目标	外层记录数
Fold1	169–335	336–383	384–479	276,480
Fold2	169–431	432–479	480–575	276,480
Fold3	169–527	528–575	576–671	276,480
留出	169–587	588–671	672–839	483,840

每个场景固定抽样种子 42，RF、XGBoost 和 GRU 使用完全相同的 60,000 条训练标签及目标时段。内部验证抽取 12,000 条用于 GRU 早停；树模型使用固定参数。三个外层折运行模型种子 42，留出运行 42 和 43。各外层时段使用全部 2,880 个 beam。[R19,R20]

各场景 StandardScaler 只在内部验证起点之前的原始观测上拟合并冻结，留出场景的拟合范围为 Time 0–587。外层评价不参与早停。训练前缀统计量对未来值变化保持不变的回归测试已通过。通用预处理文件中按 Time 0–671 拟合的变换列用于数据展示和异常模块；正式三模型预测实验按上述场景重新拟合，不直接沿用该全段 scaler。[R19–R22]

4 模型设计与实验方法

4.1 统一协议下的预测器

RandomForest 通过多棵随机采样回归树集成预测，XGBoost 通过逐轮拟合残差构建提升树；两者分别拟合每个 KPI。GRU 用门控循环编码器提取连续时序状态，连接季节向量后联合输出四项 KPI。统一训练标签和评价样本使结果可按同一目标时段比较；输入表示、早停和计算量各有差异，因此该比较用于工程选型。[R19,R20,R22]

表 5 正式预测器配置 [R19,R20]

模型	输入及输出	固定参数
RandomForest	20 维输入；每 KPI 单输出	30 棵；深度 16；叶节点最少 20；max_features=sqrt；max_samples=0.6
XGBoost	20 维输入；每 KPI 单输出	250 轮；深度 8；学习率 0.05；subsample=0.8；colsample_bytree=0.8
GRU	24×4 序列及 4 维季节向量；四输出	单层 hidden=32；Adam 0.001；batch=256；最多 12 轮；patience=3；CPU 4 线程

GRU 在标准化尺度优化四输出 MSE，评分时逆变换至原始数值尺度。Adam 训练权重、验证集选择轮次，均不等于自动超参数搜索。各折实际轮次、缩放均值及尺度保存在 runs.json，固定配置保存在 protocol.json。[R19,R20]

4.2 架构探索与参数搜索

架构探索覆盖 LSTM、GRU 和轻量 Transformer：LSTM、GRU 使用 hidden=32 的单层编码器；Transformer 使用线性嵌入、可学习位置参数、单层编码器、4 个注意力头及宽度 64 的前馈层，三者均连接季节向量和四输出预测头。LSTM、GRU、Transformer 参数量分别为 6,180、4,964、10,788。[R9,R22]

LSTM 与 Transformer 的探索记录采用训练目标 169–587、验证 588–671、测试 672–839，训练与验证各抽样 60,000 和 12,000 条，测试 483,840 条；其 scaler 在 Time 0–671 拟合，覆盖内部验证段，且仅运行模型种子 42。[R9,R19]

表 6 LSTM 与 Transformer 架构探索记录 [R9]

KPI	模型	MAE↓	RMSE↓	R^2↑
DLPRB	LSTM	0.2612	0.4919	0.7887
DLPRB	Transformer	0.2662	0.5201	0.7638
DLThpVol	LSTM	0.2205	0.4844	0.5738
DLThpVol	Transformer	0.2117	0.4874	0.5685
DLThpTime	LSTM	0.2428	0.5251	0.7016
DLThpTime	Transformer	0.2467	0.5590	0.6619
MR_number	LSTM	0.2260	0.3893	0.8714
MR_number	Transformer	0.2368	0.4269	0.8454

探索阶段还覆盖 Persistence、线性回归、决策树和 LightGBM，作为模型路线依据。独立参数搜索仅针对 DLPRB 的 RF：Optuna TPE 共 12 次，在 256 个 beam 的三折平均 RMSE 上选择参数。搜索范围为树数 40–160、深度 8–24、叶样本 5–50、max_features∈{sqrt,0.7,1.0}、max_samples 0.5–0.9；最优配置为 137、13、9、sqrt、0.698071，对应 CV RMSE=0.473700。 [R8,R22]

4.3 指标和选型规则

设 n 条评价观测的真值为 y_i、预测为 $\hat{y}_i$，均值为 $\bar{y}$，则 $MAE=(1/n)\Sigma|y_i-\hat{y}_i|$，$RMSE=\sqrt{[(1/n)\Sigma(y_i-\hat{y}_i)^2]}$，$R^2=1-\Sigma(y_i-\hat{y}_i)^2/\Sigma(y_i-\bar{y})^2$。所有评分先逐 beam-hour 计算；图中的平均曲线不替代逐样本评分。不同 KPI 的数值尺度不同，不跨 KPI 按绝对误差直接排名。

选型以 MAE 为主要指标，RMSE 用于检查大误差风险，R^2 辅助描述拟合程度。同一评价集上 RMSE 与 R^2 来自同一平方误差，不将两者名次重复加权为额外证据。三折时间回测、双种子留出和配对检验分别考察时段变化、初始化变化和损失差异。[R19,R20]

5 预测结果与模型选型

5.1 留出集预测结果

表 7 使用目标 Time 672–839 的全部 483,840 条 beam-hour，模型种子 42。三模型均按表 4 训练；指标保留六位小数，单位为数据集原始数值尺度。[R20]

表 7 留出集预测指标 seed42 [R20]

KPI	模型	MAE	RMSE	R^2
DLPRB	RandomForest	0.266552	0.513284	0.769915
DLPRB	XGBoost	0.268472	0.518092	0.765584
DLPRB	GRU	0.247765	0.476520	0.801694
DLThpVol	RandomForest	0.212908	0.478479	0.584089
DLThpVol	XGBoost	0.220221	0.559090	0.432144
DLThpVol	GRU	0.211055	0.498167	0.549158
DLThpTime	RandomForest	0.247807	0.540264	0.684194
DLThpTime	XGBoost	0.251333	0.581392	0.634282
DLThpTime	GRU	0.236438	0.519272	0.708258
MR_number	RandomForest	0.231022	0.413987	0.854584
MR_number	XGBoost	0.231131	0.416529	0.852792
MR_number	GRU	0.207566	0.366875	0.885797

GRU 在四项 KPI 上的 MAE 均最低，相对 RF 的 MAE 降幅依次为 7.05%、0.87%、4.59%、10.15%。DLPRB、DLThpTime 和 MR_number 的 RMSE 及 R^2 也以 GRU 较好。DLThpVol 上 RF 的 RMSE=0.478479、R^2=0.584089，优于 GRU 的 0.498167 和 0.549158，说明两类误差目标对应不同取舍。

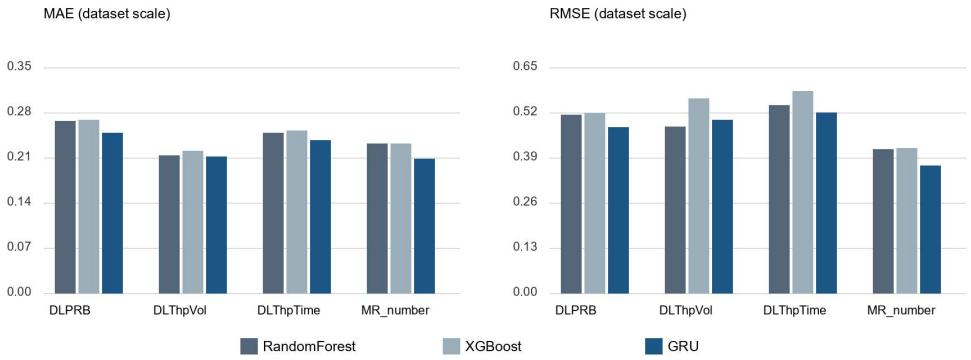


图 2 三模型留出 MAE 与 RMSE 目标 Time 672–839 n=483,840 seed42 [R20]

5.2 工程选型

以日常预测的平均绝对误差为目标，GRU 作为默认研究候选；DLThpVol 对极端误差敏感的场景保留 RF。XGBoost 作为提升树参照。部署时按 KPI 和损失目标选择模型，沿用模型自带的 scaler 与输入契约，避免混用不同实验的预处理状态。当前证据支持本数据集和配置下的离线选型。

6 稳健性与显著性

6.1 三折扩展窗口评估

表 8 三折外层指标均值与折间标准差 seed42 [R20]

KPI	模型	MAE 均值 ± SD	RMSE 均值 ± SD
DLPRB	GRU	0.2553 ± 0.0061	0.4756 ± 0.0077
DLPRB	RandomForest	0.2695 ± 0.0029	0.5161 ± 0.0107
DLPRB	XGBoost	0.2715 ± 0.0034	0.5237 ± 0.0112
DLThpVol	GRU	0.2287 ± 0.0127	1.0353 ± 0.3805
DLThpVol	RandomForest	0.2381 ± 0.0152	1.0875 ± 0.3967
DLThpVol	XGBoost	0.2440 ± 0.0137	1.1110 ± 0.3230
DLThpTime	GRU	0.2515 ± 0.0084	0.6752 ± 0.1417
DLThpTime	RandomForest	0.2628 ± 0.0125	0.7271 ± 0.1729
DLThpTime	XGBoost	0.2659 ± 0.0125	0.7259 ± 0.1452
MR_number	GRU	0.2121 ± 0.0028	0.3562 ± 0.0065
MR_number	RandomForest	0.2294 ± 0.0016	0.4069 ± 0.0029
MR_number	XGBoost	0.2291 ± 0.0021	0.4097 ± 0.0054

GRU 的四项 MAE 和 RMSE 三折均值均低于 RF、XGBoost。DLThpVol 的 GRU RMSE 为 1.0353±0.3805，折间变化较大；单次留出不能代表所有时段。这里的 SD 描述三个相邻评价窗的离散程度，不作为独立重复试验的置信区间。[R20]

6.2 配对损失检验

对相同 beam、相同目标小时逐条计算绝对损失和平方损失，再按小时平均，构成 168 对小时损失。定义 d=候选模型损失−参考模型损失，负值有利于候选。采用 Newey–West HAC，Bartlett 权重、带宽 24、双侧正态近似；每个场景及种子的 3 对模型×4 KPI×2 损失共 24 项一起 Holm 校正。表中 95% CI 为逐项 HAC 区间，p 值经过 Holm 校正。[R19,R20]

表 9 GRU 相对 RF 的配对留出损失 seed42 [R20]

KPI 与损失	平均差 d	95% CI	Holm p
DLPRB MAE	-0.018787	[-0.020485, -0.017089]	7.46e-103
DLPRB MSE	-0.036389	[-0.040054, -0.032723]	5.21e-83
DLThpVol MAE	-0.001853	[-0.004178, 0.000471]	0.354
DLThpVol MSE	0.019228	[-0.006343, 0.044798]	0.354
DLThpTime MAE	-0.011369	[-0.013218, -0.009520]	2.68e-32
DLThpTime MSE	-0.022241	[-0.027565, -0.016918]	2.64e-15
MR_number MAE	-0.023456	[-0.025629, -0.021282]	5.82e-98
MR_number MSE	-0.036788	[-0.041060, -0.032516]	1.23e-62

seed42 下，GRU 相对 RF 在 DLPRB、DLThpTime、MR_number 的绝对及平方损失均显著降低。DLThpVol 的 MAE 差为 −0.001853、MSE 差为 +0.019228，两项 Holm p≈0.354，尚未确认差异显著。GRU 相对 XGBoost 的四项 KPI、两类损失均显著降低；RF 与 XGBoost 在 MR_number 上的两类差异均不显著。完整 48 项检验包含两个种子，保存在 holdout_significance.csv。[R20]

6.3 随机种子与适用范围

表 10 两个种子的留出误差 [R20]

KPI	模型	MAE 42 / 43	RMSE 42 / 43
DLPRB	GRU	0.2478 / 0.2473	0.4765 / 0.4773
DLThpVol	GRU	0.2111 / 0.2097	0.4982 / 0.5001
DLThpTime	GRU	0.2364 / 0.2277	0.5193 / 0.5122
MR_number	GRU	0.2076 / 0.2080	0.3669 / 0.3697
DLPRB	RandomForest	0.2666 / 0.2663	0.5133 / 0.5115
DLThpVol	RandomForest	0.2129 / 0.2130	0.4785 / 0.4779
DLThpTime	RandomForest	0.2478 / 0.2478	0.5403 / 0.5408
MR_number	RandomForest	0.2310 / 0.2312	0.4140 / 0.4148
DLPRB	XGBoost	0.2685 / 0.2684	0.5181 / 0.5185
DLThpVol	XGBoost	0.2202 / 0.2201	0.5591 / 0.5561
DLThpTime	XGBoost	0.2513 / 0.2515	0.5814 / 0.5877

KPI	模型	MAE 42 / 43	RMSE 42 / 43
MR_number	XGBoost	0.2311 / 0.2310	0.4165 / 0.4158

两个种子均呈现 GRU 四项 MAE 最低、RF 的 DLThpVol RMSE 最低。DLThpVol 的 GRU 对 RF MAE 差异在 seed43 的 Holm p=0.01035，MSE 的 p=0.3196；该项绝对损失的显著性随种子变化，应连同效应量解释。两种种子使用相同抽样及相同测试时段，只提供有限初始化复核。

留出时段曾用于项目选型，本节采用固定留出集及双种子复核，支持该数据集内的模型选型。HAC 检验以 168 个小时为时间样本，依赖渐近近似；三个相邻时间窗也不足以覆盖长期非平稳性。 [R19–R21]

7 异常检测与根因排查

7.1 检测目标与四类方法

异常实验针对 Time 672–839 的 483,840 条 beam-hour 四维观测开展分布偏离筛选，拟合区间为 Time 0–671。统计方法以同一 beam 在训练期的历史分布计算阈值；多变量方法使用四种 KPI 当前标准化值与一阶差分共 8 个特征。[R11]

表 11 异常算法与训练口径 [R11]

方法	关键参数或规则	训练/测试口径
3σ	各 beam 各 KPI：训练均值±3×标准差；任一越界即标记	训练 Time 0–671；测试全量
IQR	Q1−1.5×IQR / Q3+1.5×IQR；任一越界标记	训练 Time 0–671；测试全量
Isolation Forest	n_estimators=150；max_samples=256；contamination=0.02	随机训练 80,000；测试全量
One-Class SVM	RBF；nu=0.02；gamma=scale	训练抽样 2,500；测试抽样 12,000
联合筛查	IF AND (3σ OR IQR)	全量测试；SVM 不参与投票

7.2 检测结果与时间聚集

表 12 异常候选数量与分母 [R11,R21]

算法	测试数量	标记数量	标记率	说明
3σ	483,840	22,059	4.56%	全量
IQR	483,840	51,318	10.61%	全量
Isolation Forest	483,840	9,900	2.05%	全量

算法	测试数量	标记数量	标记率	说明
One-Class SVM	12,000	552	4.60%	抽样，不可与全量计数并列排名
联合规则	483,840	3,165	0.654%	全量，优先核查候选

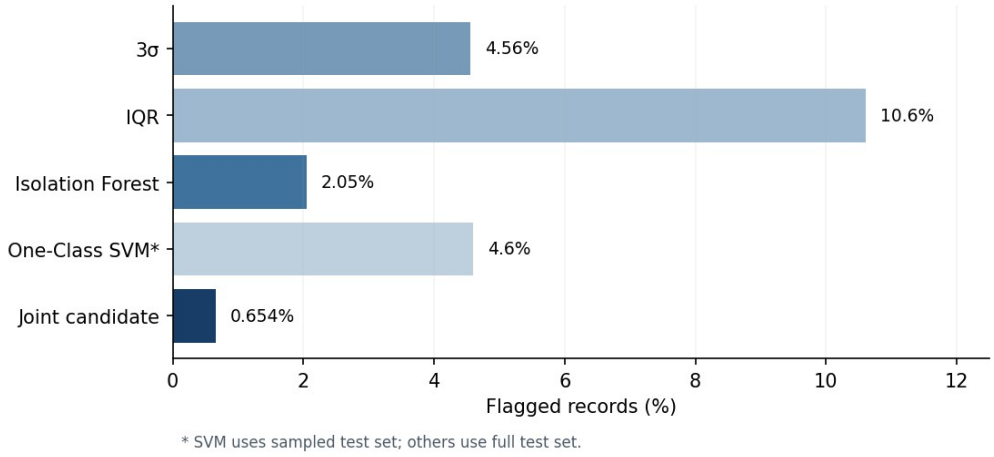


图 3 异常标记比例比较（SVM 分母为抽样测试集；依据 [R11] 重绘）

图 3 中全量测试 IQR、3σ、IF 分别标记 51,318、22,059、9,900 条；IQR 标记数约为 3σ 的 2.33 倍。SVM 的 552/12,000=4.60% 使用单独抽样分母。最终规则产生 3,165/483,840=0.654% 候选，作为人工核查入口。[R11,R14]

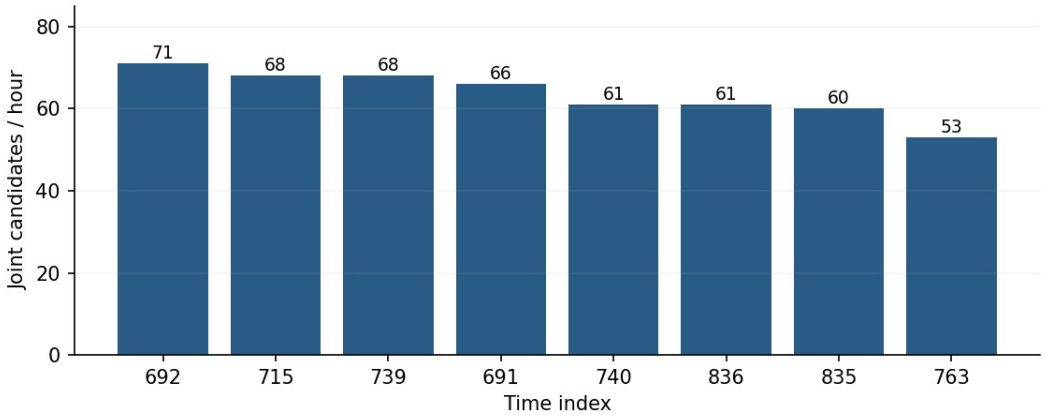


图 4 联合异常候选数最高的测试时间索引（依据 [R11] 重绘）

Time 692 有 71 个候选、715 和 739 各 68 个、691 为 66 个，740 和 836 各 61 个，835 为 60 个，763 为 53 个。691–692、739–740、835–836 等相邻时间点的候选聚集，可作为时域排查线索。[R11]

7.2.1 标记率差异的分布诊断

为解释 IQR 标记率高于 3σ 的原因，对全部 2,880 个波束分别计算训练区间四项 KPI 的偏度、超额峰度、IQR，并统计每项 KPI 在 483,840 条测试记录上的触发比例。IQR 常用的 1.5×IQR 围栏通常比高斯分布的均值±3σ 更窄；实际数据又显著偏离对称轻尾分布，因此两种阈值对极端点的敏感性不同。[R14,R15]

表 13 逐波束分布形态与逐 KPI 触发率 [R14,R15]

KPI	|偏度|>1	超额峰度>3	3σ / IQR 标记率
DLPRB	86.25%	59.79%	1.77% / 4.13%
DLThpVol	98.33%	75.45%	1.60% / 4.59%
DLThpTime	96.56%	76.15%	1.85% / 4.87%
MR_number	59.76%	21.77%	1.39% / 2.76%

统计证据：DLThpVol、DLThpTime 的训练分布中，超过 96% 的波束具有 |偏度|>1，超过 75% 的波束具有超额峰度>3；在四项 KPI 上，IQR 的逐指标触发率均高于 3σ，且没有波束出现 IQR 为零的退化分布（fallback=0）。这表明阈值宽度、显著偏态和厚尾可能共同影响标记率。[R14,R15]

7.2.2 AND/OR 逻辑组合与共识规则选择

记 A 为 Isolation Forest 标记，B 为 3σ 标记，C 为 IQR 标记。系统采用 A∩(B∪C)：要求多变量异常检测与至少一项逐波束统计阈值同时触发。与直接 OR 合并相比，该规则显著缩小审查集合；与 A∩B∩C 相比，它又不要求两个统计阈值完全一致。以下组合均在相同的 483,840 条完整测试记录上评估，One-Class SVM 因抽样协议不同不参与共识投票。[R14]

表 14 AND 与 OR 组合的候选集合 [R14]

筛选逻辑	候选数量 / 483,840	标记率	规则含义
3σ OR IQR	51,373	10.62%	只需任一种统计阈值触发
3σ AND IQR	22,004	4.55%	两种统计阈值均触发
IF AND 3σ	2,080	0.43%	IF 与 3σ 同时触发
IF AND IQR	3,159	0.65%	IF 与 IQR 同时触发
IF AND (3σ OR IQR)	3,165	0.654%	最终采用：多变量与统计信号交叉确认
IF AND 3σ AND IQR	2,074	0.43%	全部三种方法必须同时触发
IF OR 3σ OR IQR	58,108	12.01%	任一方法触发即可入选

纯 OR 得到 58,108 条候选，三者 AND 得到 2,074 条。采用 IF AND（3σ OR IQR）形成 3,165 条优先核查集合，其中仅 6 条超出 IF AND IQR 的 3,159 条。规则控制审查规模，其效果需在故障工单真值下评估；当前不报告故障精确率、召回率或误报率。[R14,R21]

7.3 异常候选间的 KPI 相关性

四项 KPI 的 Pearson 相关系数基于全部 3,165 条联合候选，覆盖 30 个基站。每对记录数为 3,165，聚类数为 30。p 值来自以基站聚类的稳健零回归斜率检验，六对一起 Holm 校正；相关系数的 95% 区间另用站级 bootstrap 估计。[R16]

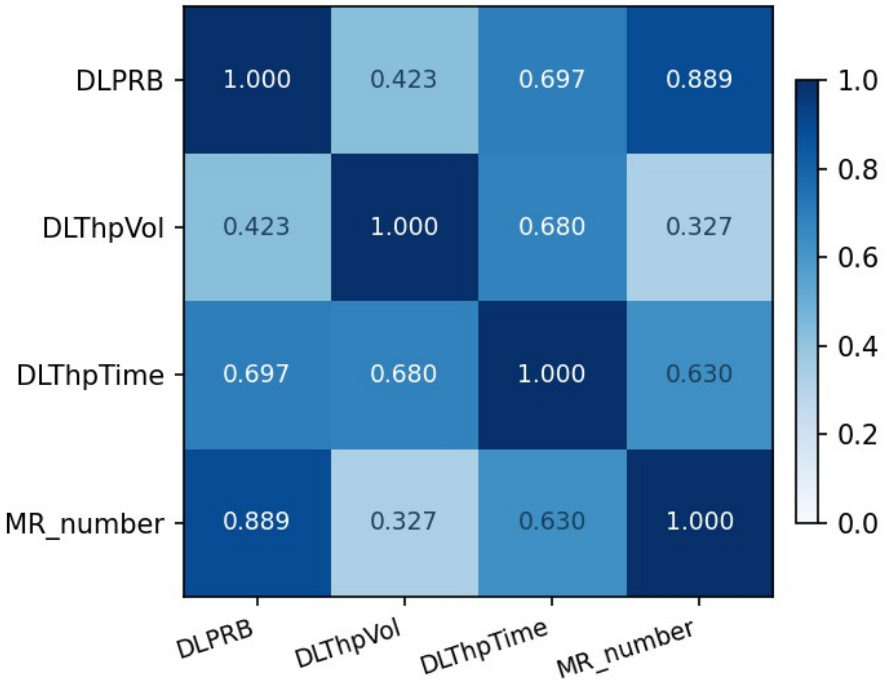


图 5 联合异常候选 KPI Pearson 矩阵：n=3,165，30 个基站，Time 672-839（据[R12]数值重绘）

表 15 候选 KPI 关联与站级统计推断 [R16]

KPI 组合	r	站级 bootstrap 95% CI	Holm p
DLPRB / DLThpVol	0.423	[0.169, 0.601]	7.61e-05
DLPRB / DLThpTime	0.697	[0.485, 0.795]	3.53e-10
DLPRB / MR_number	0.889	[0.841, 0.918]	1.1e-28
DLThpVol / DLThpTime	0.680	[0.535, 0.770]	2.68e-08
DLThpVol / MR_number	0.327	[0.065, 0.488]	0.0101
DLThpTime / MR_number	0.630	[0.449, 0.758]	8.36e-08

六组关联的 Holm p 均小于 0.05，DLPRB 与 MR_number 相关性最高，r=0.889。 [R16]

7.4 可解释的根因假设与验证路径

表 16 排查假设与核验材料 [R12]

异常模式	待验证的机制性假设	优先补充证据
DLPRB↑ + DLThpVol / DLThpTime 同向变化	业务负载增加、调度资源压力	PRB 资源、活跃 UE、吞吐统计、调度日志
DLThpTime 偏高而 DLThpVol 未同步增加	吞吐效率或业务持续时间变化	MCS、BLER、重传率、SINR、业务类型

异常模式	待验证的机制性假设	优先补充证据
MR_number 与其他 KPI 同步偏高	测量活动 / 终端规模变化	RRC 测量配置、UE 数量、切换记录
相邻 beam / cell 同时异常	站点共因、流量模式或外部事件	站点告警、拓扑、相邻小区对照

建议按“单 beam 历史偏离→同 cell 同步性→同基站扩散→外部告警/无线质量复核”逐层推进，并为每条事件生成 Time、base_station、cell、beam、触发算法、主要偏离 KPI、邻近时段曲线和核验状态。已导出的 w3_anomaly_candidate_events.csv 只包含按 Isolation Forest 分数排序的前 2,000 条，而不是全部 3,165 条候选；空间风险率必须基于补齐后的全量输出计算。[R11,R12]

典型调查样例：Time 711 / 13_0_11 的四个 KPI 均有较大逐 beam z 分数且统计规则同时触发；Time 715 / 22_2_13 的多个 KPI 同时偏高，并在 Time 835 再次形成候选。 [R12]

8 系统集成与验收

8.1 系统架构与功能

项目已基于 Python、Streamlit 实现从数据准备、模型训练及评估，到实验版本管理、下一小时预测、异常候选检测与关联分析的本机 Web 应用。入口为 app.py，业务代码按 src/core、data、models、analysis、services、ui 分层。训练评估基于测试集计算 MAE、RMSE、R^2；实际推理从用户上传或系统演示 CSV 调用保存的可信模型权重生成未来 KPI 或异常标记，两类操作在界面中分开。[R17,R18]

系统通过独立 run_id 管理训练实验，将参数、模型、scaler 与评价报告归档到 resources/experiments/<run_id>/，发布工件到 resources/models/<run_id>/。后台训练经 WebSocket 推送日志；公共字段、波束主键、时间窗口集中在 src/core/config.py。界面评估读取所选实验的输出，实时预测及关联分析读取本次输入和候选集合。[R17,R18,R21]

表 17 六个业务页面及输出 [R17,R18]

功能页面	实际输入或操作	系统输出	实现状态
数据管理与预处理	下载 KPI、审计、特征构建	数据状态与特征缓存	已实现
模型训练	选择模型、参数并训练	实时日志、指标、权重	已实现
模型管理与实验记录	选择历史结果或 run_id	版本比较和评估曲线	已实现
KPI 预测	输入历史 CSV、选择模型	下一小时结果与 CSV	已实现
异常检测	全波束 KPI、异常权重	方法标记、候选与导出	已实现
KPI 关联分析	选择本次或历史候选	KPI 相关矩阵与样本量	已实现

8.2 本机交互与推理证据

本机完成传统 ML 快速训练、GRU 小样本训练、异常模型训练以及模型发布、回载、实际预测和 CSV 导出。其后整理六模块界面并补充当次候选关联分析；后续真实 Web 截图分别展示六模块菜单、模型管理与评估、Time 840 的 MR_number 预测值 0.6485、异常检测 58/5,760 条候选以及基于本次候选的 KPI 关联矩阵。[R17,R18]



图 6 六模块 Streamlit Web 应用实际界面：数据管理与预处理（用户本机截图）

本机实际预测使用单波束真实历史观测（至少 169 个连续小时）并调用已保存模型；异常演示输入保留 2,880 个波束的连续 3 小时，首小时用于差分上下文，输出 5,760 条候选评估记录。该演示的 58 条候选与正式测试集的 3,165 条分别统计，不合并。[R17]

8.3 自动回归与工件验证

表 18 系统验收证据与完成状态 [R18,R21]

验收项	证据与结果	状态
完整自动回归	reports/delivery_final_20261025/tests.txt 记录 58 项测试全部通过；含数据契约、scaler、推理及实验隔离	通过
六页自动加载和切换	web_apptest.json 六页 exceptions 与 visible_errors 均为空	通过
正式模型工件	seed42 的 GRU 及 RF/XGBoost 各四个权重完成回载推理与 CSV 导出	通过
异常工件	既有异常权重对 5,760 条演示观测检测及 CSV 导出完成	通过
命令行训练入口	1 轮、512 样本的 DL CLI 功能验证；分数不参与正式选型	通过

自动回归覆盖重复、非整数及共同缺失小时拒绝，20 维训练推理一致性，深度模型窗口边界，未来值不影响训练 scaler，独立模型宽度，以及实验报告来源隔离。正式工件回载验证使用已训练模型，和快速训练入口检查共同构成可运行性证据。[R21]

开发过程中出现过不同 DL 训练实验合并后 train_scale_mean 不一致，以及 Windows GBK 子进程打印“R²”导致 UnicodeEncodeError 的问题。对应修复是按 run_id 分离训练参数、标准化状态、模型与报告，并在后台进程强制使用 UTF-8 I/O。将训练评估与实际模型推理拆成独立页面之后，也减少了历史测试曲线与当前输入结果被误读的风险。[R17,R18]

9 结论

项目完成了 5G SA 控制面与用户面验证、公开 KPI 数据处理、预测模型评估、无监督异常候选筛查以及六页面系统集成。抓包关键帧和 TEID 用于验证链路一致性；预测实验采用固定协议的逐 beam-hour 评价；系统侧完成 58 项自动回归、六页加载和真实模型工件回载验证。[R2–R5,R19–R21]

RF、XGBoost、GRU 在统一训练标签和时间协议下，GRU 的四项留出 MAE 及三折平均 MAE 均较低；DLThpVol 的留出 RMSE 以 RF 更优。因此默认选型为 GRU；DLThpVol 若以 RMSE 为主要指标，则选 RF。LSTM、Transformer 保留为独立架构探索。[R19,R20]

异常规则将全量 483,840 条观测筛为 3,165 条优先核查候选。分布统计和站级聚类关联仅用于解释阈值差异和候选排序。由于缺少故障真值，目前只能评价候选集合规模，不能评价故障检出效果；后续需接入告警、工单和无线质量记录核验。[R11,R14–R16]

参考资料

[R1] 《基于 AI 的 5G 网络关键性能指标预测与异常检测系统》：项目要求及实施大纲，7 页。

[R2] 《W1 环境配置文档》：Windows/WSL2/VirtualBox、free5GC + UERANSIM 环境搭建与联通性验证，20 页。

[R3] 《W1》：第一周实验报告，2 页。

[R4] 《协议分析》：5G 核心协议分析、week2_full.pcap 抓包与 N2/N3 字段解析，12 页。

[R5] 《信令流程》：关键报文逐帧与截图解释，13 页。

[R6] 《学习笔记》：5G SA、核心网功能与接口术语，4 页。

[R7] 《W1 周报》：第一周搭建进度与问题修复记录，2 页。

[R8] deliverables/submit2/5_模型性能评估报告.pdf；reports/model_metrics.csv、reports/validation/；传统 ML 阶段评价与历史验证。

[R9] deliverables/submit3/2-深度学习模型性能评估报告.pdf；reports/w3_deep_learning_metrics.csv、reports/w3_deep_learning_run_config.json；架构探索与正式 GRU 验证。

[R10] deliverables/submit3/3-传统机器学习与深度学习模型对比分析.pdf；统一协议、三指标、时间回测及配对检验。

[R11] deliverables/submit3/5-异常检测结果报告.pdf；reports/w3_anomaly_method_summary.csv、reports/w3_anomaly_rate_by_hour.csv；异常标记率与时段统计。

[R12] deliverables/submit3/6-异常根因分析初步方案.pdf；KPI 关联、站级统计推断与分层排查。

[R13] reports/raw_data_audit.json、raw_data_audit_summary.csv；四份原始 KPI 表的时间轴、缺失值、重复时间与波束一致性审计。

[R14] reports/w4_anomaly_logic_comparison.csv、reports/w4_anomaly_threshold_shape_summary.csv、reports/w4_anomaly_distribution_summary.csv；分布与联合规则定量分析。

[R15] reports/w4_anomaly_threshold_shape_summary.csv、reports/w4_anomaly_distribution_summary.csv：各波束偏度/峰度与逐指标标记率的统计输出。

[R16] reports/w4_anomaly_kpi_correlation_tests.csv、reports/w4_anomaly_kpi_correlation_pvalues_holm.csv：n=3,165、30 站聚类稳健检验、bootstrap 区间和 Holm 校正 p 值。

[R17] GitHub 仓库 Lemon-Li-x86/5g-kpi-prediction，交付分支 codex/delivery-audit-20261025；README.md、USERGUIDE.md、ARCHITECTURE.md、app.py、src/、tests/。

[R18] USERGUIDE.md；reports/final_audit_20261025/w4_verification.json、web_apptest.json；本机功能验收与当前操作说明。

[R19] reports/final_audit_20261025/experiments/protocol.json、runner_used.py、runs.json；训练标签、分折、缩放、模型参数与检验协议，2026-10-25。

[R20] reports/final_audit_20261025/experiments/metrics.csv、walkforward_summary_flat.csv、seed_summary.csv、hourly_losses.csv、holdout_significance.csv、COMPLETE.json；正式预测结果与配对统计输出。

[R21] reports/delivery_final_20261025/tests.txt；reports/final_audit_20261025/ 下的 web_apptest.json、real_artifact_roundtrip.json、w4_verification.json、cli_smoke.txt；最新 58 项回归及既有页面、工件验证。

[R22] ARCHITECTURE.md；reports/raw_data_audit.json、reports/preprocessing_summary.json；src/core/config.py、src/models/architectures.py、src/analysis/final_model_validation.py；数据、配置与实现。

附录 A 生成式 AI 使用情况

功能模块	生成式 AI 使用
1. 环境配置与数据采集	提供环境配置方法、部署命令及故障排查建议；生成抓包脚本并辅助修正错误。
2. KPI 数据预处理	辅助检索数据集及预处理方法；编写数据清洗、标准化和时间序列构建代码。
3. 传统机器学习预测	编写 RF、XGBoost、LightGBM 等模型的训练与评估代码，辅助定位和修复程序错误。
4. 深度学习预测	编写 LSTM、GRU、Transformer 模型代码及训练流程，辅助调试与优化。
5. 异常检测	编写异常检测代码，实现统计阈值、无监督检测及联合筛选方法。
6. 异常根因分析	编写 KPI 相关性分析与异常候选筛选代码，辅助提出初步排查假设。
7. Web 可视化与系统集成	编写 Streamlit 界面及业务逻辑代码，完成各功能模块的集成与调试。
8. 代码重构与维护	根据功能需求调整模块结构，统一配置参数，清理重复逻辑并重构代码。
9. 报告与技术文档	生成实验报告、结果分析及使用文档